

CHAPITRE I

Généralités sur les PFAS et l'intelligence artificielle

I.1 - Introduction

La surveillance de la qualité des eaux souterraines constitue aujourd'hui l'un des défis environnementaux les plus pressants, en particulier face à l'émergence de contaminants persistants dont les effets sur la santé humaine et les écosystèmes ne cessent d'être documentés. Parmi ces contaminants, les substances per- et polyfluoroalkylées (PFAS) occupent une place singulière : leur extrême stabilité chimique, leur mobilité dans les milieux aqueux et leur large diffusion industrielle en font une classe de polluants d'une persistance redoutable, souvent qualifiés de « polluants éternels » [Guelfo et al., 2021].

Face à l'ampleur du défi analytique — des milliers de composés à surveiller sur des milliers de sites — les approches traditionnelles d'échantillonnage exhaustif se heurtent à des contraintes budgétaires et logistiques incontournables. C'est dans ce contexte que l'intelligence artificielle, et plus précisément l'apprentissage automatique, s'impose comme un levier stratégique pour aider les régulateurs, les services d'eau potable et les bureaux d'études environnementaux à prioriser leurs efforts de surveillance. En permettant de prédire le risque de contamination à partir de données contextuelles — proximité de sources industrielles, caractéristiques hydrogéologiques, indicateurs de qualité de l'eau — ces méthodes offrent une voie prometteuse pour orienter les ressources là où elles sont le plus nécessaires [George et Dixit, 2021].

Ce premier chapitre pose les fondations conceptuelles nécessaires à la compréhension de l'ensemble du travail. Nous y présentons, d'une part, les propriétés physico-chimiques des PFAS, leurs sources, leur comportement environnemental et leur impact sur la santé, ainsi que les cadres réglementaires qui encadrent leur surveillance. D'autre part, nous introduisons les principaux paradigmes de l'apprentissage automatique mobilisés dans ce travail : les méthodes d'ensemble (gradient boosting, forêts aléatoires, stacking), la gestion du déséquilibre de classes, les réseaux de neurones sur graphes et, enfin, les approches

d'interprétabilité des modèles. Cette vue d'ensemble constitue le socle théorique à partir duquel s'articulent nos contributions.

I.2 - Les substances per- et polyfluoroalkylées (PFAS)

I.2.1 - Définition et propriétés physicochimiques

Les PFAS (per- and polyfluoroalkyl substances) désignent une famille extrêmement vaste de composés organiques de synthèse partageant une caractéristique structurelle fondamentale : une chaîne carbonée sur laquelle tout ou partie des atomes d'hydrogène ont été remplacés par des atomes de fluor. Cette substitution est à l'origine des propriétés remarquables — et problématiques — de ces molécules. La liaison carbone-fluor est en effet l'une des plus fortes que l'on rencontre en chimie organique, ce qui confère aux PFAS une résistance quasi absolue à la dégradation biologique, thermique et chimique [Prevedouros et al., 2006].

La famille des PFAS regroupe aujourd'hui plusieurs milliers de composés distincts. Les plus étudiés sont l'acide perfluorooctanesulfonique (PFOS) et l'acide perfluorooctanoïque (PFOA), deux composés à longue chaîne carbonée (C8) largement utilisés dans l'industrie depuis les années 1950. Plus récemment, sous la pression réglementaire, l'industrie a eu recours à des PFAS à chaîne courte (C4 à C6) présentés comme des alternatives, mais dont la persistance et la mobilité environnementales se révèlent elles aussi préoccupantes [Li et MacDonald Gibson, 2022].

Sur le plan physicochimique, on distingue généralement les PFAS en deux grandes catégories selon la nature du groupement fonctionnel en bout de chaîne : les acides perfluoroalkylcarboxyliques (PFCA, dont PFOA) et les acides perfluoroalkylsulfoniques (PFSA, dont PFOS). Cette distinction influe directement sur les propriétés d'adsorption, de solubilité et de mobilité dans les milieux poreux [Brusseau et al., 2019]. En raison de leur caractère tensioactif — amphiphile, combinant une tête polaire et une queue fluorée apolaire — les PFAS s'accumulent préférentiellement aux interfaces air-eau et solide-eau, une propriété qui complique considérablement la modélisation de leur transport en zone non saturée [Brusseau et al., 2019].

I.2.2 - Sources, transport et devenir environnemental

Les PFAS sont omniprésents dans l'environnement en raison de leur utilisation industrielle massive sur plusieurs décennies. Hu et al. [2016] ont établi un lien statistiquement robuste entre la présence de PFAS dans les eaux de consommation et la proximité d'installations industrielles, de bases militaires utilisant des mousses anti-incendie à base de PFAS (AFFF, pour Aqueous Film-Forming Foam), et de stations d'épuration des eaux usées (STEP). Ces trois catégories de sources constituent les principaux points d'émission identifiés dans la littérature.

La mousse AFFF mérite une attention particulière. Développée à partir des années 1960 et largement utilisée dans les armées du monde entier pour combattre les incendies d'hydrocarbures, cette mousse contient des concentrations élevées en PFOS et en précurseurs fluorés. Les zones d'entraînement au feu sur les bases militaires constituent ainsi des hotspots de contamination bien documentés, où les PFAS infiltrés au fil des décennies atteignent encore aujourd'hui les nappes phréatiques [Kibbey et al., 2020].

Le transport des PFAS dans l'environnement fait intervenir des mécanismes couplés qui en rendent la modélisation délicate. Dans le compartiment souterrain, leur mobilité est gouvernée par les propriétés hydrauliques du milieu (conductivité hydraulique, porosité, gradient hydraulique), la teneur en carbone organique du sol et le pH de l'eau souterraine. Weber et al. [2017] ont étudié en détail ces contrôles hydrogéochimiques sur un site expérimental de Cape Cod (Massachusetts), montrant que des sols sableux à faible teneur en matière organique permettent une migration rapide des PFAS vers la nappe, avec des panaches s'étendant parfois sur plusieurs kilomètres en aval des sources.

Le transport atmosphérique constitue une voie de contamination longue distance encore mal intégrée dans les outils de prédiction opérationnels. D'Ambro et al. [2021] ont caractérisé les émissions aériennes et le dépôt de PFAS depuis une usine de fabrication de polymères fluorés, montrant que ces composés peuvent être transportés sur de longues distances avant de se déposer dans les eaux de surface et les sols. Cette voie de contamination diffuse représente l'une des lacunes majeures des approches de modélisation actuelles, qui restent majoritairement centrées sur les sources ponctuelles en contact direct avec les eaux souterraines.

La co-occurrence des PFAS avec d'autres contaminants organiques — notamment les solvants chlorés (TCE, PCE) et les additifs d'essence (MTBE) — est fréquemment observée sur les sites industriels et militaires, où ces différents polluants partagent une histoire de contamination commune. Cette co-occurrence offre un signal indirect précieux pour la prédiction de la présence de PFAS, même en l'absence de mesures analytiques spécifiques [Hu et al., 2016].

1.2.3 - Impacts sanitaires et cadre réglementaire

Les préoccupations sanitaires liées à l'exposition aux PFAS sont multiples et documentées par une littérature épidémiologique croissante. Sunderland et al. [2019] ont synthétisé les voies d'exposition humaine — eau potable, alimentation, poussières domestiques, produits de consommation — et résumé l'état des connaissances sur les effets sur la santé. Parmi les effets les mieux documentés, on distingue l'immunotoxicité (réduction de la réponse vaccinale), la perturbation endocrinienne (altération des hormones thyroïdiennes), des effets sur le développement fœtal et des associations avec certains types de cancers. Ces effets surviennent à des concentrations très faibles, de l'ordre du nanogramme par litre dans l'eau potable, ce qui justifie des valeurs guide extrêmement basses [Sunderland et al., 2019].

Sur le plan réglementaire, l'Agence américaine de protection de l'environnement (U.S. EPA) a franchi une étape majeure en 2023 en établissant des Niveaux Maximaux de Contaminants (MCL) pour six PFAS dans l'eau potable, dont une valeur de 4 ng/L pour le PFOS et le PFOA pris séparément [U.S. Environmental Protection Agency, 2023]. Cette réglementation, parmi les plus strictes au monde, crée une pression considérable sur les services d'eau potable et les agences régionales pour étendre et intensifier la surveillance des réseaux de distribution. Elle constitue par ailleurs un signal fort pour l'adoption d'outils d'aide à la décision capables de hiérarchiser les sites à surveiller en priorité.

En Europe, la directive-cadre sur l'eau et la directive sur l'eau potable (2020/2184/UE) ont été amendées pour intégrer certains PFAS dans la liste des substances réglementées, avec des valeurs paramétriques portant sur la somme des 20 PFAS les plus préoccupants. Des pays comme l'Allemagne, les Pays-Bas et le Danemark ont mis en place des programmes de surveillance spécifiques dès la fin des années 2000, accumulant des bases de données précieuses pour l'entraînement de modèles prédictifs. Ce contexte réglementaire international en rapide évolution souligne la nécessité de disposer d'approches d'évaluation

du risque robustes, scalables et adaptables à différents contextes hydrogéologiques et réglementaires.

I.3 - Apprentissage automatique et méthodes d'ensemble

I.3.1 - Panorama des paradigmes d'apprentissage

L'apprentissage automatique (machine learning) est un sous-domaine de l'intelligence artificielle qui vise à doter les systèmes informatiques de la capacité d'apprendre à partir de données sans être explicitement programmés pour chaque tâche. Mitchell [1997] en donne la définition fondatrice : un programme informatique apprend de l'expérience E par rapport à une classe de tâches T et une mesure de performance P , si sa performance sur les tâches dans T , mesurée par P , s'améliore avec l'accumulation de l'expérience E . Cette définition capture l'essence de la discipline : l'amélioration progressive par exposition aux données.

On distingue classiquement trois grands paradigmes d'apprentissage. L'apprentissage supervisé constitue le cadre le plus répandu pour les problèmes de classification et de régression : l'algorithme est entraîné sur un ensemble de paires (entrée, sortie connue) et apprend à généraliser la relation entre les deux. C'est ce paradigme qui est au cœur du présent travail, où il s'agit de prédire le statut de contamination d'un point d'eau souterraine à partir de ses caractéristiques contextuelles [Pedregosa et al., 2011].

L'apprentissage non supervisé, quant à lui, vise à découvrir des structures latentes dans des données non étiquetées — typiquement par des algorithmes de partitionnement (clustering) comme k-Means, utilisé dans notre pipeline pour la construction de clusters géographiques. Enfin, l'apprentissage semi-supervisé tire parti de volumes importants de données non étiquetées pour compléter un signal d'entraînement supervisé limité : Dong et al. [2024] ont montré l'intérêt de cette approche pour la prédiction multi-étiquette des PFAS dans les eaux souterraines californiennes, où les observations étiquetées comme positives restent rares.

Dans le contexte de la surveillance des PFAS, la tâche de classification binaire — un site est-il contaminé ou non au regard d'un seuil réglementaire donné ? — constitue l'application centrale. Les méthodes d'ensemble, qui agrègent les prédictions de plusieurs modèles apprenants, se sont révélées particulièrement performantes sur ce type de problème à données tabulaires, surpassant fréquemment les réseaux de neurones profonds génériques

sur des jeux de données de taille modérée [Borisov et al., 2024]. La section suivante leur est consacrée.

I.3.2 - Méthodes d'ensemble

Les méthodes d'ensemble reposent sur un principe simple mais puissant : combiner les prédictions de plusieurs modèles dits « apprenants faibles » pour obtenir un modèle collectif plus robuste et plus précis qu'aucun des modèles pris isolément. Ce paradigme se décline en plusieurs architectures, dont les principales sont le bagging (dont les forêts aléatoires sont l'exemple canonique), le boosting (gradient boosting) et le stacking. Nous présentons ci-dessous les variantes utilisées dans le cadre de ce travail.

I.3.2.1 - Gradient boosting : XGBoost et LightGBM

Le gradient boosting est une technique d'ensemble proposée par Friedman [2001] dans laquelle les modèles sont construits séquentiellement : chaque nouvel apprenant est entraîné pour corriger les erreurs résiduelles du modèle précédent, en minimisant une fonction de perte différentiable par descente de gradient dans l'espace fonctionnel. Cette approche itérative permet au modèle global de se concentrer progressivement sur les exemples les plus difficiles à classer.

XGBoost (eXtreme Gradient Boosting), proposé par Chen et Guestrin [2016], constitue aujourd'hui la référence en matière de gradient boosting sur données tabulaires. Ses innovations clés par rapport à l'algorithme original de Friedman incluent une régularisation L1/L2 intégrée pour contrôler le surapprentissage, un traitement optimisé des valeurs manquantes, un algorithme de construction d'arbres basé sur l'approximation par histogramme pour une meilleure scalabilité, et une parallélisation efficace du calcul. Dans le cadre de la priorisation des puits d'eau souterraine pour la détection des PFAS, XGBoost a démontré des performances remarquables sur le jeu de données CA-PFAS-ASGWS de Californie, atteignant des valeurs F1 de 0,977 et ROC-AUC de 0,998 en mode confirmatoire [Bomgni et al., 2025].

LightGBM (Light Gradient Boosting Machine), développé par Ke et al. [2017], adopte une stratégie de croissance des arbres différente de celle de XGBoost. Là où XGBoost construit ses arbres niveau par niveau (level-wise), LightGBM adopte une croissance feuille par feuille (leaf-wise) qui permet d'atteindre une perte plus faible avec moins d'itérations. Il introduit également deux innovations algorithmiques majeures : le Gradient-based One-

Side Sampling (GOSS), qui réduit la taille de l'ensemble d'entraînement en conservant préférentiellement les exemples à fort gradient, et l'Exclusive Feature Bundling (EFB), qui regroupe des variables creuses mutuellement exclusives pour réduire la dimensionnalité. Dans notre pipeline, LightGBM est utilisé comme apprenant de base diversifié au sein de l'ensemble par stacking, apportant une perspective complémentaire à XGBoost pour le méta-classifieur [Ke et al., 2017].

1.3.2.2 - Forêts aléatoires (Random Forest)

La forêt aléatoire (Random Forest), introduite par Breiman [2001], constitue le paradigme de bagging par excellence. Elle repose sur la construction d'un grand nombre d'arbres de décision entraînés sur des sous-échantillons tirés avec remise du jeu d'entraînement (bootstrap), chaque arbre n'ayant accès, à chaque nœud de division, qu'à un sous-ensemble aléatoire des variables prédictives. Cette double source de randomisation — échantillonnage des observations et des variables — crée une diversité importante entre les arbres, réduisant la variance du modèle global par rapport à un arbre unique. La prédiction finale est obtenue par vote majoritaire en classification.

Dans le domaine de la priorisation des eaux souterraines, George et Dixit [2021] ont développé l'un des premiers frameworks dédiés à la classification des sites pour la détection de PFAS, utilisant des forêts aléatoires et des algorithmes de gradient boosting sur un jeu de données propre. Leurs résultats, rapportant une précision supérieure à 85 % pour la classification binaire de priorité, ont constitué un jalon important dans la littérature sur l'application du machine learning à la surveillance des PFAS et une référence de comparaison pour les travaux ultérieurs.

1.3.2.3 - Stacking (méta-apprentissage)

Le stacking, ou méta-apprentissage par empilement, est une technique d'ensemble d'ordre supérieur dans laquelle un méta-classifieur apprend à combiner optimalement les prédictions de plusieurs modèles de base. Contrairement au bagging et au boosting, qui combinent des modèles de même nature, le stacking peut agréger des modèles hétérogènes — dans notre cas, un Heterogeneous Graph Transformer (HGT), un classifieur XGBoost tabulaire et un classifieur LightGBM. L'idée centrale est que chaque modèle de base capture des aspects différents du signal prédictif, et que le méta-classifieur peut apprendre à

identifier dans quelles régions de l'espace des caractéristiques chaque base-apprenant est le plus fiable.

Pour éviter le surapprentissage lors de la construction des méta-caractéristiques, une procédure rigoureuse est nécessaire : les prédictions utilisées pour entraîner le méta-classifieur doivent être obtenues sur des exemples que les modèles de base n'ont pas vus pendant leur propre entraînement (prédictions hors-échantillon). Dans notre implémentation, le méta-classifieur XGBoost est alimenté par 21 méta-caractéristiques incluant les probabilités prédites par chaque modèle de base, l'entropie de ces prédictions (mesure de l'incertitude), le niveau d'accord entre les modèles et des résumés compressés des embeddings graphiques. Cette architecture permet au méta-apprenant d'exploiter systématiquement les désaccords entre les têtes graphique et tabulaire pour corriger les prédictions erronées sur les cas difficiles [Bomgni et al., 2025].

1.3.3 - Gestion du déséquilibre de classes (SMOTE, ADASYN)

Un défi méthodologique central dans la modélisation des PFAS est la forte asymétrie de classe caractérisant les jeux de données de surveillance : la majorité des mesures correspondent à des non-détections, les résultats positifs restant minoritaires. Cette configuration est problématique pour les algorithmes d'apprentissage standard, qui tendent à optimiser la performance globale en biaisant leurs prédictions vers la classe majoritaire, au détriment de la détection des cas positifs — précisément ceux qui présentent le plus grand intérêt pratique et sanitaire.

Plusieurs stratégies ont été développées pour pallier ce déséquilibre. La technique SMOTE (Synthetic Minority Over-sampling Technique), proposée par Chawla et al. [2002], génère des exemples synthétiques de la classe minoritaire par interpolation linéaire entre des observations minoritaires existantes et leurs plus proches voisins dans l'espace des caractéristiques. Concrètement, pour chaque exemple minoritaire, SMOTE sélectionne aléatoirement l'un de ses k plus proches voisins ($k = 5$ dans notre implémentation) et crée un nouvel exemple sur le segment reliant les deux points. Cette approche génère des exemples plausibles plutôt que des doublons, ce qui enrichit davantage l'espace d'entraînement de la classe minoritaire.

ADASYN (Adaptive Synthetic Sampling Approach), proposé par He et al. [2008], affine cette stratégie en concentrant la génération synthétique sur les exemples minoritaires les

plus difficiles à classer — ceux situés à proximité de la frontière de décision, où la densité d'exemples majoritaires est la plus élevée. Le nombre d'exemples synthétiques générés pour chaque observation minoritaire est proportionnel à la densité locale de la classe majoritaire. Dong et al. [2024] ont adapté cette approche au contexte multi-étiquette de la prédiction simultanée de 35 analytes PFAS dans les eaux souterraines californiennes.

Dans notre travail, SMOTE est appliqué exclusivement sur le split d'entraînement (`sampling_strategy = 0,5`, `k_neighbors = 5`, `random_state = 42`), ajoutant 386 observations synthétiques au jeu d'entraînement de 9 166 exemples et ramenant le ratio minoritaire/majoritaire de 2,28:1 à 2,00:1. Les splits de validation et de test ne sont jamais rééchantillonnés, ce qui garantit que les métriques rapportées reflètent la distribution naturelle des classes. Une analyse de sensibilité sur différents ratios d'échantillonnage {0,3 ; 0,5 ; 0,7 ; 1,0} a confirmé la robustesse des performances à ce choix ($\Delta F1 < 0,01$ entre les configurations).

I.4 - Généralités sur les graphes et l'apprentissage profond

I.4.1 - Réseaux de neurones sur graphes (GNN)

Les réseaux de neurones sur graphes (Graph Neural Networks, GNN) constituent une famille d'architectures d'apprentissage profond conçues pour opérer directement sur des données structurées sous forme de graphes. Contrairement aux architectures convolutives classiques ou aux réseaux récurrents, qui opèrent sur des données régulièrement structurées (grilles, séquences), les GNN peuvent traiter des données relationnelles irrégulières où les nœuds représentent des entités et les arêtes leurs relations. Cette propriété les rend naturellement adaptés à des domaines tels que la biologie moléculaire, les réseaux sociaux, la chimie computationnelle et, plus récemment, la surveillance environnementale.

Le mécanisme fondamental des GNN est le passage de messages (message passing) : à chaque couche du réseau, chaque nœud agrège les représentations vectorielles de ses voisins pour mettre à jour sa propre représentation. Après plusieurs couches, chaque nœud dispose ainsi d'une représentation enrichie par son contexte local et étendu dans le graphe. Formellement, pour un nœud v à la couche l , la mise à jour s'écrit :

$$h(l+1)_v = \text{UPDATE}(h(l)_v, \text{AGGREGATE}(\{h(l)_u : u \in N(v)\}))$$

où $N(v)$ désigne l'ensemble des voisins de v , et UPDATE et AGGREGATE sont des fonctions paramétriques apprises. Selon le choix de ces fonctions, on obtient différentes architectures de GNN : Graph Convolutional Network (GCN), Graph Attention Network (GAT), GraphSAGE, etc. [Fey et Lenssen, 2019]. La bibliothèque PyTorch Geometric fournit un cadre d'implémentation efficace pour ces architectures à grande échelle.

Dans le contexte de la prédiction des PFAS, Bomgni et al. [2025] ont développé un réseau de graphes hétérogène (HGN) pour la prédiction spatio-chimique de la contamination, encodant à la fois les relations spatiales entre sites de surveillance et les relations chimiques entre composés PFAS au sein d'un graphe unifié. Leurs résultats reportent des réductions substantielles du RMSE par rapport aux GNN homogènes, démontrant l'intérêt de la représentation graphique pour capturer la structure relationnelle de la contamination.

I.4.2 - Graphes hétérogènes

Un graphe homogène standard comporte un seul type de nœud et un seul type d'arête. Or, l'écosystème de surveillance des PFAS est foncièrement hétérogène : il implique des sites de prélèvement, des composés chimiques, des variables environnementales, des installations industrielles, des indicateurs de qualité de l'eau et des regroupements géographiques — autant d'entités de natures radicalement différentes qui entretiennent des relations sémantiquement distinctes. Un graphe hétérogène permet de représenter explicitement cette diversité typologique.

Formellement, un graphe hétérogène $G = (V, E, \tau, \varphi)$ est défini par un ensemble de nœuds V et un ensemble d'arêtes E , associés à une fonction de type de nœud $\tau : V \rightarrow T_V$ et une fonction de type d'arête $\varphi : E \rightarrow T_E$, où $|T_V| + |T_E| > 2$, c'est-à-dire qu'il existe plusieurs types de nœuds ou d'arêtes. Cette structure permet d'encoder des relations sémantiquement distinctes — par exemple, la relation « est situé à proximité de » entre un site d'échantillonnage et une installation industrielle est fondamentalement différente de la relation « présente une co-occurrence avec » entre deux composés PFAS.

Dans notre pipeline, le graphe hétérogène encode le modèle source-voie-récepteur qui constitue le cadre conceptuel de l'évaluation du risque environnemental. Six types de nœuds sont distingués : les nœuds d'échantillons (portant le vecteur de 58 caractéristiques), les nœuds PFAS (propriétés moléculaires), les nœuds environnementaux (descripteurs hydrogéologiques), les nœuds d'installations (indicateurs de proximité), les nœuds de

qualité de l'eau (co-contaminants) et les clusters géographiques. Les arêtes typées relient les échantillons à leurs analytes détectés, à leurs variables environnementales, à leurs installations de proximité et à leur cluster géographique, créant un réseau multi-relationnel au travers duquel l'information se propage selon des voies sémantiquement distinctes.

I.4.3 - Heterogeneous Graph Transformer (HGT)

Le Heterogeneous Graph Transformer (HGT), proposé par Hu et al. [2020] dans le cadre de la Conférence Web 2020, constitue l'une des architectures de référence pour l'apprentissage sur graphes hétérogènes. Son innovation principale réside dans l'introduction d'un mécanisme d'attention multi-tête spécifique au type (type-aware attention), qui permet à chaque type de relation d'apprendre ses propres poids d'attention, transformations linéaires et biais — contrairement aux GNN homogènes qui appliquent les mêmes paramètres à toutes les arêtes.

Plus précisément, pour une arête de type $(\tau(s), \phi(e), \tau(t))$ reliant un nœud source s à un nœud cible t , le mécanisme d'attention de l'HGT calcule :

$$Attention(s, e, t) = softmax(Q(\tau(t)) \cdot K(\tau(s)) / \sqrt{d_k})$$

où Q et K sont des matrices de projection spécifiques aux types de nœuds cible et source respectivement, et d_k est la dimension des vecteurs de clé. Les messages agrégés sont ensuite transformés par une matrice de valeurs spécifique au type de relation, avant d'être sommés et projetés pour mettre à jour la représentation du nœud cible. Ce mécanisme permet au HGT d'apprendre des représentations différenciées selon le contexte relationnel de chaque nœud, ce qui est essentiel lorsque les relations portent des signaux sémantiquement distincts.

Dans notre implémentation sous PyTorch Geometric, l'encodeur HGT est constitué de couches HGTConv empilées produisant un embedding de 64 dimensions pour chaque nœud d'échantillon. L'entraînement minimise l'entropie croisée avec pondération des classes, via l'optimiseur Adam avec dropout et arrêt anticipé basé sur le F1 de validation. L'hyperparamétrage est réalisé automatiquement par Optuna [Akiba et al., 2019]. La convergence de l'entraînement montre que le F1 de validation atteint un plateau proche de 0,92 après environ 150 époques, avec un léger écart par rapport à la courbe de perte d'entraînement suggérant un certain surapprentissage sur la structure graphique — cohérent

avec la performance en test autonome ($F1 = 0,908$) inférieure à celle de XGBoost [Bomgni et al., 2025].

Une précaution méthodologique importante concerne la construction du graphe en mode sans-fuite (leakage-free) : les transformateurs KMeans de clustering géographique et k-NN de similarité entre échantillons sont ajustés exclusivement sur le split d'entraînement, puis appliqués par inférence (predict, kneighbors) aux splits de validation et de test. Cette précaution est l'analogue, au niveau du graphe, de la normalisation ajustée sur l'entraînement uniquement, et garantit qu'aucune information structurelle issue des données de test ne contamine l'apprentissage du graphe.

I.5 - Interprétabilité des modèles

L'interprétabilité des modèles d'apprentissage automatique est un enjeu crucial dans les domaines à fort enjeu décisionnel comme la surveillance environnementale. Un modèle qui prédit efficacement la contamination sans pouvoir expliquer ses prédictions présente une valeur opérationnelle limitée : les régulateurs, les services d'eau potable et les tribunaux exigent des justifications défendables pour les décisions de priorisation. C'est pourquoi l'interprétabilité est aujourd'hui considérée comme une composante à part entière de l'évaluation des modèles dans les sciences environnementales, et non plus comme un simple complément esthétique.

Dans ce travail, l'interprétabilité est assurée principalement par la méthode SHAP (SHapley Additive exPlanations), proposée par Lundberg et Lee [2017]. Cette approche s'appuie sur la théorie des jeux coopératifs et le concept de valeur de Shapley pour attribuer à chaque caractéristique une contribution marginale à la prédiction d'un modèle pour chaque exemple individuel. Formellement, la valeur SHAP ϕ_i d'une caractéristique i pour une prédiction $f(x)$ est définie comme :

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F|-|S|-1)!}{|F|!} \cdot [f(S \cup \{i\}) - f(S)]$$

où F est l'ensemble de toutes les caractéristiques, S est un sous-ensemble de F ne comprenant pas i , et $f(S)$ représente la prédiction du modèle en n'utilisant que les caractéristiques de S . Cette formulation garantit plusieurs propriétés désirables : efficacité (la somme des valeurs SHAP égale la différence entre la prédiction et la valeur de base), symétrie, factice (une caractéristique sans effet reçoit une valeur SHAP nulle) et additivité.

En pratique, le calcul exact des valeurs de Shapley est exponentiel en le nombre de caractéristiques. Lundberg et Lee [2017] ont développé des algorithmes d'approximation efficaces, notamment TreeSHAP pour les modèles basés sur des arbres (XGBoost, LightGBM, Random Forest), qui exploitent la structure arborescente pour calculer les valeurs SHAP exactes en temps polynomial. C'est cette variante que nous utilisons pour l'analyse d'importance des caractéristiques dans notre pipeline.

L'analyse SHAP offre deux niveaux d'interprétation complémentaires. Au niveau global, les graphiques de résumé (summary plots) ordonnent les caractéristiques par importance moyenne (moyenne des valeurs absolues de SHAP sur l'ensemble des exemples du test), permettant d'identifier les variables les plus déterminantes pour le modèle. Au niveau local, les graphiques de force (force plots) visualisent pour un exemple individuel les contributions positives (poussant vers la classe contaminée) et négatives (poussant vers la classe non contaminée) de chaque caractéristique, facilitant l'explication de décisions spécifiques aux parties prenantes [Lundberg et Lee, 2017].

Dans notre travail, l'analyse SHAP révèle une dualité fondamentale dans la manière dont le modèle de fusion intègre l'information. D'un côté, le premier composant de l'embedding graphique (HGT_emb_0) se révèle être la caractéristique individuelle la plus importante, surpassant toute caractéristique tabulaire prise isolément. De l'autre, l'ensemble des 58 caractéristiques tabulaires domine collectivement l'importance totale (70 à 80 % de la masse SHAP), les embeddings graphiques n'en contribuant que 20 à 30 %. Cette dualité reflète deux couches d'information complémentaires : la couche de mesure (observations directes, dominante lorsqu'elles sont disponibles) et la couche contextuelle (structure relationnelle inférée du réseau de surveillance, d'autant plus importante que les mesures sont incomplètes) [Bomgni et al., 2025].

En complément de SHAP, les graphiques de dépendance (dependence plots) permettent de visualiser la relation non linéaire entre la valeur d'une caractéristique et son impact sur la prédiction. Dans notre analyse, ces graphiques confirment que les modèles arborescents apprennent un comportement à seuil : l'impact de la concentration en PFOS ou PFOA sur la prédiction augmente brusquement dès que la concentration dépasse le seuil de détection, ce qui est cohérent avec la définition binaire de la contamination adoptée dans cette étude.

I.6 - Synthèse

Ce premier chapitre a posé les bases conceptuelles et théoriques nécessaires à la compréhension des enjeux et des méthodes développés dans ce mémoire. Nous avons d'abord caractérisé les PFAS comme une classe de contaminants persistants d'une exceptionnelle stabilité chimique, dont la présence ubiquitaire dans les eaux souterraines résulte de décennies d'utilisation industrielle et militaire. Leur impact sanitaire documenté — immunotoxicité, perturbation endocrinienne, effets carcinogènes — combiné à un cadre réglementaire en rapide renforcement crée un besoin urgent d'outils de priorisation efficaces et économiquement viables.

Nous avons ensuite présenté les paradigmes de l'apprentissage automatique mobilisés dans ce travail. Les méthodes d'ensemble — gradient boosting (XGBoost, LightGBM), forêts aléatoires et stacking — se distinguent par leurs performances sur les données tabulaires environnementales, leur robustesse au bruit et leur adaptabilité aux contextes déséquilibrés. Les stratégies SMOTE et ADASYN permettent de pallier le déséquilibre de classes inhérent aux jeux de données de surveillance, où les détections positives constituent la classe minoritaire d'intérêt.

L'introduction des graphes hétérogènes et, en particulier, du Heterogeneous Graph Transformer (HGT), apporte une dimension nouvelle à la modélisation de la contamination : elle permet d'encoder explicitement les relations entre sites d'échantillonnage, composés PFAS, variables environnementales, installations industrielles et clusters géographiques au sein d'un réseau multi-relationnel. Ce formalisme traduit fidèlement le modèle source-voie-récepteur qui gouverne conceptuellement l'évaluation du risque environnemental.

Enfin, l'interprétabilité par la méthode SHAP permet de transformer des prédictions algorithmiques potentiellement opaques en décisions environnementales défendables, ancrées dans des mécanismes physiques et chimiques reconnus. Cette dimension est indispensable pour que les outils d'aide à la décision développés dans ce travail puissent être effectivement adoptés par les régulateurs et les services d'eau potable.

La tension fondamentale que ce chapitre a mise en lumière — entre la richesse du signal fourni par les mesures chimiques directes et l'accessibilité des données contextuelles

disponibles avant tout échantillonnage — sera au cœur du chapitre suivant, consacré à l'état de l'art et aux travaux antérieurs sur la prédiction des PFAS par apprentissage automatique.

Références bibliographiques du chapitre

- [Akiba et al., 2019] AKIBA T., SANO S., YANASE T., OHTA T. et KOYAMA M. (2019). Optuna : A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 2623–2631.
- [Bomgni et al., 2025] BOMGNI A. B., DNJOMOU YONMBA W. L., TENE CESKOUTSE R. F., KLEIN N., GADHAMSHETTY V. et GNIMPIEBA E. Z. (2025). Graph-Enhanced Machine Learning for PFAS Groundwater Prioritization. *Environmental Engineering Science*.
- [Borisov et al., 2024] BORISOV V., LEEMANN T., SESSLER K. et al. (2024). Deep neural networks and tabular data : A survey. *IEEE Transactions on Neural Networks and Learning Systems*.
- [Breiman, 2001] BREIMAN L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- [Brusseau et al., 2019] BRUSSEAU M. L., YAN N., VAN GLUBT S. et al. (2019). Comprehensive retention model for PFAS transport in subsurface systems. *Water Research*, 148:41–50.
- [Chawla et al., 2002] CHAWLA N. V., BOWYER K. W., HALL L. O. et KEGELMEYER W. P. (2002). SMOTE : Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- [Chen et Guestrin, 2016] CHEN T. et GUESTRIN C. (2016). XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.
- [D'Ambro et al., 2021] D'AMBRO E. L., PYE H. O. T., BASH J. O. et al. (2021). Characterizing the air emissions, transport, and deposition of per- and polyfluoroalkyl substances from a fluoropolymer manufacturing facility. *Environmental Science & Technology*, 55(2):862–870.
- [Dong et al., 2024] DONG J., TSAI G. et OLIVARES C. I. (2024). Prediction of 35 target per- and polyfluoroalkyl substances (PFASs) in California groundwater using multilabel semisupervised machine learning. *ACS EST Water*, 4:969–981.
- [Fey et Lenssen, 2019] FEY M. et LENSSEN J. E. (2019). Fast graph representation learning with PyTorch Geometric. *arXiv preprint arXiv:1903.02428*.
- [Friedman, 2001] FRIEDMAN J. H. (2001). Greedy function approximation : A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232.
- [George et Dixit, 2021] GEORGE S. et DIXIT A. (2021). A machine learning approach for prioritizing groundwater testing for per- and polyfluoroalkyl substances (PFAS). *Journal of Environmental Management*, 295:113359.
- [Guelfo et al., 2021] GUELFO J. L., KORZENIOWSKI S., MILLS M. A. et al. (2021). Environmental sources, chemistry, fate, and transport of per- and polyfluoroalkyl substances : State of the science. *Environmental Toxicology and Chemistry*, 40(12):3234–3260.
- [He et al., 2008] HE H., BAI Y., GARCIA E. A. et LI S. (2008). ADASYN : Adaptive synthetic sampling approach for imbalanced learning. In *2008 IEEE International Joint Conference on Neural Networks*, pp. 1322–1328.

- [Hu et al., 2016] HU X. C., ANDREWS D. Q., LINDSTROM A. B. et al. (2016). Detection of poly- and perfluoroalkyl substances (PFASs) in U.S. drinking water linked to industrial sites, military fire training areas, and wastewater treatment plants. *Environmental Science & Technology Letters*, 3(10):344–350.
- [Hu et al., 2020] HU Z., DONG Y., WANG K. et SUN Y. (2020). Heterogeneous graph transformer. In *Proceedings of The Web Conference 2020*, pp. 2704–2710.
- [Ke et al., 2017] KE G., MENG Q., FINLEY T., WANG T., CHEN W., MA W., YE Q. et LIU T.-Y. (2017). LightGBM : A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, pp. 3146–3154.
- [Kibbey et al., 2020] KIBBEY T. C. G., JABRZEMSKI R. et O'CARROLL D. M. (2020). Supervised machine learning for source allocation of per- and polyfluoroalkyl substances (PFAS) in environmental samples. *Chemosphere*, 252:126593.
- [Li et MacDonald Gibson, 2022] LI R. et MACDONALD GIBSON J. (2022). Predicting the occurrence of short-chain PFAS in groundwater using machine-learned Bayesian networks. *Frontiers in Environmental Science*, 10:958784.
- [Lundberg et Lee, 2017] LUNDBERG S. M. et LEE S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*.
- [Mitchell, 1997] MITCHELL T. (1997). *Machine Learning*. McGraw-Hill.
- [Pedregosa et al., 2011] PEDREGOSA F., VAROQUAUX G., GRAMFORT A. et al. (2011). Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- [Prevedouros et al., 2006] PREVEDOUROS K., COUSINS I. T., BUCK R. C. et KORZENIOWSKI S. H. (2006). Sources, fate and transport of perfluorocarboxylates. *Environmental Science & Technology*, 40(1):32–44.
- [Sunderland et al., 2019] SUNDERLAND E. M., HU X. C., DASSUNCAO C. et al. (2019). A review of the pathways of human exposure to poly- and perfluoroalkyl substances (PFASs) and present understanding of health effects. *Journal of Exposure Science and Environmental Epidemiology*, 29:131–147.
- [U.S. EPA, 2023] U.S. ENVIRONMENTAL PROTECTION AGENCY (2023). PFAS National Primary Drinking Water Regulation. Consulté le 29 mars 2026.
- [Weber et al., 2017] WEBER A. K., BARBER L. B., LEBLANC D. R., SUNDERLAND E. M. et VECITIS C. D. (2017). Geochemical and hydrologic factors controlling subsurface transport of poly- and perfluoroalkyl substances, Cape Cod, Massachusetts. *Environmental Science & Technology*, 51(8):4269–4279.