

**RÉPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON**

**PAIX - TRAVAIL - PATRIE
PEACE - WORK - FATHERLAND**

**UNIVERSITÉ DE DSCHANG
UNIVERSITY OF DSCHANG**

ÉCOLE DES SCIENCES ET TECHNOLOGIES DE DSCHANG

**UNITÉ DE RECHERCHE EN INFORMATIQUE
FONDAMENTALE,
INGÉNIERIE ET APPLICATION (URIFIA)**

THÈME :

**Prédiction par intelligence artificielle des contaminants émergents des
eaux :**

étude de cas sur la détection des PFAS et l'évaluation des risques

Mémoire présenté en vue de l'obtention du diplôme de
Master en Informatique

Option : **Informatique Fondamentale**
Spécialisation : **Intelligence Artificielle**

Par

DNJOMOU YONMBA Wilfried Loïc

Matricule : CM-UDS-24SCI0999

Licence de technologie en conception, développement, réseaux et Internet

Sous la direction de :

Pr BOMGNI Alain Bertrand
Professeur Titulaire, Université de Dschang

Année académique 2025/2026

CERTIFICATION

Je soussigné, **DNJOMOU YONMBA Wilfried Loïc**, étudiant en Master, option Intelligence Artificielle, au Département de Mathématiques et Informatique, matricule **CM-UDS-24SCI0999**, Faculté des Sciences, Université de Dschang, certifie que les présents travaux de recherche intitulés « Prédiction par intelligence artificielle des contaminants émergents des eaux : étude de cas sur la détection des PFAS et l'évaluation des risques », réalisés au sein de l'Unité de Recherche URIFIA de l'Université de Dschang, sous la direction de **Pr BOMGNI Alain Bertrand**, Professeur Titulaire, Université de Dschang, sont le fruit de mes propres travaux de recherche.

Cela n'a jamais été publié auparavant pour l'obtention d'un diplôme.

L'étudiant

Le superviseur

**DNJOMOU YONMBA Wilfried
Loïc**

Date : _____

Pr BOMGNI Alain Bertrand

Date : _____

DÉDICACE

À mon père YONMBA RICHARD et à ma mère DJEUMEN LUCIE CLAIRE.

REMERCIEMENTS

Alors...

- Au Dr...;
- À...;

TABLE DES MATIÈRES

Dédicace	ii
Remerciements	iii
Table des matières	iv
List of Symbols	vii
List of Acronyms	ix
List of Tables	xi
List of Figures	xii
Résumé	xiii
Abstract	xv
Introduction	1
Le contexte du travail	1
Les documents structurés	1
L'édition coopérative des documents structurés	1
La problématique étudiée	1
<i>Chapter I ► Généralités</i>	2
I.1 - Introduction	2
I.2 - Substances per- et polyfluoroalkylées (PFAS)	3
I.2.1 - Définition et propriétés physicochimiques	3
I.2.1.1 - Une famille chimique vaste et hétérogène	3
I.2.1.2 - La liaison carbone–fluor et la persistance	3
I.2.1.3 - Groupes fonctionnels, tensioactivité et rétention dans les sols	4
I.2.2 - Usages, sources et devenir environnemental	5
I.2.2.1 - Usages industriels	5
I.2.2.2 - Typologie des sources de contamination	6
I.2.2.3 - Mécanismes de transport dans l'air, le sol et l'eau	6
I.2.2.4 - Le schéma source, voie et récepteur	7
I.2.3 - Surveillance des eaux souterraines et limites de la mesure	7
I.2.4 - Impacts sanitaires et cadre réglementaire	9

I.2.4.1 - Voies d'exposition et effets documentés	9
I.2.4.2 - Évolution du cadre réglementaire	10
I.3 - Apprentissage automatique et méthodes d'ensemble	11
I.3.1 - Paradigmes de l'apprentissage automatique	12
I.3.1.1 - Apprentissage supervisé	12
I.3.1.2 - Apprentissage non supervisé	12
I.3.1.3 - Apprentissage semi-supervisé	13
I.3.1.4 - Apprentissage par renforcement	13
I.3.2 - Méthodes d'ensemble	13
I.3.2.1 - Bagging	14
I.3.2.2 - Boosting	15
I.3.2.3 - Stacking	17
I.4 - Graphes et réseaux de neurones sur graphes	19
I.4.1 - Représentation des données par graphe	19
I.4.2 - Réseaux de neurones sur graphes	20
I.4.3 - Graphes hétérogènes	22
I.4.4 - Heterogeneous Graph Transformer (HGT)	23
I.5 - Interprétabilité des modèles	24
I.5.1 - Enjeux et interprétabilité a posteriori	24
I.5.2 - Valeurs de Shapley et décomposition additive	25
I.5.3 - Analyses globale et locale	26
I.5.4 - Limites et recul épistémologique	27
I.6 - Synthèse	27
Chapter II ► État de l'art	29
II.1 - Introduction	29
II.2 - Cadre conceptuel de la revue	30
II.2.1 - Formalisation du problème de prédiction PFAS par apprentis- sage automatique	30
II.2.2 - Mécanismes de transport des PFAS et pertinence des variables contextuelles	31
II.2.3 - Métriques d'évaluation des classifieurs de contamination PFAS	33
II.2.4 - Déséquilibre de classes et rééchantillonnage synthétique . . .	35
II.2.5 - Mode prédictif et mode confirmatoire	36
II.3 - Modèles tabulaires pour la prédiction des PFAS	37
II.3.1 - Approches probabilistes et cartographie précoce de la vulnérabilité	37

II.3.1.1 - Travaux de Li et MacDonald Gibson (2022)	37
II.3.1.2 - Travaux de McMahon et al. (2022)	38
II.3.1.3 - Travaux de Hu et al. (2021)	39
II.3.2 - Méthodes d'ensemble pour la priorisation des puits	39
II.3.2.1 - Travaux de George et Dixit (2021)	40
II.3.2.2 - Travaux de Tokranov et al. (2024)	40
II.3.3 - Attribution des sources : une tâche diagnostique en aval de l'analyse	41
II.3.3.1 - Travaux de Kibbey et al. (2020)	42
II.3.3.2 - Travaux de Dávila-Santiago et al. (2022)	42
II.4 - Architectures profondes et relationnelles	43
II.4.1 - Réseaux de neurones sur données tabulaires et applications moléculaires	43
II.4.1.1 - Travaux de Borisov et al. (2024)	43
II.4.1.2 - Travaux de Cheng et Ng (2019)	44
II.4.2 - Apprentissage semi-supervisé multi-étiquettes : les travaux de Dong et al. (2024)	45
II.5 - Discussion	47
II.5.1 - Tableau comparatif synthétique	47
II.5.2 - Lecture transversale : convergences et enseignements	48
II.5.3 - Lacunes structurelles identifiées	49
II.6 - Synthèse	50
Chapter III ► Fusion consensuelle des mises à jour des répliques partielles	52
Conclusion générale	53
La problématique étudiée et les choix méthodologiques	53
Analyse critique des résultats obtenus	53
Quelques perspectives	53
Bibliography	54
Appendix A ► Un autre exemple complet de fusion consensuelle	59
Appendix B ► Quelques fonctions Haskell pour le calcul des consensus	60

LIST OF SYMBOLS

$\mathbb{G}$	A grammatical model of workflow;
t_{if}	A global artefact obtained after merging a set of artefacts.

LIST OF ACRONYMS

PFAS	Substances per- et polyfluoroalkylées ;
EPA	Environmental Protection Agency (États-Unis) ;
PFOA	Acide perfluorooctanoïque ;
PFOS	Sulfonate de perfluorooctane ;
PFOA	Acides perfluorocarboxyliques ;
PFSA	Acides perfluoroalkylsulfoniques ;
AFFF	Mousse anti-incendie à film aqueux ;
GNN	Graph Neural Network ;
HGT	Heterogeneous Graph Transformer ;
PyG	PyTorch Geometric ;
GCN	Graph Convolutional Network ;
SMOTE	Synthetic Minority Over-sampling Technique ;
ADASYN	Adaptive Synthetic Sampling ;
SHAP	SHapley Additive exPlanations ;
ROC-AUC	Aire sous la courbe ROC ;
PR-AUC	Aire sous la courbe précision-rappel ;
MCC	Coefficient de corrélation de Matthews ;
ML	Apprentissage automatique (<i>Machine Learning</i>) ;
RF	Forêt aléatoire (<i>Random Forest</i>) ;
XGBoost	<i>Extreme Gradient Boosting</i> ;
LightGBM	<i>Light Gradient Boosting Machine</i> ;
DAG	Graphe orienté acyclique (<i>Directed Acyclic Graph</i>) ;
BRT	Arbres de régression boostés (<i>Boosted Regression Trees</i>) ;
CC	Chaînes de classifieurs (<i>Classifier Chains</i>) ;
MLP	Perceptron multicouche (<i>Multilayer Perceptron</i>) ;
DNN	Réseau de neurones profond (<i>Deep Neural Network</i>) ;
MNN	Réseau de neurones multitâche (<i>Multitask Neural Network</i>) ;
SVM	Machine à vecteurs de support (<i>Support Vector Machine</i>) ;
SVD	Décomposition en valeurs singulières (<i>Singular Value Decomposition</i>) ;
LC-MS/MS	Chromatographie liquide couplée à la spectrométrie de masse tandem ;
HRMS	Spectrométrie de masse haute résolution ;
NTS	Criblage non ciblé (<i>Non-Target Screening</i>) ;
COD	Carbone organique dissous ;
TDS	Solides dissous totaux (<i>Total Dissolved Solids</i>) ;
LD	Limite de détection ;
BIC	Critère d'information bayésien (<i>Bayesian Information Criterion</i>) ;
GAMA	Groundwater Ambient Monitoring and Assessment ;
USGS	<i>United States Geological Survey</i> ;
NOAA	<i>National Oceanic and Atmospheric Administration</i> ;

LIST OF TABLES

I - Principales classes de PFAS et propriétés associées (synthèse pédagogique).	4
II - Exemples d'effets sanitaires associés à l'exposition aux PFAS (synthèse).	10
III - Synthèse des trois familles d'ensembles et d'un exemple représentatif pour chacune.	19
IV - Matrice de confusion pour une classification binaire (classe positive = site contaminé).	33
V - Performances du groupe tabulaire sur la prédiction/priorisation des PFAS. Les métriques proviennent des articles sources ; les protocoles diffèrent entre études. * : présence probable de concentrations PFAS mesurées parmi les features (composante confirmatoire partielle, cf. section II.2.5). n.r. : non renseigné (métrique non rapportée par les auteurs). Synthèse complète : voir Tab. VI.	41
VI - Synthèse comparative des approches de prédiction PFAS examinées. Les métriques proviennent des articles sources ; protocoles et corpus diffèrent entre études. * : présence de concentrations PFAS ou de signatures chimiques mesurées dans les features.	48
VII - Positionnement des principales contributions au regard des cinq lacunes identifiées. ● : lacune adressée ; ○ : partiellement adressée ; × : non adressée. L1 : structure relationnelle ; L2 : biais confirmatoire ; L3 : transfert géographique ; L4 : interprétabilité standardisée.	50
VIII - Les schémas des règles de transition pour notre exemple	59

LIST OF FIGURES

1 - Représentation schématique du PFOS (acide perfluorooctanesulfonique, $\text{C}_8\text{F}_{17}\text{SO}_3\text{H}$ ou $\text{C}_8\text{F}_{17}\text{SO}_3^-$). Source : adapté de [1].	5
2 - Voies possibles de contamination humaine aux PFAS (sources directes en rouge, contamination indirecte via sol ou eau en bleu, voies d'exposition en violet). Source : adapté de [2].	8
3 - Pathologies suspectées d'être induites par la toxicité des PFAS (effets épidémiologiques corroborés au centre ; autres effets documentés en gris ; effets reprotoxiques sur les côtés). Source : adapté de [2].	10
4 - Schéma d'une forêt aléatoire (bagging d'arbres de décision avec sous-échantillonnage des observations et des variables). Source : adapté de [3].	15
5 - Principe du boosting : ajout séquentiel d'arbres pour corriger les erreurs du modèle courant. Source : illustration pédagogique adaptée de [4]. .	16
6 - Principe du stacking : plusieurs modèles de base alimentent un méta-classifieur.	18
7 - Message passing : agrégation des représentations des voisins $\mathcal{N}(v)$ vers le nœud v	21
8 - Architecture du Heterogeneous Graph Transformer (HGT) : attention typée par méta-relation pour la propagation de l'information dans un graphe hétérogène. Source : adapté de [5].	23
9 - Pipeline bi-tâche de Dong et al. [6]. La tâche 1 (criblage total) repose sur une forêt aléatoire avec sur-échantillonnage ADASYN ; la tâche 2 (prédiction des 35 analytes) enchaîne un pseudo-étiquetage semi-supervisé et une chaîne de classifieurs XGBoost. Les 112 variables contextuelles constituent l'unique entrée, sans aucune concentration PFAS mesurée.	47

RÉSUMÉ

Le travail réalisé dans ce mémoire...

Mots clés: Documents structurés, Workflow d'édition Coopérative, Fusion des répliques partielles, Conflits, Consensus, Automates d'arbre, Produit d'automates, Évaluation paresseuse, TinyCE v2.

AI-POWERED PREDICTION OF EMERGING WATER CONTAMINANTS: A CASE STUDY IN PFAS DETECTION AND RISK ASSESSMENT

ABSTRACT

The work presented ...

Keywords: Structured documents, Workflow of cooperative edition, Merging partial replicas, Conflict, Consensus, Tree automata, Automata product, Lazy evaluation, TinyCE v2.

INTRODUCTION

CONTENTS

Le contexte du travail	1
La problématique étudiée	1

Le contexte du travail

La coopération et la collaboration ...

Les documents structurés

gjfjh...

L'édition coopérative des documents structurés

Le processus [7] consiste...

La problématique étudiée

Pendant la...

I

CHAPTER

GÉNÉRALITÉS SUR LES PFAS ET L'INTELLIGENCE ARTIFICIELLE

SOMMAIRE

I.1 - Introduction	2
I.2 - Substances per- et polyfluoroalkylées (PFAS)	3
I.3 - Apprentissage automatique et méthodes d'ensemble	11
I.4 - Graphes et réseaux de neurones sur graphes	19
I.5 - Interprétabilité des modèles	24
I.6 - Synthèse	27

I.1. Introduction

La surveillance de la qualité des eaux souterraines est confrontée à l'émergence de contaminants persistants, parmi lesquels les substances per- et polyfluoroalkylées (PFAS) occupent une place particulière par leur stabilité chimique, leur mobilité et la diversité de leurs usages. Dans le même temps, le développement de l'**intelligence artificielle** et de l'**apprentissage automatique** (*machine learning*, ML) fournit des outils puissants pour analyser des volumes importants de données environnementales, combiner des sources d'information hétérogènes et appuyer la prise de décision. Ce premier chapitre a pour objectif de réunir les **notions fondamentales** qui seront mobilisées dans la suite du mémoire. Nous y présentons d'abord le contexte des PFAS : définition, propriétés physicochimiques, principaux usages, sources de contamination, devenir environnemental, enjeux de surveillance des eaux souterraines et cadre réglementaire (section I.2). Nous introduisons ensuite les paradigmes de l'apprentissage automatique, le bagging, le boosting et le stacking (section I.3), puis les **graphes** et les réseaux de neurones sur graphes, en

particulier les graphes hétérogènes et le Transformeur de Graphe hétérogènes (section I.4). Enfin, nous présentons les principaux outils d'**interprétabilité** des modèles, avec un accent sur l'approche SHAP (section I.5), afin de préparer l'analyse des résultats qui sera menée dans les chapitres suivants.

I.2. Substances per- et polyfluoroalkylées (PFAS)

Les PFAS occupent une place à part parmi les contaminants de l'eau : leur persistance, leur mobilité et le nombre très élevé de composés potentiels compliquent la surveillance classique. Cette section en présente la **définition**, les **propriétés physicochimiques**, les **usages** à l'origine des rejets, le **devenir** dans l'environnement (sources et transport), les enjeux de **surveillance des eaux souterraines**, puis les **risques sanitaires** et le **cadre réglementaire**.

I.2.1. Définition et propriétés physicochimiques

I.2.1.1. Une famille chimique vaste et hétérogène

Les **substances per- et polyfluoroalkylées** (PFAS, *per- and polyfluoroalkyl substances*) désignent une famille de composés organiques de synthèse dont le nombre exact dépasse largement quelques centaines de molécules : les inventaires réglementaires et scientifiques recensent de l'ordre de **4 000 à plus de 10 000** structures selon les critères d'inclusion retenus [8]. Toutes partagent l'idée d'une chaîne carbonée aliphatique dont une partie des atomes d'hydrogène est remplacée par du **fluor**.

Historiquement, une définition de référence exigeait la présence d'un groupement **perfluoroalkylé** saturé en fluor. L'Organisation de coopération et de développement économiques (OCDE) a ensuite élargi le champ à toute substance contenant au moins un groupement méthylène ou méthyle **entièrement fluoré**, afin d'intégrer des molécules utilisées dans des filières récentes (semi-conducteurs, batteries, matériaux haute performance). Le terme **PFAS** fonctionne ainsi comme un **parapluie réglementaire et analytique**, et non comme le nom d'un produit unique.

I.2.1.2. La liaison carbone–fluor et la persistance

La liaison **carbone–fluor** (C–F) est l'une des plus fortes de la chimie organique (de l'ordre de 485 kJ/mol). Elle confère aux molécules une inertie remarquable face à la chaleur, aux oxydants et aux enzymes microbiennes. C'est ce qui justifie le surnom de *polluants éternels* : contrairement à de nombreux hydrocarbures, les

PFAS ne sont pas facilement **biodégradés** dans les conditions naturelles [9]. Leur présence dans les sols, les eaux et certains biotes peut donc se prolonger **décennies** après l'arrêt des émissions à la source.

On oppose en pratique :

- les composés **perfluoroalkylés** : la chaîne est saturée en fluor (hors groupe fonctionnel) ;
- les composés **polyfluoroalkylés** : la fluorination est partielle ; ils peuvent se transformer en dérivés plus persistants, appelés **précurseurs**.

Les composés historiques à **chaîne longue** (souvent $\geq 6-8$ atomes de carbone pour les PFCA) comme le PFOA ou le PFOS ont été massivement produits à partir des années 1950. Sous pression réglementaire, l'industrie s'est orientée vers des **chaînes courtes** (C4–C6), présentées comme des alternatives ; celles-ci restent toutefois mobiles et persistantes dans l'environnement.

1.2.1.3. Groupes fonctionnels, tensioactivité et rétention dans les sols

Selon le **groupe fonctionnel** terminal, on classe notamment :

- les **acides perfluorocarboxyliques** (PFCA), par exemple l'acide perfluorooctanoïque (PFOA) ;
- les **acides perfluoroalkylsulfoniques** (PFSA), par exemple le sulfonate de perfluorooctane (PFOS).

Le tableau I illustre d'autres familles courantes.

Table I – Principales classes de PFAS et propriétés associées (synthèse pédagogique).

Classe	Groupe	Exemple	Propriété dominante
PFCA	Carboxylate	PFOA (C8)	Persistance, adsorption, bioaccumulation
PFSA	Sulfonate	PFOS (C8)	Tensioactivité, bioaccumulation, stabilité
Fluorotélomères	Alcools, sulfonates	6:2 FTS	Précurseur de PFCA
PFPE	Éther perfluoré	Lubrifiants	Résistance thermique

Les PFAS sont **amphiphiles** : une chaîne fluorée hydrophobe et lipophobe est reliée à une tête polaire hydrophile. Cette structure explique leur efficacité comme **tensioactifs** (réduction de la tension superficielle), notamment dans les mousses anti-incendie, et leur tendance à s'accumuler aux **interfaces** air-eau et solide-eau en zone non saturée [10].

La figure 1 illustre la structure d'un PFAS non polymérique, le sulfonate de perfluorooctane (PFOS).




Figure 1 – Représentation schématique du PFOS (acide perfluorooctanesulfonique, $C_8F_{17}SO_3H$ ou $C_8F_{17}SO_3^-$). Source : adapté de [1].

La structure illustrée met en évidence la dualité de la chaîne perfluorée (queue) et du groupe sulfonate (tête polaire), qui fonde à la fois la persistance et la tensioactivité du composé.

La **longueur de chaîne** modifie la solubilité, la mobilité et la bioaccumulation : les chaînes courtes se déplacent plus facilement dans l'eau ; les chaînes longues sont davantage retenues par les matières organiques du sol et les protéines.

1.2.2. Usages, sources et devenir environnemental

La présence des PFAS dans l'environnement découle d'une chaîne causale continue : des choix industriels engendrent des rejets, qui alimentent des sources de contamination, lesquelles propagent les composés vers les milieux récepteurs selon des mécanismes physiques bien documentés. Cette sous-section détaille successivement les usages à l'origine des émissions, la nature des sources, les voies de dispersion, et le modèle conceptuel source-voie-récepteur qui en synthétise la logique.

1.2.2.1. Usages industriels

Les PFAS ne sont pas des polluants accidentels ponctuels : ils résultent de **choix industriels** répétés sur plus de soixante ans. Leur combinaison de répellence (eau, graisses), de stabilité thermique et de faible friction a conduit à de nombreuses applications [8] :

- **Textiles et habillement** : imperméabilité, résistance aux taches ;

- **Emballages alimentaires** et papier traité : barrière à l'huile et à l'eau ;
- **Mousses anti-incendie** pour feux d'hydrocarbures (films aqueux AFFF) ;
- **Industrie chimique et électronique** : fluides de procédé, lubrifiants, revêtements ;
- **Cosmétiques et produits d'entretien** : certains composés sont aujourd'hui progressivement interdits ou restreints selon les juridictions.

À chaque **cycle de vie** (fabrication, utilisation, traitement des déchets), une fraction des PFAS peut être rejetée dans l'air, l'eau ou les sols. Les procédés de traitement classiques des eaux usées ou des lixiviats de décharges ne sont généralement pas conçus pour **casser** la liaison C–F : une partie des composés traverse les stations et retourne vers les milieux naturels [11, 9].

I.2.2.2. Typologie des sources de contamination

On classe couramment les sources selon leur intensité et leur localisation :

1. **Sources ponctuelles industrielles** : usines de synthèse ou de transformation de produits fluorés, rejets historiques stockés dans les sols ;
2. **Sites militaires et aéroportuaires** : entraînements au feu avec mousses AFFF, souvent identifiés comme **hotspots** de contamination des nappes ;
3. **Sources diffuses** : stations d'épuration, sites d'enfouissement, ruissellement urbain transportant des résidus de produits de consommation.

Des études à l'échelle régionale ont montré une association statistique entre la présence de PFAS dans l'eau potable et la proximité d'installations industrielles, de bases militaires ou de stations d'épuration [11]. La mousse **AFFF** mérite une attention particulière : développée pour éteindre les feux de carburant, elle a été déployée à grande échelle sur les aérodromes et casernes ; les mélanges infiltrés dans le sol peuvent alimenter des panaches souterrains durables.

I.2.2.3. Mécanismes de transport dans l'air, le sol et l'eau

Une fois rejetés, les PFAS suivent des trajectoires **couplées** :

- **Eaux souterraines** : transport principalement **advectif** avec le flux de la nappe ; la vitesse dépend de la conductivité hydraulique, de la porosité, du gradient hydraulique et du degré de rétention sur les sols (matière organique, minéraux) [10].

- **Zone vadose** (non saturée) : accumulation possible aux interfaces air–eau, formant un **réservoir** libéré progressivement lors des pluies ;
- **Atmosphère** : certains précurseurs volatils (fluorotélomères) peuvent être transportés sur de longues distances avant dépôt sec ou humide, contribuant à une contamination **ubiquitaire** même loin des sites industriels [12].

Sur des aquifères perméables à faible teneur en carbone, des panaches de plusieurs **kilomètres** ont été décrits en aval de sources ponctuelles. Le comportement ne se réduit donc pas à une dilution immédiate : la persistance et la mobilité conjointes expliquent l'étendue spatiale des problèmes.

1.2.2.4. Le schéma source, voie et récepteur

En évaluation des risques environnementaux, le devenir des PFAS est souvent représenté par le modèle **source, voie et récepteur** [10, 12] :

- **Source** : activité humaine qui émet les PFAS (usine, base militaire, rejet urbain) ;
- **Voie** : milieu qui transporte le polluant (sol, eau souterraine, eau de surface, air) ;
- **Récepteur** : milieu ou organisme exposé (nappe exploitée, puits, rivière, population).

Ce schéma aide à structurer la pensée, indépendamment des outils mathématiques utilisés ensuite pour l'analyse des données. La figure 2 en illustre la déclinaison concrète pour les PFAS.

La figure met en évidence que les rejets industriels ou l'usage de produits de consommation alimentent d'abord les milieux (sol, eau), avant d'atteindre l'homme par l'eau potable, l'alimentation ou d'autres voies d'exposition. On observe par ailleurs une **co-occurrence** fréquente avec d'autres polluants organiques sur les mêmes sites : solvants chlorés (TCE, PCE), hydrocarbures, additifs (MTBE). Ces co-contaminants partagent souvent une histoire industrielle commune, même si leurs propriétés de transport diffèrent.

1.2.3. Surveillance des eaux souterraines et limites de la mesure

Les **eaux souterraines** constituent un enjeu majeur car elles alimentent une part importante de l'eau potable et de l'irrigation. Les PFAS y sont d'autant plus préoccupants qu'ils peuvent migrer **loin** de la source visible et demeurer longtemps à des concentrations très faibles mais significatives sur le plan sanitaire [11].




Figure 2 – Voies possibles de contamination humaine aux PFAS (sources directes en rouge, contamination indirecte via sol ou eau en bleu, voies d'exposition en violet). Source : adapté de [2].

La **surveillance** repose classiquement sur :

- le prélèvement sur des **puits** ou points de contrôle ;
- l'analyse en laboratoire par chromatographie de type LC-MS/MS, ciblant un **panier** de composés (souvent quelques dizaines de molécules parmi des milliers possibles) ;
- la comparaison aux **seuils réglementaires** ou aux valeurs guides sanitaires.

Plusieurs limites structurelles expliquent la difficulté d'un suivi exhaustif :

- **Coût** élevé d'une analyse multi-composés ;
- **Couverture spatiale** incomplète (impossible de mesurer tous les puits d'une région) ;
- **Non-détection** fréquente : une valeur nulle ne signifie pas toujours l'absence de PFAS, mais parfois une concentration sous le seuil de détection de la méthode [12] ;
- **Hétérogénéité** des protocoles entre régions et campagnes.

Ces contraintes expliquent l'intérêt, dans la littérature récente, pour des approches de **priorisation** fondées sur des données déjà disponibles (contexte géologique, proximité d'activités, qualité de l'eau) [6].

I.2.4. Impacts sanitaires et cadre réglementaire

I.2.4.1. Voies d'exposition et effets documentés

L'exposition humaine aux PFAS peut intervenir par plusieurs **voies** [13] :

- **Eau potable** contaminée (voie souvent dominante près des sites pollués) ;
- **Alimentation** (poissons d'eau douce, produits d'origine animale bioaccumulants) ;
- **Poussières intérieures** et produits de consommation traités ;
- **Contact professionnel** sur les sites de production ou d'usage intensif.

Les effets sanitaires étudiés à des doses environnementales très basses (ng/L dans l'eau) incluent notamment :

- des effets sur le **système immunitaire** (réponse vaccinale);
- des perturbations **thyroïdiennes** et métaboliques (lipides);
- des impacts sur le **développement fœtal** (poids à la naissance, prééclampsie);
- pour certains composés, des associations avec des **cancers** (rein, testicules) dans les cohortes les plus exposées.

La figure 3 synthétise les pathologies suspectées d'être liées à la toxicité des PFAS chez l'humain.




Figure 3 – Pathologies suspectées d’être induites par la toxicité des PFAS (effets épidémiologiques corroborés au centre ; autres effets documentés en gris ; effets reprotoxiques sur les côtés). Source : adapté de [2].

Cette synthèse illustre que plusieurs organes et fonctions (immunité, thyroïde, développement fœtal, reproduction) figurent parmi les effets les plus documentés, justifiant le renforcement des seuils réglementaires et des programmes de surveillance.

Le tableau II en donne une vue synthétique tabulaire ; il ne remplace pas une analyse toxicologique détaillée.

Table II – Exemples d’effets sanitaires associés à l’exposition aux PFAS (synthèse).

Système	Effets documentés	Populations sensibles
Immunitaire	Diminution de la réponse vaccinale	Enfants
Endocrinien	Perturbation thyroïdienne, lipides	Adultes
Développement	Faible poids à la naissance	Femmes enceintes
Reproduction	Fertilité, complications gestationnelles	Adultes
Cancér (certains composés)	Rein, testicules (associations)	Exposés professionnels

1.2.4.2. Évolution du cadre réglementaire

Face à ces risques, les seuils admissibles ont fortement baissé au cours des dernières années. Aux États-Unis, l’EPA a publié en 2016 un **avis sanitaire** (*health*

advisory) à **70 ng/L** pour la somme PFOA+PFOS [14], puis en 2024 un **règlement national** sur l'eau potable fixant des limites maximales de contaminants (MCL) à **4 ng/L** pour le PFOA et le PFOS **séparément** [15]. Cette dualité (avis historique vs limites récentes plus strictes) illustre la **rapidité** de l'évolution normative.

En Europe, la directive sur l'eau potable (2020/2184/UE) encadre un sous-ensemble de PFAS :

- une limite sur la **somme de 20 PFAS** prioritaires (indicateur $PFAS_{Total}$, valeur paramétrique de l'ordre de $0,1 \mu g/L$) ;
- une limite sur le **total des PFAS** mesurés au-delà d'un seuil de quantification (indicateur $PFAS_{TQS}$, de l'ordre de $0,5 \mu g/L$).

Des initiatives nationales complètent ce cadre (programmes de surveillance en Allemagne, Pays-Bas, Danemark, etc.). En France, des textes récents visent à restreindre certains usages non essentiels (cosmétiques, textiles, produits de loisirs) et à renforcer la fiscalité ou la redevance sur les rejets industriels, dans une logique de **prévention** à la source.

Quelle que soit la juridiction, le message commun est le suivant : les concentrations d'intérêt sont **très faibles**, la liste des composés à suivre **change**, et la surveillance doit être **étendue** dans le temps et dans l'espace, ce qui pose un défi logistique considérable pour les gestionnaires de l'eau.

Sur le continent africain, les réglementations nationales spécifiques aux PFAS font encore largement défaut. Les lignes directrices de l'Organisation mondiale de la santé pour la qualité de l'eau potable [16] constituent, dans ce contexte, la référence disponible pour les pays d'Afrique subsaharienne. Au Cameroun en particulier, aucune norme nationale dédiée aux PFAS n'est actuellement en vigueur ; la surveillance s'appuie sur des valeurs guides internationales, rendant d'autant plus pertinentes les approches fondées sur des données contextuelles disponibles pour estimer le risque sans analyse ciblée systématique.

L'ensemble de ces contraintes (analytiques, logistiques et réglementaires) motive le recours à des outils d'apprentissage automatique capables d'extraire un signal utile à partir des données existantes. La section suivante introduit les méthodes et paradigmes de l'apprentissage automatique qui seront mobilisés dans cette étude.

I.3. Apprentissage automatique et méthodes d'ensemble

L'**apprentissage automatique** (*machine learning*, ML) regroupe les méthodes qui permettent à un système informatique d'améliorer une tâche à partir de données, sans que chaque règle de décision soit codée explicitement. En sciences de l'environnement, ces approches servent notamment à exploiter des tableaux de mesures et de variables contextuelles (géologie, hydrologie, proximité d'activités) pour estimer un risque ou prioriser des sites à contrôler. Cette section présente d'abord les principaux **paradigmes** d'apprentissage, puis les **principes des méthodes d'ensemble** illustrés par des exemples courants.

I.3.1. Paradigmes de l'apprentissage automatique

L'apprentissage automatique peut se définir, suivant Mitchell [17], comme suit : un programme **apprend** à partir de l'expérience E par rapport à une classe de tâches T et une mesure de performance P si sa performance sur T , mesurée par P , s'améliore avec l'accumulation de l'expérience E . En pratique, un **algorithme** ajuste des paramètres à partir d'exemples pour produire des prédictions ou des décisions. On distingue ensuite plusieurs paradigmes selon la nature des données disponibles et l'objectif visé.

I.3.1.1. Apprentissage supervisé

En **apprentissage supervisé**, chaque exemple d'entrée $\mathbf{x}$ est associé à une **étiquette** y connue. L'objectif est d'apprendre une fonction $f(\mathbf{x}) \approx y$ qui **généralise** à de nouvelles observations non vues à l'entraînement.

Deux tâches principales en découlent :

- la **classification**, lorsque y est discrète (par exemple *contaminé / non contaminé*) ;
- la **régression**, lorsque y est continue (par exemple une concentration mesurée).

Le protocole habituel consiste à séparer les données en un jeu d'**entraînement** (pour ajuster f), un jeu de **validation** (pour choisir les hyperparamètres) et un jeu de **test** (pour estimer la performance en conditions indépendantes). En surveillance environnementale, la classification binaire (dépassement ou non d'un seuil, présence ou absence d'un signal) est fréquente lorsque l'on cherche à orienter des campagnes de mesure [18].

I.3.1.2. Apprentissage non supervisé

En **apprentissage non supervisé**, les données ne sont pas étiquetées : l'algorithme cherche à mettre en évidence des **structures** sans cible explicite [18]. Les objectifs typiques sont :

- le **regroupement** (*clustering*), par exemple regrouper des sites aux profils hydrogéologiques voisins ;
- la **réduction de dimension**, pour visualiser ou compresser un grand nombre de variables corrélées ;
- la détection d'**anomalies**, pour repérer des observations atypiques.

Ces méthodes ne produisent pas directement une prédiction de contamination, mais elles peuvent précéder une étape supervisée en révélant des homogénéités spatiales ou des corrélations entre variables.

I.3.1.3. Apprentissage semi-supervisé

L'**apprentissage semi-supervisé** combine un nombre limité d'exemples **étiquetés** et un volume plus important de données **non étiquetées**. Il est particulièrement utile lorsque l'étiquetage est **coûteux** ou **lent**, ce qui est souvent le cas en environnement lorsque chaque étiquette correspond à une analyse de laboratoire.

L'idée générale est d'exploiter la structure des données non étiquetées (similarité entre sites, continuité spatiale) pour renforcer un modèle entraîné sur le sous-ensemble étiqueté. Des travaux récents sur les PFAS en eaux souterraines ont mobilisé cette logique lorsque les mesures ciblées restent rares par rapport au nombre de points à évaluer [6].

I.3.1.4. Apprentissage par renforcement

En **apprentissage par renforcement**, un **agent** interagit avec un **environnement** et apprend une politique de décision à partir de **récompenses** ou de **pénalités** reçues au fil du temps. Contrairement au cadre supervisé, il n'existe pas d'étiquette correcte pour chaque action : l'agent doit **explorer** et **exploiter** ses choix pour maximiser un gain cumulé.

Ce paradigme trouve ses principales applications en robotique, dans les jeux à information incomplète et dans les systèmes de recommandation dynamique [19].

I.3.2. Méthodes d'ensemble

Une **méthode d'ensemble** combine plusieurs **apprenants** pour former un prédicteur plus stable ou plus précis qu'un modèle isolé. Le principe est le suivant : si les apprenants ne se trompent pas toujours aux mêmes endroits, les combiner peut compenser leurs faiblesses respectives. Le **bagging** atténue surtout la **variance** (prédictions instables d'un modèle très flexible), tandis que le **boosting** réduit plutôt le **biais** (erreurs systématiques d'un modèle trop simple). Quant au **stack-**

ing, il combine des modèles de natures éventuellement différentes pour optimiser la combinaison des sorties.

1.3.2.1. Bagging

Le **bagging** (*bootstrap aggregating*) entraîne plusieurs modèles en **parallèle** sur des tirages **bootstrap** des observations (échantillonnage avec remise), puis **agrège** leurs prédictions. En classification, la décision finale est un **vote majoritaire** ; en régression, une moyenne des prédictions. Le bagging vise surtout à stabiliser un apprenant à forte variance (comme un arbre de décision profond) en moyennant des versions entraînées sur des sous-jeux légèrement différents. On peut formaliser l'agrégation en classification par

$$\hat{y}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \sum_{b=1}^B \mathbb{I}(h_b(\mathbf{x}) = c),$$

où h_b désigne le b -ième modèle entraîné sur un bootstrap, et B le nombre total de modèles. Plus B augmente, plus la prédiction devient stable, jusqu'à un plateau de performance.

Exemple (forêt aléatoire). La **forêt aléatoire** (*Random Forest*) [20] est l'illustration standard du bagging appliqué aux arbres de décision. Chaque arbre est entraîné sur un sous-échantillon bootstrap ; à chaque nœud, seul un sous-ensemble aléatoire de variables est candidat au meilleur partage. Cette double aléa (données et variables) **décorrèle** les arbres et limite le surapprentissage. Dans la pratique, les hyperparamètres les plus structurants sont :

- le nombre d'arbres B (`n_estimators`) ;
- la profondeur maximale de chaque arbre (`max_depth`) ;
- le nombre minimal d'observations pour scinder un nœud ou créer une feuille (`min_samples_split`, `min_samples_leaf`) ;
- le nombre de variables testées à chaque nœud (`max_features`).

Un réglage prudent de ces paramètres contrôle le compromis biais-variance et évite des arbres trop spécialisés.

Un atout important de Random Forest est l'estimation dite **out-of-bag** (OOB) : pour chaque observation, on peut évaluer la prédiction en utilisant uniquement les arbres qui n'ont pas vu cette observation à l'entraînement. Ce score OOB donne une estimation rapide de la généralisation sans validation croisée exhaustive.

Pour l'interprétation, la forêt fournit des **importances de variables** (par impureté ou par permutation), utiles pour identifier les descripteurs dominants. En

revanche, ces importances doivent être analysées avec prudence en présence de variables corrélées. Les forêts aléatoires restent ainsi une base solide en données tabulaires, à la fois robuste, explicable à un niveau global, et souvent performante comme modèle de référence ou composant d'un ensemble plus complexe.

La figure 4 illustre le principe d'une forêt aléatoire : plusieurs arbres entraînés en parallèle sur des sous-échantillons, puis agrégés par vote.




Figure 4 – Schéma d'une forêt aléatoire (bagging d'arbres de décision avec sous-échantillonnage des observations et des variables). Source : adapté de [3].

Chaque arbre voit un sous-jeu de données différent et ne retient qu'une fraction des variables à chaque scission, ce qui diversifie les prédictions avant leur agrégation finale.

1.3.2.2. Boosting

Le **boosting** construit le modèle de façon **séquentielle** : chaque nouvel apprenant cible les erreurs laissées par l'ensemble des apprenants précédents, au lieu d'entraîner des modèles indépendants comme en bagging. La figure 5 résume cette logique additive : le modèle courant est enrichi à chaque itération par un arbre entraîné sur les résidus.




Figure 5 – Principe du boosting : ajout séquentiel d’arbres pour corriger les erreurs du modèle courant. Source : illustration pédagogique adaptée de [4].

Il ressort de cette représentation que les prédictions s’améliorent progressivement en cumulant de petits correctifs, plutôt qu’en moyennant des modèles parallèles indépendants comme en bagging.

Le **gradient boosting** [21] met cette idée en œuvre en ajoutant, à chaque itération, un arbre qui corrige les résidus selon le gradient d’une fonction de perte différentiable. On écrit souvent la prédiction additive sous la forme

$$F_M(\mathbf{x}) = F_{M-1}(\mathbf{x}) + \eta h_M(\mathbf{x}), \quad (\text{I.1})$$

où h_M est un nouvel arbre entraîné sur les résidus et η un taux d’apprentissage. Dans la pratique, le boosting construit souvent des arbres **courts** (faible profondeur) afin de corriger progressivement les erreurs sans sur-ajuster le bruit. Le paramètre η (*learning rate*) contrôle la contribution de chaque nouvel arbre : une valeur faible stabilise l’apprentissage mais exige davantage d’itérations. Le nombre d’arbres, la profondeur maximale et les contraintes de régularisation gouvernent ainsi le compromis entre **capacité de modélisation** et **généralisation**.

Exemple (XGBoost et LightGBM). XGBoost (*eXtreme Gradient Boosting*) [22] est l’une des implémentations les plus utilisées sur **données tabulaires**, notamment lorsque l’on recherche un modèle performant et robuste. Son apprentissage optimise une fonction objectif composée d’un terme de perte et d’un terme de complexité :

$$\mathcal{J}^{(t)} = \sum_{i=1}^n l\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t),$$

avec une régularisation typique

$$\Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j|,$$

où T est le nombre de feuilles, w_j les poids des feuilles, et $(\alpha, \lambda, \gamma)$ les coefficients de pénalisation. Cette formulation explicite permet de limiter la complexité des arbres et de réduire le surapprentissage.

En pratique, les hyperparamètres les plus influents sont :

- `n_estimators` : nombre d'arbres ajoutés ;
- `max_depth` : profondeur maximale des arbres ;
- `learning_rate` : poids de chaque nouvel arbre ;
- `subsample` et `colsample_bytree` : sous-échantillonnage des observations et des variables ;
- `reg_alpha`, `reg_lambda` et `gamma` : contrôle de la régularisation.

XGBoost prend aussi en charge les valeurs manquantes en apprenant une direction de branche par défaut lors des splits, et propose des implémentations efficaces (*histogram-based*, parallélisation) adaptées aux volumes de données importants. Dans un cadre appliqué, XGBoost est souvent mobilisé comme modèle de référence fort ou comme composant d'un empilement, car il combine bonne précision, robustesse et interprétabilité globale (importance des variables, SHAP).

LightGBM (*Light Gradient Boosting Machine*) [23] privilégie une croissance des arbres **feuille par feuille** (*leaf-wise*) et introduit des mécanismes d'échantillonnage (GOSS) et de regroupement de variables (EFB) pour accélérer l'entraînement sur de grands jeux de données.

1.3.2.3. Stacking

Le **stacking** (*stacked generalization*) place un **méta-classifieur** (ou méta régresseur) au-dessus de plusieurs **modèles de base** de natures éventuellement différentes. Chaque modèle de base produit une prédiction (ou une probabilité) ; le méta-modèle apprend à les combiner de manière optimale, au lieu de se limiter à un vote fixe comme en bagging. L'idée centrale est que des modèles différents capturent des **signaux complémentaires** : un modèle peut mieux exploiter les interactions non linéaires tabulaires, un autre la structure relationnelle, un autre encore des effets locaux. Le stacking apprend donc une **fonction de fusion** des sorties de base plutôt qu'une règle de combinaison fixée a priori.

Si l'on note $p_k(\mathbf{x})$ la sortie du k -ième modèle de base, le méta-modèle apprend une fonction

$$\hat{y} = g(p_1(\mathbf{x}), p_2(\mathbf{x}), \dots, p_K(\mathbf{x})),$$

où g peut être, selon les cas, une régression logistique, un arbre de décision, un gradient boosting ou un autre classifieur. En pratique, les entrées de g peuvent être enrichies par des variables de confiance (entropie des probabilités, écart entre modèles, etc.).

Exemple (méta-classifieur sur sorties de bases). On peut par exemple empiler une forêt aléatoire, un gradient boosting et un modèle produisant des embeddings (graphe ou autre), puis entraîner un classifieur final sur les vecteurs de prédictions produits par ces bases.

La figure 6 résume l'architecture hiérarchique du stacking.




Figure 6 – Principe du stacking : plusieurs modèles de base alimentent un méta-classifieur.

La figure souligne que le méta-modèle ne reçoit pas les variables brutes mais les sorties des apprenants de base, permettant ainsi de combiner des modèles de natures différentes.

Pour éviter le surapprentissage, les entrées du méta-classifieur doivent provenir de **prédictions hors échantillon** : les modèles de base ne doivent pas avoir vu les exemples utilisés pour entraîner le méta-modèle. La procédure usuelle repose sur une validation croisée en deux niveaux :

- niveau 1 : générer, pour chaque observation d'entraînement, des prédictions hors pli des modèles de base ;
- niveau 2 : entraîner le méta-modèle sur cette matrice de méta-caractéristiques, puis réentraîner les modèles de base sur l'ensemble d'entraînement.

Cette discipline méthodologique est essentielle pour obtenir un gain réel au test.

Le stacking est particulièrement utile quand la performance individuelle des modèles est proche mais que leurs erreurs ne se recouvrent pas totalement. Il peut

toutefois être sensible à la complexité du méta-modèle et à la qualité des prédictions de base ; un protocole d'évaluation rigoureux reste donc indispensable.

Le tableau III présente les trois familles d'ensembles et un exemple représentatif pour chacune ; pour les données tabulaires de taille modérée, les ensembles d'arbres restent souvent très compétitifs face à des réseaux profonds génériques [24].

Table III – Synthèse des trois familles d'ensembles et d'un exemple représentatif pour chacune.

Famille	Construction		Effet visé	Exemple
Bagging	Parallèle	sur	Réduit la variance	Forêt aléatoire
	tirages bootstrap			
Boosting	Séquentielle	sur	Réduit le biais	XGBoost, Light-GBM
	les résidus			
Stacking	Méta-modèle	sur	Combine des mod-	Méta-classifieur
	les sorties	des	èles hétérogènes	
	bases			

I.4. Graphes et réseaux de neurones sur graphes

Les données de surveillance des eaux souterraines sont souvent stockées sous forme **tabulaire** (une ligne par puits, une colonne par variable). Or, un site de prélèvement n'est pas isolé : il partage un contexte géologique, une proximité d'installations, des co-contaminants et une position géographique avec d'autres sites. Les **graphes** offrent un langage naturel pour représenter ces dépendances et les exploiter par apprentissage profond, en complément des modèles tabulaires (forêts aléatoires, XGBoost) présentés en section I.3.2.1–I.3.2.3.

I.4.1. Représentation des données par graphe

Un **graphe** $G = (V, E)$ modélise des entités par des **nœuds** $v \in V$ et des liens par des **arêtes** $e \in E$ [25]. Chaque nœud peut porter un vecteur de caractéristiques $\mathbf{x}_v \in \mathbb{R}^{d_v}$. En classification de sites, on associe en général à chaque nœud **sample** (échantillon) une **étiquette** y_v (par exemple contamination oui/non).

Contrairement à une image (grille régulière) ou à une séquence (chaîne), un graphe autorise des connexions **irrégulières** : le voisinage d'un site n'est pas imposé par la position dans un tableau, mais par la structure relationnelle choisie. Cette flexibilité est utile lorsque l'on veut relier explicitement un puits à des variables de contexte (environnement, installations, qualité de l'eau, regroupement géographique).

On distingue :

- le **graphe homogène** : un seul type de nœud et un seul type d'arête ;
- le **graphe hétérogène** : plusieurs types de nœuds et d'arêtes typées, notées (s, r, t) pour une relation r entre un nœud source de type s et un nœud cible de type t .

En surveillance environnementale, l'hétérogénéité reflète le modèle conceptuel **source, voie et récepteur** (section I.2.2.4) : sources d'activité, milieux de transport, sites de mesure.

I.4.2. Réseaux de neurones sur graphes

Les **réseaux de neurones sur graphes** (GNN, *Graph Neural Networks*) apprennent une **représentation vectorielle** (*embedding*) pour chaque nœud en diffusant l'information de proche en proche. Le mécanisme standard est le **message passing** : à chaque couche ℓ , un nœud agrège les messages de ses voisins $\mathcal{N}(v)$ puis met à jour sa représentation :

$$\mathbf{h}_v^{(\ell+1)} = \text{UPDATE}\left(\mathbf{h}_v^{(\ell)}, \text{AGGREGATE}\left(\{\mathbf{h}_u^{(\ell)} : u \in \mathcal{N}(v)\}\right)\right).$$

La figure 7 illustre ce mécanisme sur un nœud central et ses voisins.




Figure 7 – *Message passing : agrégation des représentations des voisins $\mathcal{N}(v)$ vers le nœud v .*

L'information locale se propage ainsi par couches successives : après ℓ itérations, $\mathbf{h}_v^{(\ell)}$ encode un voisinage à ℓ sauts [26, 27].

Des variantes historiques incluent les **GCN** (*Graph Convolutional Networks*), les **GAT** (*Graph Attention Networks*) et **GraphSAGE**, qui diffèrent par la fonction d'agrégation et la pondération des voisins. En pratique, ces modèles sont souvent implémentés avec des bibliothèques spécialisées telles que **PyTorch Geometric** (PyG), qui fournit des structures de données et des couches convolutives sur graphe [27].

I.4.3. Graphes hétérogènes

Un **graphe hétérogène** (ou *graphe typé*) étend la définition élémentaire $G = (V, E)$ en associant un type à chaque nœud et à chaque arête [5] :

$$G = (V, E, \tau, \phi),$$

où $\tau : V \rightarrow \mathcal{T}$ est la fonction de typage des nœuds ($|\mathcal{T}| \geq 2$) et $\phi : E \rightarrow \mathcal{R}$ celle des arêtes ($|\mathcal{R}| \geq 2$). Chaque type de nœud $A \in \mathcal{T}$ dispose de son propre espace de caractéristiques $\mathbb{R}^{d_A}$, ce qui autorise des entités de natures radicalement différentes (auteurs, articles, lieux de publication, thèmes de recherche) à cohabiter dans la même structure relationnelle.

Une **méta-relation** est un triplet $\langle A, r, B \rangle \in \mathcal{T} \times \mathcal{R} \times \mathcal{T}$ décrivant un lien de type r entre un nœud source de type A et un nœud cible de type B . Deux nœuds peuvent ainsi être reliés par des arêtes de sémantiques distinctes (co-autorat, citation, appartenance à un même domaine) ; le modèle peut apprendre des paramètres d'agrégation distincts pour chaque méta-relation plutôt qu'un seul ensemble de paramètres partagé.

Une **méta-chemin** désigne une séquence ordonnée de types de nœuds reliés par des types de relations :

$$\mathcal{P} : A_0 \xrightarrow{r_1} A_1 \xrightarrow{r_2} A_2 \cdots \xrightarrow{r_\ell} A_\ell.$$

Les méta-chemins capturent des dépendances sémantiques composées qui ne sont pas visibles dans le voisinage immédiat. Par exemple, dans un réseau académique, le méta-chemin $\text{Auteur} \xrightarrow{\text{écrit}} \text{Article} \xrightarrow{\text{écrit_par}} \text{Auteur}$ identifie deux chercheurs ayant co-publié sans qu'une arête directe entre eux soit présente dans le graphe.

Ce formalisme s'applique dans de nombreux domaines où les entités et leurs relations sont intrinsèquement hétérogènes : réseaux académiques (auteurs, articles, lieux, domaines) [5], graphes biomédicaux associant gènes, maladies et médicaments, graphes de connaissance à large échelle, ou encore réseaux de surveillance environnementale où plusieurs catégories d'entités sont reliées par des liens typés. La conception du graphe hétérogène utilisé dans cette étude est détaillée au chapitre 3.

Contrairement aux GNN homogènes, les GNN hétérogènes doivent gérer simultanément des espaces de caractéristiques de dimensions différentes selon le type de nœud. La solution usuelle est de projeter les vecteurs de chaque type dans un espace latent commun de dimension d avant les opérations d'agrégation, puis de spécialiser les paramètres d'attention selon la méta-relation. C'est précisément

ce mécanisme que le **HGT** (section I.4.4) formalise par des matrices de clé (**K**), de requête (**Q**) et de valeur (**V**) propres à chaque type de nœud et de relation.

I.4.4. Heterogeneous Graph Transformer (HGT)

Le **Heterogeneous Graph Transformer** (HGT) [5] adapte le mécanisme d'**attention** des transformeurs aux graphes hétérogènes. Pour une méta-relation (τ_s, ϕ, τ_t) , les poids d'attention dépendent du type de nœud source, du type de relation et du type de nœud cible. Chaque type dispose de projections spécifiques (matrices requête, clé, valeur), ce qui permet d'apprendre des interactions différenciées entre, par exemple, un lien *géographique* et un lien *de qualité de l'eau*.

Pour un message envoyé d'un voisin u vers un nœud cible v , l'attention peut s'écrire schématiquement :

$$\alpha_{uv} = \text{softmax} \left(\frac{(\mathbf{K}_{\tau(u)} \mathbf{h}_u)^\top (\mathbf{Q}_{\tau(v)} \mathbf{h}_v)}{\sqrt{d}} \right), \quad \mathbf{h}'_v = \sum_{u \in \mathcal{N}(v)} \alpha_{uv} \mathbf{V}_{\phi(u,v)} \mathbf{h}_u,$$

où $\mathbf{K}_{\tau(u)}$ (clé, type source) et $\mathbf{Q}_{\tau(v)}$ (requête, type cible) sont des projections spécifiques au type, et $\mathbf{V}$ dépend du type de relation [5]. Des couches HGTConv sont empilées pour produire, en sortie, un **embedding** de dimension fixe pour chaque nœud sample.

La figure 8 illustre le mécanisme d'attention hétérogène du HGT : les nœuds sources projettent leurs représentations via les matrices clé (**K**), les nœuds cibles via les matrices requête (**Q**), et les valeurs (**V**) sont pondérées par les scores d'attention avant agrégation.




Figure 8 – Architecture du *Heterogeneous Graph Transformer* (HGT) : attention typée par méta-relation pour la propagation de l'information dans un graphe hétérogène. Source : adapté de [5].

La figure souligne que chaque méta-relation (τ_s, ϕ, τ_t) dispose de ses propres paramètres de projection, ce qui permet au modèle d'apprendre des interactions sémantiquement différentes selon la nature des nœuds et des liens connectés.

Cet embedding résume l'information relationnelle diffusée dans le graphe (contexte environnemental, proximité d'installations, co-contaminants, voisinage géographique). Il peut ensuite être exploité de deux manières complémentaires, au coeur des approches hybrides :

- **Fusion par embeddings** : concaténation des embeddings HGT avec les variables tabulaires d'origine, puis apprentissage d'un classifieur XGBoost sur l'espace enrichi ;
- **Stacking** : utilisation des probabilités ou embeddings HGT comme entrées d'un méta-classifieur, aux côtés d'autres modèles tabulaires (section I.3.2.3).

Cette dualité révèle un pont entre **données relationnelles** (graphe) et **modèles tabulaires** (boosting), utile lorsque la structure spatiale et contextuelle apporte un signal que les seules colonnes isolées ne capturent pas entièrement.

I.5. Interprétabilité des modèles

Un modèle précis mais opaque limite l'acceptation par les gestionnaires de l'eau et les régulateurs : une décision de contrôle, de priorisation de campagnes ou de fermeture de puits exige une **justification** compréhensible et reproductible. En santé environnementale, l'interprétabilité n'est plus un simple complément esthétique : elle conditionne la confiance des parties prenantes et la possibilité de confronter les sorties algorithmiques à des connaissances de terrain (hydrogéologie, usages industriels, co-contaminants). Cette section présente les notions nécessaires pour lire les analyses menées dans la contribution, en particulier l'approche **SHAP** et son déploiement sur les modèles tabulaires, fusionnés et empilés décrits aux sections I.3.2.3 et I.4.4.

I.5.1. Enjeux et interprétabilité a posteriori

On distingue en pratique deux familles d'approches. L'interprétabilité **intrinsèque** repose sur des modèles structurellement lisibles (arbres de décision peu profonds, régressions linéaires avec coefficients explicites). L'interprétabilité **a posteriori** (*post-hoc*) applique, après entraînement, des méthodes qui expliquent les prédictions d'un modèle potentiellement complexe (forêt aléatoire, gradient boosting, réseau sur graphe). Les importances par impureté des forêts aléatoires (section I.3.2.1) donnent un ordre de grandeur global, mais elles ne décrivent pas la contribution à une prédiction individuelle ni ne satisfont des axiomes de répartition

équitable entre variables corrélées. Les importances par permutation [20] corrigent partiellement ce biais en mesurant la dégradation de performance lorsqu’une variable est mélangée aléatoirement sur l’échantillon de validation ; elles s’appliquent à tout type de modèle mais restent globales, insensibles à la direction de l’effet et coûteuses à calculer quand le nombre de variables est élevé.

LIME (*Local Interpretable Model-agnostic Explanations*) [28] adopte une logique locale : pour chaque observation, un modèle linéaire interprétable est ajusté sur des perturbations de l’entrée pondérées par leur proximité au point d’intérêt. La flexibilité de LIME est un atout, mais la stabilité des explications dépend fortement du protocole d’échantillonnage et peut varier d’une exécution à l’autre, ce qui limite son usage dans des contextes réglementaires exigeant la reproductibilité.

L’approche **SHAP** (*SHapley Additive exPlanations*) [29] fournit un cadre unifié : chaque variable reçoit une contribution additive à la prédiction, fondée sur la théorie des jeux coopératifs. Elle s’applique naturellement aux modèles à arbres mobilisés dans ce mémoire (XGBoost, LightGBM) via l’algorithme **Tree-SHAP**, et se prolonge aux espaces de features enrichis (fusion d’embeddings, méta-caractéristiques de stacking).

1.5.2. Valeurs de Shapley et décomposition additive

Pour une prédiction $f(\mathbf{x})$ sur un vecteur de variables $\mathbf{x} = (x_1, \dots, x_p)$, la contribution SHAP de la variable i repose sur la **valeur de Shapley** :

$$\phi_i = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|!(|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)], \quad (\text{I.2})$$

où $\mathcal{F} = \{1, \dots, p\}$ est l’ensemble des indices de variables et $f(S)$ la prédiction moyenne du modèle lorsque seules les variables de la coalition S sont observées, les autres étant marginalisées selon la distribution de référence (souvent l’échantillon d’entraînement ou de test).

Chaque variable est vue comme un *joueur* ; la coalition S représente un sous-ensemble de variables disponibles pour la prédiction. Le terme $f(S \cup \{i\}) - f(S)$ mesure le **gain marginal** de i lorsque S est déjà connu ; la formule (I.2) en fait la moyenne pondérée sur toutes les coalitions, ce qui évite qu’une variable corrélée monopolise tout le crédit ou soit ignorée selon l’ordre d’introduction.

Cette construction vérifie des propriétés souhaitables [29] :

- **Efficacité** : $\sum_{i=1}^p \phi_i = f(\mathbf{x}) - \mathbb{E}[f(\mathbf{X})]$, où $\mathbb{E}[f(\mathbf{X})]$ est la **valeur de base** (*expected value*) du modèle ;

- **Symétrie** : deux variables ayant la même contribution marginale sur toute coalition reçoivent la même valeur SHAP ;
- **Nullité** : une variable sans effet reçoit $\phi_i = 0$;
- **Additivité** : pour un ensemble de modèles combinés additivement, les contributions se somment.

La prédiction s'écrit ainsi sous forme additive :

$$f(\mathbf{x}) = \phi_0 + \sum_{i=1}^p \phi_i, \quad \phi_0 = \mathbb{E}[f(\mathbf{X})],$$

ce qui permet de lire, pour chaque observation, quelles variables **augmentent** ou **diminuent** la sortie du modèle par rapport à la moyenne.

Le calcul exact de l'équation (I.2) est exponentiel en p (toutes les coalitions). **TreeSHAP** [29] exploite la structure des arbres de décision pour obtenir des valeurs SHAP **exactes** en temps polynomial pour XGBoost, LightGBM et les forêts aléatoires. En pratique, on instancie un `TreeExplainer` sur le booster entraîné ; à défaut, XGBoost expose aussi des *pred_contri*s (contributions par feuille) compatibles avec la même lecture additive.

I.5.3. Analyses globale et locale

Les sorties SHAP se lisent à deux échelles complémentaires.

Niveau global. On agrège typiquement les valeurs absolues $|\phi_i|$ sur un jeu d'observations (souvent l'échantillon de test) pour obtenir une **importance moyenne** par variable. Le graphique en barres (*bar plot*) classe les variables par ordre décroissant de cette importance. Le graphique en nuage (*beeswarm*, ou *summary plot*) représente, pour chaque variable, la distribution des ϕ_i : la position horizontale indique l'ampleur et le signe de l'effet, la couleur le niveau de la variable (faible ou élevé). On observe ainsi non seulement *quelles* variables comptent le plus, mais aussi si une valeur élevée de la variable pousse généralement vers la classe positive ou négative [29].

Niveau local. Pour une observation $\mathbf{x}^{(j)}$ (un puits, un point de surveillance), les $\phi_i^{(j)}$ décrivent la prédiction individuelle. Le **graphique de force** (*force plot*) aligne les contributions positives (vers la classe *contaminé*) et négatives (vers la classe *non contaminé*) autour de la valeur de base ϕ_0 . Un barplot local des $|\phi_i^{(j)}|$ les plus élevés offre une vue synthétique pour un cas d'étude. Ces vues sont utiles pour expliquer à un expert pourquoi un site précis a été classé à risque, au-delà d'un score global.

Relations non linéaires. Les **graphiques de dépendance** (*dependence plots*) représentent, pour une variable i , la valeur de x_i en abscisse et ϕ_i en ordonnée. Ils mettent en évidence des effets à seuil, des saturations ou des interactions (en colorant les points selon une deuxième variable corrélée). Pour des classifieurs par arbres, on peut y vérifier que le modèle reproduit des comportements plausibles (par exemple une influence accrue de la proximité d'une source industrielle au-delà d'un certain rayon), sans confondre cette cohérence avec une preuve causale.

I.5.4. Limites et recul épistémologique

Une variable importante au sens SHAP (proximité d'une installation, co-contaminant, embedding lié à un cluster géographique) signale une **association statistique** apprise par le modèle, pas un mécanisme physique démontré. Les variables corrélées se partagent le crédit : l'ordre d'importance peut varier selon l'échantillon et la distribution de référence. Les explications portent sur le **modèle entraîné** et le jeu de données considéré ; un réentraînement ou un changement de protocole (par exemple passage au mode confirmatoire avec concentrations PFAS) peut modifier les profils SHAP même si les tendances physiques demeurent qualitatives.

Pour le HGT, la partie du signal portée par la **topologie** du graphe (chemins entre facility, env, sample) n'est pas entièrement dépliée dans les graphiques tabulaires ou d'embeddings. Enfin, l'usage opérationnel suppose une **lecture conjointe** avec des hydrogéologues et des toxicologues : l'outil priorise et explique, la décision publique reste argumentée au-delà du seul score algorithmique.

I.6. Synthèse

Ce chapitre a introduit, de manière autonome et progressive, les concepts mobilisés dans la suite du mémoire. Les **PFAS** ont été présentés comme polluants persistants, soumis à un encadrement réglementaire de plus en plus strict. Les paradigmes de l'**apprentissage automatique** (supervisé, non supervisé, semi-supervisé et par renforcement), les méthodes d'ensemble par **bagging** (forêt aléatoire), **boosting** (XGBoost, LightGBM) et **stacking** (méta-classifieur) constituent le socle des méthodes prédictives en données tabulaires. Les **graphes hétérogènes**, les GNN, le **HGT** et les schémas de fusion ou de stacking entre embeddings graphiques et modèles tabulaires, préparent la lecture des approches hybrides développées dans la suite du mémoire. Enfin, **SHAP** et TreeSHAP (analyses globale et locale, graphiques de dépendance) permettent d'expliquer les modèles tabulaires, la fusion embeddings–XGBoost, le stacking sur méta-caractéristiques et, partiellement,

le HGT par sensibilité au gradient ; cette interprétabilité conditionne une utilisation responsable en santé environnementale, sous réserve d'un recul sur la causalité.

II

CHAPTER

ÉTAT DE L'ART SUR LA PRÉDICTION DES CONTAMINANTS ÉMERGENTS DE L'EAU PAR INTELLIGENCE ARTIFICIELLE

SOMMAIRE

II.1 - Introduction	29
II.2 - Cadre conceptuel de la revue	30
II.3 - Modèles tabulaires pour la prédiction des PFAS	37
II.4 - Architectures profondes et relationnelles	43
II.5 - Discussion	47
II.6 - Synthèse	50

II.1. Introduction

La surveillance des PFAS dans les eaux souterraines constitue un défi analytique et économique : une analyse par chromatographie liquide couplée à la spectrométrie de masse tandem coûte plusieurs centaines d'euros par échantillon, alors que les seuils réglementaires se durcissent (4 ng/L pour le PFOA et le PFOS depuis 2023 aux États-Unis [15], 0,5 µg/L pour la somme des PFAS dans la directive européenne 2020/2184 [30]). Un contrôle exhaustif du parc de puits étant hors de portée de la plupart des gestionnaires, les méthodes d'intelligence artificielle se sont imposées comme outils de priorisation : orienter les campagnes vers les sites à plus forte probabilité de dépassement, à partir d'informations contextuelles disponibles sans analyse PFAS préalable. Les enjeux sanitaires, la chimie des

PFAS et les fondements algorithmiques mobilisés ayant été détaillés au chapitre I, ce chapitre se concentre sur leur application à la surveillance.

Depuis la décennie 2010, deux générations de méthodes sont bien documentées. La première repose sur des modèles probabilistes et tabulaires (réseaux bayésiens, forêts aléatoires, gradient boosting) traitant chaque puits comme un vecteur de descripteurs indépendants. La deuxième introduit des architectures plus complexe: d'abord avec des réseaux de neurones sur données moléculaires (QSAR), puis avec des chaînes de classifieurs semi-supervisées prédisant simultanément plusieurs dizaines d'analytes.

Ce chapitre examine ces deux générations de manière structurée : le cadre conceptuel de la revue (section II.2), dont la distinction mode prédictif/confirmatoire (section II.2.5) ; les méthodes tabulaires, probabilistes, d'ensemble et d'attribution de sources (section II.3) ; les architectures profondes et relationnelles (section II.4) ; une discussion transversale (section II.5) assortie des lacunes structurelles (section II.5.3) ; enfin une synthèse (section II.6).

II.2. Cadre conceptuel de la revue

Avant d'examiner les travaux, cinq éléments conceptuels propres à cette revue doivent être posés. Le premier est la formalisation du problème de prédiction ML sur données PFAS. Le deuxième relie la sélection des variables contextuelles aux mécanismes physico-chimiques de transport des PFAS, fondement commun à toutes les études examinées. Le troisième et le quatrième établissent le socle métrique commun (métriques d'évaluation, gestion du déséquilibre de classes) qui sert de référence à toutes les comparaisons inter-études. Le cinquième, et le plus fondamental, est la distinction entre mode prédictif et mode confirmatoire : mal comprise, elle conduit à des comparaisons de performance trompeuses entre études.

II.2.1. Formalisation du problème de prédiction PFAS par apprentissage automatique

La prédiction du statut de contamination d'un puits par apprentissage automatique revient à estimer une fonction $g : \mathcal{X} \rightarrow \mathcal{Y}$ associant à chaque puits, décrit par un vecteur de variables $\mathbf{x} \in \mathcal{X}$, une cible $y \in \mathcal{Y}$. Le vecteur $\mathbf{x}$ rassemble les descripteurs disponibles (géologie, hydrologie, proximité aux sources, qualité générale de l'eau) ; sa composition, avec ou sans concentrations PFAS mesurées, détermine le

régime d'évaluation discuté en section II.2.5. La fonction g est ajustée sur un jeu d'entraînement étiqueté en minimisant une fonction de perte, puis évaluée sur des données non vues (section I.3.1.1).

Les travaux examinés se distinguent par la nature de la cible $\mathcal{Y}$, qui commande le choix des méthodes et des métriques.

- *Classification binaire* ($y \in \{0, 1\}$) : présence ou absence d'un analyte, ou dépassement d'un seuil réglementaire. C'est la formulation la plus répandue (George et Dixit, Tokranov, Li et MacDonald Gibson, ainsi que le criblage total de Dong et al.).
- *Classification multi-étiquettes* ($\mathbf{y} \in \{0, 1\}^L$, L analytes) : prédiction simultanée de plusieurs dizaines d'analytes. Absente du cadre multiclasse classique présenté au chapitre I, elle est propre à la littérature PFAS [6] et conditionne le choix des architectures présentées en section II.4.2.
- *Cartographie de vulnérabilité* (y continu ou ordinal) : production d'un score de risque régional ou national plutôt que d'une étiquette par puits (Hu et al., McMahon et al.).

Deux propriétés traversent ces formulations. D'une part, la cible binaire dépend d'un seuil qui a évolué avec la réglementation, ce qui complique la comparaison directe des performances entre études anciennes et récentes (section II.2.5). D'autre part, le déséquilibre structurel de classes (section II.2.4, avec SMOTE [31] et ADASYN [32]) est particulièrement marqué dans les corpus PFAS, le rapport entre classe minoritaire et classe majoritaire s'étalant de 1/10 à 1/50 [6] ; le score F1 (section II.2.3) sert d'indicateur de référence, complété par la ROC-AUC pour les comparaisons inter-études.

II.2.2. Mécanismes de transport des PFAS et pertinence des variables contextuelles

La sélection des variables contextuelles dans les modèles ML de prédiction des PFAS n'est pas arbitraire : elle découle directement des mécanismes physico-chimiques qui gouvernent le devenir et le transport des PFAS en milieu souterrain. Trois processus principaux, décrits par Guelfo et al. [12] dans une revue exhaustive de l'état de la science, conditionnent la distribution spatiale des concentrations observées.

Advection et atténuation en fonction de la distance. Les PFAS se déplacent principalement par advection avec le flux d'eau souterraine, suivant les lignes d'écoulement

depuis les zones de recharge vers les zones de décharge. Prevedouros et al. [9] montrent que les concentrations de PFCA's décroissent avec la distance aux sources ponctuelles : la proximité à une installation fluorochimique, une base militaire (usage de mousses AFFF) ou une station d'épuration constitue donc un proxy du flux de contamination advectif. C'est ce constat mécaniste qui fonde l'utilisation systématique, dans toutes les études examinées, du nombre d'installations à 1, 3, 10 et 50 km comme variables prédictives.

Rétention sur la matrice solide. Brusseau et al. [10] établissent un modèle de rétention complet montrant que les PFAS se sorbent sur la matière organique du sol et sur les interfaces air-eau des zones vadoses : la granulométrie (proportion d'argiles, de limons, uniformité de la distribution), la teneur en matière organique et la profondeur de la nappe modulent fortement la mobilité des différentes familles de PFAS. Les composés à longue chaîne (PFOS, PFOA) se retiennent davantage que les composés à chaîne courte (PFBS, PFPeA), plus mobiles mais aussi plus difficiles à éliminer. Ce mécanisme justifie l'inclusion de descripteurs de sol (granulométrie, teneur en argile, ratio eau-argile) dans les vecteurs de features des modèles tabulaires.

Déposition atmosphérique. Les PFAS volatils ou semi-volatils (fluorotélomères, sulfonamides) sont émis dans l'atmosphère par les installations industrielles, transportés sur des distances pouvant dépasser 50 km et déposés par les précipitations [12]. Ce vecteur de contamination diffus et longue portée explique pourquoi les variables météorologiques (humidité, précipitations, qualité de l'air : $PM_{2.5}$, NO_2) figurent parmi les prédicteurs importants identifiés par Dong et al. [6], alors qu'elles ne sont pas directement liées aux sources ponctuelles locales.

Conséquences pour la modélisation par graphes. L'advection crée une dépendance spatiale structurelle entre puits : deux puits situés en aval d'une même source partagent un contexte de contamination commun qui ne peut pas être capturé par des vecteurs indépendants. Cette dépendance est directionnelle (orientée par le sens de l'écoulement) et hétérogène (fonction de l'intensité du flux, de la lithologie, de la proximité à la source). Les graphes hétérogènes, et en particulier le Heterogeneous Graph Transformer [5], sont conçus pour encoder cette topologie : des nœuds de types distincts (puits de surveillance, installations sources, clusters géographiques) sont reliés par des arêtes typées représentant la proximité aux sources et le voisinage spatial, le long desquelles l'information de contamination

se propage. Cette justification mécaniste fonde l'intérêt des architectures relationnelles, discutées comme direction émergente dans la lacune L1 (section II.5.3) : la topologie d'écoulement y est encodée explicitement plutôt que déduite de variables indépendantes.

II.2.3. Métriques d'évaluation des classifieurs de contamination PFAS

La comparaison des méthodes exigée par la revue nécessite un socle métrique commun, d'autant que les études examinées ne rapportent pas toutes les mêmes indicateurs. Cette section fixe les définitions retenues pour la classification binaire (présence/absence d'un PFAS, dépassement d'un seuil réglementaire), puis précise le passage au cas multi-étiquettes ; Sokolova et Lapalme [33] en proposent l'analyse systématique dont nous reprenons l'ossature. Toutes les métriques dérivent de la **matrice de confusion** (tableau IV), qui recense quatre effectifs en confrontant les prédictions à la vérité terrain : vrais positifs (VP), vrais négatifs (VN), faux positifs (FP) et faux négatifs (FN).

Table IV – *Matrice de confusion pour une classification binaire (classe positive = site contaminé).*

	Prédit 0	Prédit 1
Réel 0	Vrai négatif (VN)	Faux positif (FP)
Réel 1	Faux négatif (FN)	Vrai positif (VP)

Le choix de l'indicateur n'est pas neutre en surveillance environnementale : un faux négatif (site contaminé non détecté) expose une population, là où un faux positif (prélèvement inutile) n'entraîne qu'un coût analytique. Les métriques sensibles aux faux négatifs sont donc privilégiées.

Exactitude. L'exactitude $Acc = (VP + VN) / (VP + VN + FP + FN)$ mesure la proportion de prédictions correctes. Sous un fort déséquilibre de classes (section II.2.4), elle devient trompeuse : un classifieur prédisant toujours la classe majoritaire atteint une exactitude proche de 1 sans détecter le moindre site contaminé.

Précision, rappel et spécificité. Trois quantités se lisent directement dans la matrice :

$$\text{Précision} = \frac{VP}{VP + FP}, \quad \text{Rappel} = \frac{VP}{VP + FN}, \quad \text{Spécificité} = \frac{VN}{VN + FP}. \quad (\text{II.1})$$

La précision indique, parmi les sites signalés contaminés, la part qui l'est réellement. Le rappel (ou sensibilité) indique, parmi les sites réellement contaminés, la part détectée ; en priorisation PFAS, il prime, puisque manquer un site pollué est l'erreur la plus coûteuse. La spécificité indique, parmi les sites réellement non contaminés, la part correctement écartée (taux de vrais négatifs). Son complément $1 - \text{Spécificité}$, le taux de faux positifs, constitue l'abscisse de la courbe ROC.

Score F1 et F_β . Le score F1, moyenne harmonique de la précision et du rappel, condense ces deux quantités :

$$F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}. \quad (\text{II.2})$$

Sa généralisation $F_\beta = (1 + \beta^2) \frac{\text{Précision} \cdot \text{Rappel}}{\beta^2 \text{Précision} + \text{Rappel}}$ pondère le rappel par un facteur β ; choisir $\beta > 1$ pénalise davantage les faux négatifs, conformément à la logique de surveillance. La moyenne harmonique chute dès que la précision ou le rappel est faible, ce qui rend le F1 plus exigeant que l'exactitude sous déséquilibre [33].

Coefficient de corrélation de Matthews. Le coefficient de Matthews (MCC) combine les quatre cases de la matrice :

$$\text{MCC} = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}. \quad (\text{II.3})$$

Borné entre -1 et $+1$, il n'est élevé que si le classifieur réussit simultanément sur les deux classes. Chicco et Jurman [34] montrent qu'il reste plus fiable que le F1 et l'exactitude sous fort déséquilibre, car aucune classe ne peut à elle seule le gonfler.

Courbes ROC et précision-rappel. La courbe ROC trace le taux de vrais positifs contre le taux de faux positifs à mesure que varie le seuil de décision ; son aire (**ROC-AUC**) quantifie la séparabilité des classes indépendamment du seuil opérationnel [35]. Sous déséquilibre marqué, cette aire peut paraître optimiste ; la courbe précision-rappel et son aire (PR-AUC) reflètent alors plus fidèlement la performance sur la classe positive rare [36, 37].

Choix retenu pour la revue. Le F1 sert d'indicateur de référence pour les comparaisons inter-études, complété par la ROC-AUC lorsqu'elle est rapportée. En classification multi-étiquettes (L analytes), le **F1 macro**, moyenne uniforme sur les L analytes, est privilégié : il accorde le même poids à chaque analyte et évite

de masquer les mauvaises performances sur les composés rares, contrairement au F1 micro que dominent les analytes fréquents [33].

II.2.4. Déséquilibre de classes et rééchantillonnage synthétique

Dans les corpus de surveillance PFAS, la classe positive (détection ou dépassement de seuil) est structurellement minoritaire : le rapport entre classe minoritaire et classe majoritaire peut atteindre 1/10 à 1/50 selon les analytes et la région [6, 38]. Un classifieur entraîné sans correction tend alors à ignorer la classe positive pour maximiser l'exactitude globale, comportement inacceptable en surveillance sanitaire où c'est précisément cette classe qui importe. He et Garcia [39] distinguent quatre familles de réponses, souvent combinées.

Rééchantillonnage. La première agit sur la distribution du jeu d'entraînement, par sous-échantillonnage de la classe majoritaire ou sur-échantillonnage de la classe minoritaire. Le sur-échantillonnage aléatoire duplique des exemples existants, au risque du surapprentissage ; SMOTE et ADASYN, dominants dans la littérature PFAS, génèrent au contraire des exemples synthétiques. **SMOTE** (*Synthetic Minority Over-sampling Technique*) [31] interpole linéairement entre un exemple $\mathbf{x}_i$ et l'un de ses k plus proches voisins minoritaires :

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda(\mathbf{x}_j - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1). \quad (\text{II.4})$$

ADASYN (*Adaptive Synthetic Sampling*) [32] concentre la génération près de la frontière de décision : le nombre d'exemples alloué à chaque $\mathbf{x}_i$ croît avec la fraction $r_i = \Delta_i/k$ de ses k voisins appartenant à la classe majoritaire. Cette focalisation adaptative est pertinente lorsque les sites contaminés sont spatialement dispersés dans un corpus hétérogène, comme dans les études californiennes à grande échelle.

Pondération du coût. La deuxième famille conserve la distribution mais pénalise davantage les erreurs sur la classe minoritaire, en pondérant la fonction de perte par l'inverse de la fréquence des classes. Native dans la plupart des implémentations d'arbres d'ensemble via un paramètre de poids de classe, elle évite la création d'exemples artificiels.

Ajustement du seuil et métriques adaptées. La troisième famille déplace le seuil de décision (par défaut 0,5) vers une valeur qui maximise le rappel ou le F1 sur un jeu de validation. La quatrième, transversale, évalue le modèle avec des métriques robustes au déséquilibre plutôt qu'avec l'exactitude (section II.2.3).

Règle méthodologique commune. Quelle que soit la technique, le rééchantillonnage ne s'applique qu'au **jeu d'entraînement** ; les jeux de validation et de test conservent la distribution réelle des classes, faute de quoi les métriques sont artificiellement gonflées. Cette règle est appliquée dans tous les travaux examinés ; son non-respect est signalé explicitement dans les limites.

II.2.5. Mode prédictif et mode confirmatoire

Pour comparer les travaux examinés sur une base homogène, nous distinguons deux régimes d'évaluation selon un critère unique : la présence ou l'absence, dans le vecteur de features, de concentrations PFAS mesurées pour le puits évalué.

Le **mode confirmatoire** désigne la configuration où ce vecteur comprend des concentrations PFAS mesurées (partielles ou complètes) et où la variable cible est elle-même dérivée de ces mesures : $\mathbb{I}[\text{PFAS_total} > 70 \text{ ng/L}]$ en référence à l'avis sanitaire EPA 2016 [14]. Ce seuil de 70 ng/L, depuis abaissé à 4 ng/L [15], demeure la référence de la quasi-totalité des travaux examinés, ce qui complique leur comparaison avec les études les plus récentes. La configuration crée une **circularité** : les entrées contiennent l'information qui détermine l'étiquette, de sorte que les performances publiées (F1 supérieur à 0,96) ne reflètent pas ce que le modèle ferait sur un puits jamais analysé. Cette circularité est le seul critère du mode confirmatoire : la distinction ne porte donc que sur les tâches dont la cible est un statut de contamination dérivé de concentrations PFAS, et ne s'applique pas aux tâches dont la cible est de nature différente, telles que l'attribution de sources ou la prédiction de bioactivité moléculaire.

Le **mode prédictif** correspond au scénario opérationnellement pertinent : classer un puits avant tout prélèvement PFAS, sur la seule base d'informations contextuelles disponibles a priori (géologie, hydrologie, qualité générale de l'eau, proximité aux sources anthropiques, coordonnées géographiques). Formellement, si $\mathbf{x}_c$ est le vecteur de variables contextuelles et $\mathbf{x}_p = (\tilde{c}_1, \dots, \tilde{c}_K)$ les concentrations PFAS mesurées :

$$\text{Mode prédictif : } \hat{y} = g(\mathbf{x}_c), \quad (\text{II.5})$$

$$\text{Mode confirmatoire : } \hat{y} = g(\mathbf{x}_c, \mathbf{x}_p). \quad (\text{II.6})$$

Les deux modes répondent à des questions métiers distinctes : le mode prédictif (« Dois-je envoyer un préleveur ? ») précède l'analyse ; le mode confirmatoire (« Ce profil partiel indique-t-il un dépassement global ? ») complète un laboratoire partiellement informé. C'est le mode prédictif qui détermine la valeur réelle d'un outil d'aide à la décision pour les gestionnaires de réseaux.

Cette clé de lecture est appliquée systématiquement à chaque travail examiné dans les sections suivantes.

II.3. Modèles tabulaires pour la prédiction des PFAS

Les méthodes tabulaires constituent le fondement de la littérature prédictive sur les PFAS. Elles traitent chaque puits comme un vecteur de variables contextuelles dont la pertinence repose sur les mécanismes physico-chimiques de transport des PFAS en aquifère (section II.2.2). Leur avantage principal est la compatibilité directe avec les bases de surveillance environnementale structurées en tableaux, sans recours à des architectures graphiques ou à des modèles de transport hydrogéologique. Leur limite structurelle est l'hypothèse d'indépendance des observations : la topologie du réseau de surveillance et les liens de voisinage entre puits ne sont pas exploités.

II.3.1. Approches probabilistes et cartographie précoce de la vulnérabilité

Ce premier groupe rassemble les travaux pionniers visant à caractériser la vulnérabilité des aquifères à partir de proxys contextuels, avant l'usage systématique des méthodes d'ensemble pour la priorisation opérationnelle (section II.3.2). Les réseaux bayésiens (graphe orienté acyclique, DAG) y occupent une place centrale : ils se distinguent des méthodes discriminantes classiques par leur capacité à représenter des dépendances conditionnelles non monotones et à inférer avec des données manquantes ; pour une variable cible Y et un ensemble d'observations $\mathbf{e}$, la distribution a posteriori $P(Y | \mathbf{e})$ est calculée en marginalisant les variables non observées via la factorisation de Markov du DAG. Cette propriété est décisive en surveillance des PFAS, où les jeux de données sont structurellement incomplets (valeurs censurées, campagnes hétérogènes). Deux travaux non bayésiens (McMahon et al., Hu et al.) sont rattachés à ce groupe car ils partagent le même objectif de cartographie précoce de la vulnérabilité régionale ou nationale, distinct de la priorisation par classifieur d'ensemble.

II.3.1.1. Travaux de Li et MacDonald Gibson (2022)

Problème. Li et MacDonald Gibson [40] cherchent à prédire la présence des PFAS à chaîne courte (PFBS, PFBA, PFPeA et leurs précurseurs fluorotélomères) dans les eaux souterraines du Minnesota. Ces composés, substituts industriels aux PFAS à longue chaîne progressivement interdits, sont plus hydrophiles, plus mo-

biles en phase aqueuse et moins fréquemment mesurés dans les bases historiques, ce qui limite les approches purement supervisées.

Méthodologie. Les auteurs agrègent les données du programme de surveillance du Minnesota, recodent les valeurs sous le seuil de détection à LD/2 et standardisent 88 variables contextuelles couvrant : proximité aux sources industrielles (distance aux usines 3M de Cottage Grove et Oakdale), caractéristiques hydrogéologiques régionales, occupation du sol et co-contaminants inorganiques. La structure du DAG est apprise automatiquement par Hill Climbing avec score BIC.

Résultats. Les ROC-AUC dépassent 0,96 pour les composés les mieux représentés (PFOS, PFOA, PFHxS) et sont de l'ordre de 0,78 à 0,82 pour les composés à chaîne courte. Les arêtes les plus fortes du DAG relient le statut de contamination PFAS aux variables de proximité industrielle, relation médiée par les zones humides (bassins de rétention des composés PFAS transportés par ruissellement).

Limites. Le modèle est entraîné et validé exclusivement sur le Minnesota (transférabilité non validée). Le réseau bayésien infère la cible en marginalisant les variables non observées ; lorsque des mesures PFAS partielles figurent parmi les nœuds observés, leur contribution à la prédiction reste difficile à isoler sans protocole de division strict par site.

II.3.1.2. Travaux de McMahon et al. (2022)

Problème. McMahon et al. [41] cherchent à caractériser la distribution spatiale des concentrations PFAS dans les eaux souterraines potables de l'est des États-Unis à partir de proxies géochimiques, en s'affranchissant de mesures PFAS ciblées systématiques.

Méthodologie. Les auteurs mobilisent des arbres de régression boostés (BRT, variante de gradient boosting, section I.3.2.2) sur un corpus de plusieurs centaines d'échantillons géoréférencés. Les prédicteurs incluent la concentration en tritium (^3H), le carbone organique dissous (COD), la présence de solvants chlorés volatils (TCE, PCE) et divers indicateurs hydrogéologiques régionaux.

Résultats (approche descriptive). Le tritium, indicateur d'une recharge récente, est le prédicteur le plus fortement associé aux concentrations PFAS élevées : résultat mécanistiquement interprétable, les aquifères rechargés récemment ayant été en contact avec des eaux de surface potentiellement contaminées par les rejets industriels de la seconde moitié du XX^e siècle. Le COD et les solvants chlorés constituent également des co-prédicteurs significatifs, suggérant que les indicateurs in-

directs d'activité industrielle peuvent servir de proxys efficaces sans mesure PFAS directe.

Limites. Les auteurs ne fournissent pas de métriques quantitatives de classification ; le travail est davantage descriptif qu'opérationnel pour la priorisation directe des puits. Il n'est pas transposable tel quel à une démarche de priorisation sans étape de calibration quantitative supplémentaire.

II.3.1.3. Travaux de Hu et al. (2021)

Problème. Environ 43 millions d'Américains dépendent de puits privés qui échappent aux programmes de surveillance institutionnels. Hu et al. [42] cherchent à identifier ces puits à risque élevé à l'échelle nationale sans disposer d'aucune donnée analytique PFAS a priori.

Méthodologie. Les auteurs mobilisent uniquement des variables contextuelles disponibles sans campagne PFAS : densité d'installations militaires et aéronautiques dans un rayon de 20 km, proximité de stations d'épuration et de décharges, caractéristiques pédologiques. Ce protocole constitue un exemple référence de mode prédictif pur, sans aucune mesure PFAS en entrée.

Résultats (mode prédictif pur). Les auteurs produisent des cartes de vulnérabilité nationales permettant de prioriser les puits à contrôler. La démarche démontre qualitativement sa valeur pour orienter des campagnes d'information à grande échelle.

Limites. La validation externe reste absente ; l'incertitude sur les estimations n'est pas quantifiée. La couverture nationale introduit un lissage régional pouvant sous-représenter des aquifères spécifiques.

II.3.2. Méthodes d'ensemble pour la priorisation des puits

L'émergence des méthodes d'ensemble à base d'arbres (forêt aléatoire [20], XGBoost [22], LightGBM [23], section I.3.2.2) a élargi les capacités de priorisation à des corpus de plus grande taille. Quatre propriétés expliquent leur domination sur les jeux de données tabulaires de surveillance PFAS [24] : compatibilité native avec les données mixtes, robustesse aux valeurs manquantes par branches par défaut, interprétabilité par importances SHAP [29], et absence de nécessité de réglage d'architecture. Le déséquilibre structurel de classes impose l'usage systématique de SMOTE ou ADASYN [31, 32] : Dong et al. [6] montrent que le choix de la stratégie de rééchantillonnage et du ratio cible influence de 3 à 12 points de F1 sur la classe positive, rendant non comparables les études qui omettent de documenter ce protocole.

II.3.2.1. Travaux de George et Dixit (2021)

Problème. George et Dixit [38] proposent l'un des premiers cadres dédiés à la priorisation des puits de surveillance PFAS par apprentissage automatique, sur un corpus californien constitué à partir des bases publiques du California State Water Resources Control Board. L'objectif est de concevoir un outil capable d'orienter les prélèvements vers les sites à risque avant ou en complément des analyses de laboratoire.

Méthodologie. Les auteurs entraînent et comparent une forêt aléatoire et XGBoost sur des descripteurs couvrant la proximité aux sources (bases militaires, sites industriels, stations d'épuration, aéroports), les caractéristiques hydrogéologiques (type de lithologie, perméabilité, profondeur de crépine, type d'aquifère) et la qualité générale de l'eau (nitrates, sulfates, chlorures, TDS). Le déséquilibre est corrigé par SMOTE avant entraînement ; les performances sont évaluées par validation croisée stratifiée à 5 plis.

Résultats (mode mixte). La forêt aléatoire obtient une ROC-AUC d'environ 0,948 et un F1 d'environ 0,964 ; XGBoost atteint respectivement 0,906 et 0,878. L'analyse SHAP révèle que les variables de proximité aux bases militaires et aux installations fluorochimiques contribuent le plus à l'écart entre puits contaminés et non contaminés.

Limites. Les auteurs eux-mêmes signalent [38] qu'une fraction des observations inclut des mesures PFAS préalablement disponibles dans la base californienne, introduisant une composante confirmatoire partielle : les performances publiées ne reflètent pas nécessairement ce qui serait obtenu sur des puits jamais échantillonnés (cf. modes, section II.2.5).

II.3.2.2. Travaux de Tokranov et al. (2024)

Problème. Tokranov et al. [43] étendent la démarche à l'échelle nationale américaine, en s'appuyant sur les données géochimiques de l'USGS collectées entre 2019 et 2022. L'enjeu est d'estimer l'exposition de la population américaine à une échelle encore inatteignable par les études régionales.

Méthodologie. Un modèle XGBoost est entraîné sur plusieurs milliers d'échantillons géoréférencés avec des centaines de variables couvrant la géologie, l'hydrologie, l'occupation du sol, la proximité aux sources et la profondeur des puits. L'importance des variables est analysée par SHAP global et par permutation.

Résultats (mode mixte). Les résultats permettent d'estimer qu'entre 71 et 95 millions d'Américains dépendraient de sources d'eau souterraine avec des concentrations détectables de PFAS. L'analyse des importances classe en tête l'utilisation

des sols en zone urbaine, la profondeur de crépine, la densité de population et la distance aux aéroports et centres d'entraînement des pompiers. Ce classement est cohérent avec celui de George et Dixit, confirmant la robustesse du signal de proximité industrielle à travers des régions géologiquement très diverses.

Limites. La présence de mesures PFAS dans une fraction des données d'entraînement introduit une composante confirmatoire partielle dont l'impact en déploiement pur reste difficile à quantifier a posteriori. Le lissage de la résolution régionale par la grande hétérogénéité des aquifères nationaux constitue une limite supplémentaire pour les applications locales.

Le tableau V récapitule les performances de l'ensemble du groupe tabulaire, des approches probabilistes et de cartographie précoce (section II.3.1) aux méthodes d'ensemble présentées ci-dessus.

Table V – Performances du groupe tabulaire sur la prédiction/priorisation des PFAS. Les métriques proviennent des articles sources ; les protocoles diffèrent entre études. * : présence probable de concentrations PFAS mesurées parmi les features (composante confirmatoire partielle, cf. section II.2.5). n.r. : non renseigné (métrique non rapportée par les auteurs). Synthèse complète : voir Tab. VI.

Référence	Méthode	ROC-AUC	F1	Mode	Particularité
Li et al. [40]	Réseau bayésien	$\approx 0,78$ – 0,96	n.r.	Mixte	PFAS ch. courte, Minnesota
McMahon et al. [41]	BRT	(descriptif)	n.r.	Descriptif	Est États-Unis
Hu et al. [42]	Stats. contextuelles	(cartes)	n.r.	Prédictif pur	Puits privés USA
George et Dixit [38]	Forêt aléatoire	$\approx 0,948$	$\approx 0,964^*$	Mixte*	Californie
George et Dixit [38]	XGBoost	$\approx 0,906$	$\approx 0,878^*$	Mixte*	Californie
Tokranov et al. [43]	XGBoost	(national)	n.r.	Mixte*	Échelle nationale US

On observe que les scores les plus élevés ($F1 \approx 0,96$) sont obtenus dans des protocoles où des mesures analytiques PFAS peuvent figurer parmi les entrées, tandis que les approches purement contextuelles affichent des performances plus modestes mais opérationnellement plus représentatives.

II.3.3. Attribution des sources : une tâche diagnostique en aval de l'analyse

L'attribution de sources (*source apportionment*) exploite les profils multi-analytes pour allouer un échantillon contaminé à un type de source : mousses anti-incendie AFFF, rejets d'usines fluorochimiques, stations d'épuration. Cette tâche, qui pré-suppose des concentrations PFAS déjà connues et intervient donc en aval de l'analyse,

est incluse dans la revue parce qu'elle informe la sélection des variables de proximité dans les modèles de priorisation : les témoins chimiques caractéristiques de chaque type de source justifient l'usage de variables de proximité typées par catégorie d'installation.

II.3.3.1. Travaux de Kibbey et al. (2020)

Problème. Kibbey et al. [44] cherchent à identifier la source de contamination PFAS (AFFF, industrie fluorochimique, station d'épuration) à partir du profil analytique multi-composé d'un échantillon d'eau, sans nécessiter de modèle hydrogéologique.

Méthodologie. Les auteurs exploitent les empreintes chimiques des échantillons : les profils relatifs d'une cinquantaine de composés PFAS constituent un vecteur de caractéristiques multi-analytique. La pertinence de ce vecteur repose sur un fondement chimique : chaque type de source industrielle génère des profils PFAS spécifiques en termes de longueur de chaîne carbo-fluorée et de groupement fonctionnel terminal (sulfonate/carboxylate/phosphonate), partiellement conservés lors du transport en aquifère. Plusieurs algorithmes sont comparés (forêts aléatoires, SVM à noyau radial, classifieurs naïfs bayésiens), évalués par validation croisée à 10 plis.

Résultats (tâche diagnostique). Une précision d'attribution d'environ 90 % est obtenue pour distinguer entre sources AFFF, industrielles et diffuses ; ce résultat démontre que la diversité structurale des profils PFAS encode des informations diagnostiques robustes.

Limites. La qualité de l'attribution dépend du nombre d'analytes ciblés ; les mélanges de sources génèrent des vecteurs ambigus pour lesquels les classifieurs standard produisent des attributions incertaines.

II.3.3.2. Travaux de Dávila-Santiago et al. (2022)

Problème. Dávila-Santiago et al. [45] prolongent la démarche de Kibbey et al. vers l'attribution de sources à partir de données non ciblées (NTS, *non-target screening*) : sans viser a priori un ensemble défini d'analytes, les techniques d'analyse de masse haute résolution (HRMS) détectent des milliers de signaux chimiques dans un échantillon.

Méthodologie. Les auteurs développent un pipeline intégrant normalisation et filtrage des signaux HRMS, réduction de dimension par décomposition en valeurs singulières (SVD) et un classifieur de gradient boosting sur l'espace réduit. Le pipeline est appliqué sur des jeux de données californiens d'eau de surface et souterraine.

Résultats (tâche diagnostique). Des signatures liées aux sources AFFF, industrielles et agricoles restent identifiables même sans ciblage analytique : la démarche ouvre la voie à un criblage de surveillance à grande échelle moins coûteux qu’une analyse multi-résidus ciblée systématique.

Limites. Le pipeline dépend fortement de la résolution HRMS disponible. Sa généralisation à des contextes où seul un LC-MS/MS standard est disponible reste à évaluer.

II.4. Architectures profondes et relationnelles

Les méthodes tabulaires traitent chaque puits comme un point isolé dans un espace de features et ignorent la topologie du réseau de surveillance. Or, les panaches de PFAS s’étendent le long de lignes d’écoulement préférentielles : les puits situés dans le même cluster géographique ou en aval d’une même source partagent un contexte de contamination commun que les vecteurs indépendants ne peuvent pas capturer. Les architectures profondes ont émergé pour intégrer ces dépendances : d’abord sur des données moléculaires (QSAR), puis sous forme de chaînes semi-supervisées multi-analytes ; les graphes hétérogènes modélisant la structure relationnelle du système de surveillance constituent l’étape suivante de cette progression, encore peu explorée dans la littérature PFAS publiée (lacune L1, section II.5.3).

II.4.1. Réseaux de neurones sur données tabulaires et applications moléculaires

II.4.1.1. Travaux de Borisov et al. (2024)

Problème. Borisov et al. [24] évaluent empiriquement si les réseaux de neurones surpassent les arbres d’ensemble sur les jeux de données tabulaires de taille petite à moyenne : régime typique des corpus de surveillance environnementale, où quelques centaines à quelques dizaines de milliers d’observations analysées sont disponibles.

Méthodologie. Les auteurs réalisent un benchmark systématique comparant MLP génériques, TabNet [46] et SAINT [47] aux méthodes d’ensemble (forêt aléatoire, XGBoost) sur des jeux de données publics généraux et environnementaux, avec réglage soigneux des hyperparamètres pour toutes les architectures.

Résultats. Les méthodes d’ensemble à base d’arbres surpassent ou égalent les réseaux de neurones dans la grande majorité des benchmarks. Trois mécanismes

explicatifs sont identifiés : (i) les données tabulaires ne sont pas invariantes par transformation, rendant inutilisable le biais inductif local des convolutions ; (ii) les effets non-linéaires sont souvent locaux et discrets dans les données environnementales, ce que les arbres capturent par leur mécanisme de partitionnement récursif ; (iii) les perceptrons requièrent davantage de données pour généraliser. Par transposition au régime de données typique des corpus de surveillance PFAS comme EW3C00134 (environ 26 000 observations, dont seulement 2 600 à 3 000 étiquetées), ces résultats généraux indiquent que les architectures profondes tabulaires restent désavantagées par rapport à XGBoost dans ce régime partiellement étiqueté.

Limites. Ces résultats sont généraux et ne ferment pas la porte aux architectures spécialisées exploitant la structure relationnelle des données de surveillance.

II.4.1.2. Travaux de Cheng et Ng (2019)

Problème. Cheng et Ng [48] cherchent à prédire la bioactivité de plus de 3 400 composés PFAS répertoriés sur la liste OCDE sur 26 cibles biologiques (protéines, enzymes, récepteurs cellulaires), sans expérimentation animale systématique, dans le cadre d’une approche QSAR (*Quantitative Structure-Activity Relationship*).

Méthodologie. Les auteurs comparent des classifieurs classiques, des réseaux de neurones multitâches (*Multitask Neural Networks*, MNN) partageant des couches entre les 26 cibles, et des réseaux convolutifs sur graphes moléculaires (GCN). Les molécules sont encodées par des descripteurs physicochimiques : masse molaire, $\log P$, nombre d’atomes de fluor, longueur de chaîne carbo-fluorée, groupe fonctionnel terminal.

Résultats (QSAR moléculaire). Les MNN et GCN moléculaires obtiennent une précision équilibrée entre 70 et 80 % selon l’essai ciblé, et une AUC moyenne de 0,916 pour les meilleures architectures, surpassant les classifieurs classiques de 5 à 10 points. L’apprentissage multitâche se révèle particulièrement bénéfique : le partage de représentations entre plusieurs cibles compense le manque d’étiquettes pour les essais peu documentés.

Limites. Cette approche est moléculaire : elle prédit la bioactivité d’un composé PFAS, pas la contamination d’un puits de surveillance. Sa portée est avant tout méthodologique : elle illustre que l’apprentissage profond trouve un terrain favorable dès lors que la structure moléculaire peut être exploitée directement, ce qui explique l’intérêt des réseaux convolutifs sur graphes moléculaires (GCN) pour représenter les composés PFAS.

II.4.2. Apprentissage semi-supervisé multi-étiquettes : les travaux de Dong et al. (2024)

La prédiction simultanée de plusieurs dizaines d’analytes se heurte à deux contraintes structurelles. La première est la rareté des étiquettes : moins de 10 % des sites du corpus californien EW3C00134 disposent de mesures PFAS complètes pour les 35 analytes cibles [6] ; les 90 % restants constituent des données non étiquetées exploitables. La seconde est la corrélation inter-analytes : les différents composés PFAS ne sont pas statistiquement indépendants dans un même échantillon ; leur cooccurrence encode l’empreinte chimique de la source [9].

Les chaînes de classifieurs [49] capturent ces dépendances en prédisant les étiquettes séquentiellement :

$$\hat{y}_\ell = f_\ell(\mathbf{x}, \hat{y}_1, \dots, \hat{y}_{\ell-1}), \quad \ell = 1, \dots, L, \quad (\text{II.7})$$

où chaque classifieur f_ℓ utilise les prédictions précédentes comme variables supplémentaires. L’apprentissage semi-supervisé (section I.3.1.3) répond à la contrainte de rareté en générant des pseudo-étiquettes pour les observations non étiquetées dont la probabilité dépasse un seuil de confiance, puis en ré-entraînant sur le jeu élargi.

Problème. Dong et al. [6] cherchent à prédire, à partir de variables contextuelles exclusivement (sans concentration PFAS mesurée en entrée), deux cibles distinctes sur le corpus californien EW3C00134 : (i) le dépassement du seuil global de 70 ng/L (criblage binaire) et (ii) la présence de chacun des 35 analytes PFAS individuels au-delà de 2 ng/L (classification multi-étiquettes). Le corpus regroupe 26 000 observations géoréférencées issues de 23 sources publiques (programme GAMA, Geotracker, EPA, NOAA, SGMA, etc.) pour la période 2016–2022.

Corpus et features. Après nettoyage (suppression des variables avec plus de 40 % de valeurs manquantes), les 112 variables d’entrée couvrent six catégories : sources de contamination (nombre d’installations industrielles à 1, 3, 10 et 50 km), géospatial/date, qualité de l’air et météo (humidité, PM_{2,5}, NO₂, SO₂), sol (granulométrie, uniformité), hydrologie, et qualité de l’eau souterraine mesurée via des co-contaminants indicateurs (solvants chlorés, hydrocarbures aromatiques, nitrates). **Aucune concentration PFAS mesurée n’est incluse dans ces features.** Les coordonnées géographiques explicites (longitude, latitude, comté) sont volontairement exclues afin d’améliorer la généralisabilité spatiale du modèle.

Méthodologie. Le pipeline est organisé en deux tâches séquentielles (figure 9) :

1. **Tâche 1 – Criblage total.** Un classifieur binaire (forêt aléatoire avec sur-échantillonnage ADASYN) prédit si la somme des concentrations PFAS dé-

passé 70 ng/L ; la cible est dérivée des données de laboratoire disponibles, les 112 features contextuelles servant de seule entrée.

2. **Tâche 2 – Prédiction multi-analytes.** Les 35 analytes sont répartis en quatre classes selon leur taux de détection (Class 0 : $n > 25\,000$ obs. ; Class 3 : $n < 100$ obs.). Pour chaque classe :

- **Apprentissage semi-supervisé par pseudo-étiquetage** : un premier modèle est entraîné sur les puits étiquetés (PFAS mesuré) ; ses prédictions sur les puits non étiquetés (PFAS non mesuré) dont la probabilité dépasse 95 % de confiance sont réintégrées comme pseudo-étiquettes dans un second entraînement.
- **Chaînes de classifieurs XGBoost** (équation (II.7)) : les analytes sont ordonnés par sous-famille (PFCAs, fluorotélomères, PFSA, sulfonamides) puis par longueur de chaîne croissante ; chaque classifieur f_ℓ reçoit en entrée les 112 features contextuelles ainsi que les étiquettes prédites $\hat{y}_1, \dots, \hat{y}_{\ell-1}$ des analytes précédents. L'entrée supplémentaire de la chaîne est donc une prédiction de modèle, non une concentration PFAS mesurée.
- Sur-échantillonnage SMOTE (Task 2) sur le jeu d'entraînement uniquement.

Résultats. *Tâche 1* : la forêt aléatoire avec ADASYN atteint une ROC-AUC de 0,99, une exactitude de 96 % et un rappel de 95 % sur le jeu de test final, surpassant XGBoost (AUC 0,91) et tous les classifieurs linéaires (ce score doit être interprété avec la réserve du spatial data leakage identifié en lacune L2, section II.5.3). *Tâche 2* : la chaîne de classifieurs XGBoost est la méthode la plus performante pour l'ensemble des classes ; les ROC-AUC moyennes par classe sont 0,938 (Class 0), 0,965 (Class 1), 0,942 (Class 2) et 0,985 (Class 3) ; la valeur minimale individuelle est 0,729 (PFBA, analyte très rare). Le pseudo-étiquetage améliore l'AUC de Class 2 de +2,9 pp (gain négligeable pour Classes 1 et 3). Les sources de contamination (nombre d'installations à 1–50 km) et la granulométrie du sol dominent l'importance des variables pour les deux tâches ; un seul co-contaminant inorganique (nitrate) apparaît parmi les 20 variables les plus importantes.

Limites. L'apprentissage semi-supervisé ne se confond pas avec le mode confirmatoire : le pseudo-étiquetage gère la rareté des étiquettes sur des puits non analysés, mais les features restent purement contextuelles. La chaîne de classifieurs exploite des corrélations inter-analytes via des étiquettes prédites, non des concentrations mesurées ; l'évaluation reste proche du mode prédictif au sens de la section II.2.5. Les limites opérationnelles sont : (i) biais de sélection du programme

GAMA (sur-représentation des zones suspectes) ; (ii) division aléatoire 80/20 sans contrainte géographique, exposant à un **spatial data leakage** ; (iii) dégradation du pseudo-étiquetage en dessous de 100 exemples étiquetés (Class 3).




Figure 9 – Pipeline bi-tâche de Dong et al. [6]. La tâche 1 (criblage total) repose sur une forêt aléatoire avec sur-échantillonnage ADASYN ; la tâche 2 (prédiction des 35 analytes) enchaîne un pseudo-étiquetage semi-supervisé et une chaîne de classifieurs XGBoost. Les 112 variables contextuelles constituent l'unique entrée, sans aucune concentration PFAS mesurée.

On observe que les deux tâches partagent le même vecteur de variables contextuelles : la tâche 2 l'enrichit des seules étiquettes prédites par la chaîne, jamais de concentrations mesurées, ce qui maintient l'ensemble du dispositif dans le régime prédictif (section II.2.5).

II.5. Discussion

II.5.1. Tableau comparatif synthétique

Le tableau VI synthétise les travaux examinés selon leur mode d'évaluation dominant, leur tâche et leurs métriques.

On observe que les publications affichant les meilleurs scores ($F1 > 0,90$) mobilisent presque systématiquement des données analytiques PFAS dans leurs entrées. Deux travaux seulement (Hu et al. et Dong et al.) évaluent leur modèle en mode prédictif strict ; cette lacune de documentation n'est pas anodine : un praticien qui lit $F1 = 0,96$ dans un article peut croire disposer d'un outil opérationnel de priorisation avant analyse, alors qu'il s'agit en réalité d'un outil de complétude

Table VI – Synthèse comparative des approches de prédiction PFAS examinées. Les métriques proviennent des articles sources ; protocoles et corpus diffèrent entre études. * : présence de concentrations PFAS ou de signatures chimiques mesurées dans les features.

Référence	Méthode	Métrique	Mode	Tâche
Li et al. [40]	Réseaux bayésiens	AUC $\approx 0,78$ – 0,96	Mixte	PFAS ch. courte (MN)
Hu et al. [42]	Stats. con- textuelles	(cartes)	Prédictif pur	Vuln. puits privés
McMahon et al. [41]	BRT	(descriptif)	Descriptif	Profils régionaux
George & Dixit [38]	RF / XGBoost	F1 $\approx 0,96/0,88^*$	Mixte*	Priorisation bin. (CA)
Tokranov et al. [43]	XGBoost	(national)	Mixte*	Vuln. nationale US
Kibbey et al. [44]	ML supervisé	Préc. $\approx 90\%^*$	Diagnostic	Attribution sources
Dávila-Santiago et al. [45]	ML non ciblé	(relatif)	Diagnostic	NTS fingerprinting
Cheng et Ng [48]	QSAR/DNN	AUC moy. 0,916	Moléculaire	Bioactivité mol.
Dong et al. [6]	Semi-sup., CC	AUC 0,94– 0,99 (T1) ; 0,73–1,00 (T2)	Prédictif (ctx)	35 analytes (CA)

d'un profil analytique partiellement connu. Aucune étude publiée ne compare les deux modes sur le même corpus avec le même protocole de division par site.

II.5.2. Lecture transversale : convergences et enseignements

Trois enseignements transversaux ressortent de la lecture croisée des dix travaux.

La proximité industrielle est le signal le plus robuste. La proximité aux bases militaires, aux usines fluorochimiques et aux aéroports ressort en tête des variables explicatives dans des contextes géologiques très différents, qu'elle soit mesurée par les importances SHAP (George et Dixit, Tokranov, Dong et al.) ou par les arêtes du réseau bayésien (Li et al.). Ce résultat constitue un fondement solide pour la sélection des features contextuelles.

La complémentarité tabulaire/relationnelle est structurellement fondée.

L'exploitation de la structure relationnelle entre analytes améliore les scores par rapport aux modèles tabulaires indépendants : les chaînes de classifieurs de Dong et al. en fournissent la seule démonstration publiée sur les PFAS. La structure relationnelle entre puits voisins, attendue mécaniquement (section II.2.2), n'a en revanche pas encore été évaluée dans la littérature PFAS : les features contextuelles encodent le risque statique, tandis que la topologie d'écoulement, encore

inexploitée, encoderait la corrélation spatiale entre puits voisins et la proximité aux sources anthropiques.

Le mode d'évaluation conditionne les performances de façon fondamentale. Les études dont les features comprennent des concentrations PFAS mesurées publient des scores bien supérieurs ($F1 > 0,90$) à celles qui s'appuient exclusivement sur des variables contextuelles. Cette différence ne reflète pas un surcroît de qualité algorithmique : elle quantifie la valeur informative des mesures de laboratoire, et ne vaut que si l'on compare strictement le même modèle dans les deux modes sur un même ensemble de test.

II.5.3. Lacunes structurelles identifiées

L'examen croisé des travaux révèle quatre lacunes structurelles.

L1 – Structure relationnelle sous-exploitée. La majorité des études tabulaires ignore les liens entre puits voisins, panaches et sources communes. Les graphes hétérogènes [5] comblent partiellement ce vide, mais la sensibilité des performances aux choix de construction du graphe (seuil de distance pour les arêtes, nombre de types de nœuds, dimension de l'embedding) n'a pas fait l'objet d'une étude de sensibilité systématique dans la littérature publiée. La question de la sensibilité au seuil de distance et au nombre de types de nœuds reste ouverte.

L2 – Biais d'évaluation circulaire. Plusieurs publications présentent des scores très élevés ($F1 > 0,90$) sans préciser si des concentrations PFAS mesurées figurent dans les features [38]. Peu de travaux documentent simultanément les deux modes sur le même corpus ; aucune étude publiée ne compare les deux modes avec le même protocole de division strictement par site. La vérification de l'absence de fuite d'information entre variables contextuelles et concentrations PFAS est une étape méthodologique souvent omise.

L3 – Transférabilité géographique non validée. Les modèles sont entraînés et testés sur une seule région (Californie, Minnesota, est des États-Unis). Les validations croisées spatiales (entraînement sur un aquifère, test sur un autre de lithologie différente) restent pratiquement absentes. Pour les graphes hétérogènes, la question est architecturalement profonde : le graphe étant construit sur les nœuds d'entraînement, une approche inductive [25] (GraphSAGE) serait requise pour généraliser à des nœuds non vus.

L4 – Interprétabilité insuffisamment standardisée. Si SHAP [29] s'impose progressivement comme standard, les protocoles varient fortement entre études. Les pipelines hybrides graphe et boosting soulèvent des questions spécifiques non encore codifiées : comment interpréter la contribution d'un embedding HGT agrégeant l'information de dizaines de nœuds voisins ? Comment comparer des valeurs Tree-SHAP exactes (XGBoost, LightGBM) à des estimations SHAP Kernel approximations (HGT) ? Une variable tabulaire fortement corrélée à HGT_emb_0 verra sa valeur SHAP individuelle réduite par interaction, rendant son importance marginale sous-estimée.

Remarque sur le périmètre géographique de la revue. L'ensemble des travaux examinés porte sur des aquifères nord-américains ; aucune étude comparable mobilisant l'apprentissage automatique sur des données PFAS européennes ou africaines n'a été identifiée dans la littérature publiée. Cette limitation intrinsèque de la revue mérite d'être signalée : les enseignements sur les variables prédictives et les architectures restent transposables, mais les seuils réglementaires (directive UE 2020/2184 [30] vs EPA 2023 [15]), les contextes géologiques et les pratiques de surveillance diffèrent sensiblement.

Le tableau VII positionne les principales contributions au regard de ces cinq lacunes.

Table VII – Positionnement des principales contributions au regard des cinq lacunes identifiées.

● : lacune adressée ; ○ : partiellement adressée ; × : non adressée. L1 : structure relationnelle ; L2 : biais confirmatoire ; L3 : transfert géographique ; L4 : interprétabilité standardisée.

Référence	L1	L2	L3	L4
Li et al. [40]	×	○	×	×
George et Dixit [38]	×	×	×	○
McMahon et al. [41]	×	○	○	×
Tokranov et al. [43]	×	○	●	○
Dong et al. [6]	×	×	×	○

On observe qu'aucun travail de la littérature n'adresse simultanément L1, L2 et L4 : les études tabulaires ignorent la structure relationnelle ; celles qui exploitent un graphe ne documentent pas le mode prédictif strict ; l'interprétabilité reste non standardisée. La combinaison de ces lacunes, en particulier la validation inter-aquifères (L3) définit autant de directions de recherche encore ouvertes.

II.6. Synthèse

Ce chapitre a dressé un panorama structuré de l'application de l'intelligence artificielle à la prédiction et à la surveillance des PFAS en eaux souterraines. La première génération (modèles probabilistes et arbres d'ensemble) a établi le socle des variables prédictives (proximité aux sources, indicateurs hydrogéologiques, co-contaminants) et démontré la faisabilité de la priorisation régionale et nationale. La deuxième (réseaux de neurones, puis chaînes semi-supervisées multi-étiquettes) a étendu le champ à plusieurs dizaines d'analytes et exploité les données non étiquetées, sans toujours expliciter le régime d'évaluation retenu.

Les lacunes L1–L4 dessinent en creux un système idéal de priorisation : fonctionnant sans mesure PFAS préalable (mode prédictif pur), intégrant les relations spatiales par un graphe hétérogène, interprétable par SHAP globale et locale, et validé sur une division spatiale indépendante. Aucune étude publiée ne satisfait simultanément ces critères.

III

CHAPTER

FUSION CONSENSUELLE DES MISES À JOUR DES RÉPLIQUES PARTIELLES

CONCLUSION GÉNÉRALE

CONTENTS

La problématique étudiée et les choix méthodologiques	53
Analyse critique des résultats obtenus	53
Quelques perspectives	53

Le bilan...

La problématique étudiée et les choix méthodologiques

Nous...

Analyse critique des résultats obtenus

Sachant...

Quelques perspectives

Ce travail...

BIBLIOGRAPHY

- [1] Veille Données de Santé (Université de Strasbourg). Per- et polyfluoroalkylés : introduction; 2025. Carnet de recherche Hypothèses. Available from: <https://vds.hypotheses.org/6348>.
- [2] Figures sur les voies d'exposition et les effets sanitaires des PFAS; 2024. Figures reproduites pour usage pédagogique ; référence bibliographique complète à préciser. Food and Chemical Toxicology (Elsevier). Available from: <https://www.sciencedirect.com/science/article/pii/S0007996024001639>.
- [3] Janosh. Random forest (TikZ illustration); 2024. Illustration sous licence CC BY 4.0. tikz.net. Available from: <https://tikz.net/random-forest/>.
- [4] Verma A. XGBoost: a deep dive into boosting; 2020. Figure pédagogique sur le principe du boosting. Medium (SFU CSPMP). Available from: <https://medium.com/sfu-csmp/xgboost-a-deep-dive-into-boosting-f06c9c41349>.
- [5] Hu Z, Dong Y, Wang K, Sun Y. Heterogeneous Graph Transformer. In: Proceedings of The Web Conference 2020; 2020. p. 2704-10.
- [6] Dong J, Tsai G, Olivares CI. Prediction of 35 Target Per- and Polyfluoroalkyl Substances (PFASs) in California Groundwater Using Multilabel Semisupervised Machine Learning. ACS ES&T Water. 2024;4(3):969-80.
- [7] Badouel E, Tchoupi M. Merging hierarchically structured documents in workflow systems. In: Proceedings of the Ninth Workshop on Coalgebraic Methods in Computer Science (CMCS 2008), Budapest. Electronic Notes in Theoretical Computer Science. vol. 203; 2008. p. 3-24.
- [8] Glüge J, Scheringer M, Cousins IT, DeWitt JC, Goldenman G, Herzke D, et al. An overview of the uses of per- and polyfluoroalkyl substances (PFAS). Environmental Science: Processes & Impacts. 2020;22(12):2345-73.

- [9] Prevedouros K, Cousins IT, Buck RC, Korzeniowski SH. Sources, fate and transport of perfluorocarboxylates. *Environmental Science & Technology*. 2006;40(1):32-44.
- [10] Brusseau ML, Yan N, Van Glubt S, et al. Comprehensive retention model for PFAS transport in subsurface systems. *Water Research*. 2019;148:41-50.
- [11] Hu XC, Andrews DQ, Lindstrom AB, et al. Detection of poly- and perfluoroalkyl substances (PFASs) in U.S. drinking water linked to industrial sites, military fire training areas, and wastewater treatment plants. *Environmental Science & Technology Letters*. 2016;3(10):344-50.
- [12] Guelfo JL, Korzeniowski S, Mills MA, et al. Environmental sources, chemistry, fate, and transport of per- and polyfluoroalkyl substances: State of the science. *Environmental Toxicology and Chemistry*. 2021;40(12):3234-60.
- [13] Sunderland EM, Hu XC, Dassuncao C, et al. A review of the pathways of human exposure to poly- and perfluoroalkyl substances (PFASs) and present understanding of health effects. *Journal of Exposure Science & Environmental Epidemiology*. 2019;29:131-47.
- [14] U S Environmental Protection Agency. Drinking Water Health Advisory for PFOA and PFOS; 2016. Recommendation sanitaire ; seuil combiné de 70 ng/L. Available from: <https://www.epa.gov/ground-water-and-drinking-water/drinking-water-health-advisories-pfoa-and-pfos>.
- [15] U S Environmental Protection Agency. PFAS National Primary Drinking Water Regulation; 2024. Règlement national ; MCL de 4 ng/L pour PFOA et PFOS pris séparément. Available from: <https://www.epa.gov/sdwa/and-polyfluoroalkyl-substances-pfas>.
- [16] World Health Organization. Guidelines for Drinking-Water Quality: Fourth Edition Incorporating the First and Second Addenda. Geneva: World Health Organization; 2022.
- [17] Mitchell TM. Machine Learning. McGraw-Hill; 1997.
- [18] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. Springer; 2009.
- [19] Sutton RS, Barto AG. Reinforcement Learning: An Introduction. 2nd ed. MIT Press; 2018.

- [20] Breiman L. Random forests. *Machine Learning*. 2001;45(1):5-32.
- [21] Friedman JH. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*. 2001;29(5):1189-232.
- [22] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*; 2016. p. 785-94.
- [23] Ke G, Meng Q, Finley T, Wang T, Chen W, Ma W, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In: *Advances in Neural Information Processing Systems 30*; 2017. p. 3146-54.
- [24] Borisov V, Leemann T, Seßler K, et al. Deep neural networks and tabular data: A survey. *IEEE Transactions on Neural Networks and Learning Systems*. 2024:1-21.
- [25] Hamilton WL, Ying R, Leskovec J. Inductive Representation Learning on Large Graphs. In: *Advances in Neural Information Processing Systems (NeurIPS)*. vol. 30; 2017. p. 1024-34. GraphSAGE : agrégation inductive pour la généralisation à des nœuds non vus.
- [26] Kipf TN, Welling M. Semi-Supervised Classification with Graph Convolutional Networks. In: *International Conference on Learning Representations*; 2017. .
- [27] Fey M, Lenssen JE. Fast graph representation learning with PyTorch Geometric; 2019. arXiv:1903.02428.
- [28] Ribeiro MT, Singh S, Guestrin C. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM; 2016. p. 1135-44.
- [29] Lundberg SM, Lee SI. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems 30*; 2017. p. 4765-74.
- [30] European Parliament and Council. Directive (EU) 2020/2184 on the quality of water intended for human consumption (recast); 2020. Official Journal of the European Union, L 435/1, 23 December 2020. Limites : 0,1 $\mu\text{g/L}$ par substance PFAS individuelle ; 0,5 $\mu\text{g/L}$ pour la somme.

- [31] Chawla NV, Bowyer KW, Hall LO, Kegelmeyer WP. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*. 2002;16:321-57.
- [32] He H, Bai Y, Garcia EA, Li S. ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. In: *Proceedings of the IEEE International Joint Conference on Neural Networks*; 2008. p. 1322-8.
- [33] Sokolova M, Lapalme G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*. 2009;45(4):427-37.
- [34] Chicco D, Jurman G. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*. 2020;21(1):6.
- [35] Fawcett T. An introduction to ROC analysis. *Pattern Recognition Letters*. 2006;27(8):861-74.
- [36] Davis J, Goadrich M. The relationship between Precision-Recall and ROC curves. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*. ACM; 2006. p. 233-40.
- [37] Saito T, Rehmsmeier M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*. 2015;10(3):e0118432.
- [38] George S, Dixit A. A machine learning approach for prioritizing groundwater testing for per- and polyfluoroalkyl substances (PFAS). *Journal of Environmental Management*. 2021;295:113359.
- [39] He H, Garcia EA. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*. 2009;21(9):1263-84.
- [40] Li R, MacDonald Gibson J. Predicting the occurrence of short-chain PFAS in groundwater using machine-learned Bayesian networks. *Frontiers in Environmental Science*. 2022;10:958784.
- [41] McMahon PB, Tokranov AK, Bexfield LM, et al. Perfluoroalkyl and polyfluoroalkyl substances in groundwater used as a source of drinking water in the eastern United States. *Environmental Science & Technology*. 2022;56(4):2279-88.

- [42] Hu XC, Ge B, Ruyle BJ, Sun J, Sunderland EM. A statistical approach for identifying private wells susceptible to perfluoroalkyl substances (PFAS) contamination. *Environmental Science & Technology Letters*. 2021;8(7):596-602.
- [43] Tokranov AK, Bexfield LM, Dupuy C, McMahon PB, et al. Predictions of groundwater PFAS occurrence at drinking-water supply depths in the contiguous United States. *Environmental Science & Technology*. 2024. Données associées : USGS data release <https://doi.org/10.5066/P13MQIVR>.
- [44] Kibbey TCG, Jabrzemski R, O'Carroll DM. Supervised machine learning for source allocation of per- and polyfluoroalkyl substances (PFAS) in environmental samples. *Chemosphere*. 2020;252:126593.
- [45] Dávila-Santiago E, Shi C, Mahadwar G, et al. Machine learning applications for chemical fingerprinting and environmental source tracking using non-target chemical data. *Environmental Science & Technology*. 2022;56(7):4080-90.
- [46] Arik SÖ, Pfister T. TabNet: Attentive Interpretable Tabular Learning. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. vol. 35; 2021. p. 6679-87.
- [47] Somepalli G, Goldblum M, Schwarzschild A, Bruss CB, Goldstein T. SAINT: Improved Neural Networks for Tabular Data via Row Attention and Contrastive Pre-Training. In: *Workshop on Self-Supervised Learning for Reasoning and Perception (NeurIPS 2021)*; 2021. ArXiv:2106.01342.
- [48] Cheng W, Ng CA. Using machine learning to classify bioactivity for 3486 per- and polyfluoroalkyl substances (PFASs) from the OECD list. *Environmental Science & Technology*. 2019;53(23):13970-80.
- [49] Read J, Pfahringer B, Holmes G, Frank E. Classifier chains for multi-label classification. *Machine Learning*. 2011;85(3):333-59.



UN AUTRE EXEMPLE COMPLET DE FUSION CONSENSUELLE

Dans cette annexe...

Les schémas des règles de transition

Rappelons que les schémas des transitions (complétés pour prendre en compte les documents non clos) de l'automate permettant de représenter les expansions des répliques partielles suivant la vue $\mathcal{V}_1 = \{A, B\}$ lorsqu'on associe les symboles de Dyck '(' et ')' (resp. '[' et ']') au symbole visible A (resp. B) et qu'on associe les symboles ' $(_\omega$ ' et ' $)_\omega$ ' (resp. ' $[_\omega$ ' et ' $]_\omega$ ') au bourgeon A_ω (resp. B_ω) de type A (resp. B), sont les suivants:

De même...

Table VIII – Les schémas des règles de transition pour notre exemple

$\langle A, w_1 \rangle \longrightarrow$	$(P_1, [\langle C, u \rangle, \langle B, v \rangle])$	si $w_1 = u[v]$
$\langle A, w_2 \rangle \longrightarrow$	$(P_1, [\langle C, u \rangle, \langle B, w_{11} \rangle])$	si $w_2 = uw_{11}$ avec $w_{11} = [_\omega]_\omega$
$\langle A, w_3 \rangle \longrightarrow$	$(P_2, [])$	si $w_3 = \varepsilon$
$\langle A, w_4 \rangle \longrightarrow$	$(A_\omega, [])$	si $w_4 = (_\omega)_\omega$
$\langle B, w_5 \rangle \longrightarrow$	$(P_3, [\langle C, u \rangle, \langle A, v \rangle])$	si $w_5 = u(v)$
$\langle B, w_6 \rangle \longrightarrow$	$(P_3, [\langle C, u \rangle, \langle A, w_4 \rangle])$	si $w_6 = uw_4$
$\langle B, w_7 \rangle \longrightarrow$	$(P_4, [\langle B, u \rangle, \langle B, v \rangle])$	si $w_7 = [u][v]$
$\langle B, w_8 \rangle \longrightarrow$	$(P_4, [\langle B, w_{11} \rangle, \langle B, v \rangle])$	si $w_8 = w_{11}[v]$
$\langle B, w_9 \rangle \longrightarrow$	$(P_4, [\langle B, u \rangle, \langle B, w_{11} \rangle])$	si $w_9 = [u]w_{11}$
$\langle B, w_{10} \rangle \longrightarrow$	$(P_4, [\langle B, w_{11} \rangle, \langle B, w_{11} \rangle])$	si $w_{10} = w_{11}w_{11}$
$\langle B, w_{11} \rangle \longrightarrow$	$(B_\omega, [])$	si $w_{11} = [_\omega]_\omega$
$\langle C, w_{12} \rangle \longrightarrow$	$(P_5, [\langle A, u \rangle, \langle C, v \rangle])$	si $w_{12} = (u)v$
$\langle C, w_{13} \rangle \longrightarrow$	$(P_5, [\langle A, w_4 \rangle, \langle C, v \rangle])$	si $w_{13} = w_4v$
$\langle C, w_{14} \rangle \longrightarrow$	$(P_6, [\langle C, u \rangle, \langle C, v \rangle])$	si $w_{14} = uv \neq \varepsilon$
$\langle C, w_{15} \rangle \longrightarrow$	$(C_\omega, [])$	si $w_{15} = \varepsilon$



APPENDIX

QUELQUES FONCTIONS HASKELL POUR LE CALCUL DES CONSENSUS

Dans cette annexe...

Représentation des grammaires et des vues

Une grammaire est constituée d'un ensemble de symboles et d'un ensemble de productions. Nous représentons une grammaire par le type `Gram` suivant:

```
1 data Gram prod symb = Gram {prods::[prod],
2                               symbols::[symb],
3                               lhs::prod -> symb,
4                               rhs::prod -> [symb]}
```

La fonction `lhs` (resp. `rhs`) prend en argument une grammaire `G` et une production `p` de `G` puis retourne le symbole en partie gauche (resp. la liste des symboles en partie droite) de `p`. À partir de ce type, on peut construire la grammaire $\mathbb{G}_{expl}$ (chap ?? exemple ??) grâce au code Haskell suivant:

```
1 data Prod = P1 | P2 | P3 | P4 | P5 | P6 | P7 | Aomega | Bomega | Comega
2           deriving (Eq, Show)
3 data Symb = A | B | C deriving (Eq, Show)
4
5 gram :: Gram Prod Symb
6 gram = Gram lprod lsymb lhs_ rhs_
7   where
8     lprod = [P1, P2, P3, P4, P5, P6, P7]
9     lsymb = [A, B, C]
10    lhs_ p = case p of
11      P1 -> A; P2 -> A; P3 -> B; P4 -> B; P5 -> C; P6 -> C; P7 -> C
12    rhs_ p = case p of
13      P1 -> [C, B]; P2 -> []; P3 -> [C, A]; P4 -> [B, B];
14      P5 -> [A, C]; P6 -> [C, C]; P7 -> []
```

Les productions Aomega, Bomega et Comega ont été introduites pour pouvoir désigner les bourgeons de types respectifs A, B et C.