

**RÉPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON**

**PAIX - TRAVAIL - PATRIE
PEACE - WORK - FATHERLAND**

**UNIVERSITÉ DE DSCHANG
UNIVERSITY OF DSCHANG**

ÉCOLE DES SCIENCES ET TECHNOLOGIES DE DSCHANG

**UNITÉ DE RECHERCHE EN INFORMATIQUE
FONDAMENTALE,
INGÉNIERIE ET APPLICATION (URIFIA)**

THÈME :

**Prédiction par intelligence artificielle des contaminants émergents des
eaux :**

étude de cas sur la détection des PFAS et l'évaluation des risques

Mémoire présenté en vue de l'obtention du diplôme de
Master en Informatique

Option : **Informatique Fondamentale**
Spécialisation : **Intelligence Artificielle**

Par

DNJOMOU YONMBA Wilfried Loïc

Matricule : CM-UDS-24SCI0999

Licence de technologie en conception, développement, réseaux et Internet

Sous la direction de :

Pr BOMGNI Alain Bertrand
Professeur Titulaire, Université de Dschang

Année académique 2025/2026

CERTIFICATION

Je soussigné, **DNJOMOU YONMBA Wilfried Loïc**, étudiant en Master, option Intelligence Artificielle, au Département de Mathématiques et Informatique, matricule **CM-UDS-24SCI0999**, Faculté des Sciences, Université de Dschang, certifie que les présents travaux de recherche intitulés « Prédiction par intelligence artificielle des contaminants émergents des eaux : étude de cas sur la détection des PFAS et l'évaluation des risques », réalisés au sein de l'Unité de Recherche URIFIA de l'Université de Dschang, sous la direction de **Pr BOMGNI Alain Bertrand**, Professeur Titulaire, Université de Dschang, sont le fruit de mes propres travaux de recherche.

Cela n'a jamais été publié auparavant pour l'obtention d'un diplôme.

L'étudiant

Le superviseur

**DNJOMOU YONMBA Wilfried
Loïc**

Date : _____

Pr BOMGNI Alain Bertrand

Date : _____

DÉDICACE

À mon père YONMBA RICHARD et à ma mère DJEUMEN LUCIE CLAIRE.

REMERCIEMENTS

Alors...

- Au Dr...;
- À...;

TABLE DES MATIÈRES

LIST OF SYMBOLS

$\mathbb{G}$	A grammatical model of workflow;
t_{i_f}	A global artefact obtained after merging a set of artefacts.

LIST OF ACRONYMS

PFAS	Substances per- et polyfluoroalkylées ;
EPA	Environmental Protection Agency (États-Unis) ;
PFOA	Acide perfluorooctanoïque ;
PFOS	Sulfonate de perfluorooctane ;
PFCA	Acides perfluorocarboxyliques ;
PFSA	Acides perfluoroalkylsulfoniques ;
AFFF	Mousse anti-incendie à film aqueux ;
GNN	Graph Neural Network ;
HGT	Heterogeneous Graph Transformer ;
PyG	PyTorch Geometric ;
GCN	Graph Convolutional Network ;
SMOTE	Synthetic Minority Over-sampling Technique ;
ADASYN	Adaptive Synthetic Sampling ;
SHAP	SHapley Additive exPlanations ;
ROC-AUC	Aire sous la courbe ROC ;
GAMA	Groundwater Ambient Monitoring and Assessment ;
QSAR	Quantitative Structure-Activity Relationship (relation structure-activité quantitative).

LIST OF TABLES

LIST OF FIGURES

RÉSUMÉ

Le travail réalisé dans ce mémoire...

Mots clés: Documents structurés, Workflow d'édition Coopérative, Fusion des répliques partielles, Conflits, Consensus, Automates d'arbre, Produit d'automates, Évaluation paresseuse, TinyCE v2.

AI-POWERED PREDICTION OF EMERGING WATER CONTAMINANTS: A CASE STUDY IN PFAS DETECTION AND RISK ASSESSMENT

ABSTRACT

The work presented ...

Keywords: Structured documents, Workflow of cooperative edition, Merging partial replicas, Conflict, Consensus, Tree automata, Automata product, Lazy evaluation, TinyCE v2.

INTRODUCTION

CONTENTS

Le contexte du travail	1
La problématique étudiée	1

Le contexte du travail

La coopération et la collaboration ...

Les documents structurés

gjfjh...

L'édition coopérative des documents structurés

Le processus [?] consiste...

La problématique étudiée

Pendant la...

I

CHAPTER

GÉNÉRALITÉS SUR LES PFAS ET L'INTELLIGENCE ARTIFICIELLE

SOMMAIRE

I.1 - Introduction	2
I.2 - Les substances per- et polyfluoroalkylées (PFAS)	3
I.3 - Apprentissage automatique et méthodes d'ensemble	11
I.4 - Généralités sur les graphes et l'apprentissage profond	19
I.5 - Interprétabilité des modèles	24
I.6 - Synthèse	29

I.1. Introduction

La surveillance de la qualité des eaux souterraines est confrontée à l'émergence de contaminants persistants, parmi lesquels les substances per- et polyfluoroalkylées (PFAS) occupent une place particulière par leur stabilité chimique, leur mobilité et la diversité de leurs usages. Dans le même temps, le développement de l'**intelligence artificielle** et de l'**apprentissage automatique** (*machine learning*, ML) fournit des outils puissants pour analyser des volumes importants de données environnementales, combiner des sources d'information hétérogènes et appuyer la prise de décision. Ce premier chapitre a pour objectif de réunir les **notions fondamentales** qui seront mobilisées dans la suite du mémoire. Nous y présentons d'abord le contexte des PFAS : définition, propriétés physicochimiques, principaux usages, sources de contamination, devenir environnemental, enjeux de surveillance des eaux souterraines et cadre réglementaire (section ??). Nous introduisons ensuite les paradigmes de l'apprentissage automatique, l'évaluation des classifieurs,

le bagging, le boosting, le stacking et la gestion du déséquilibre de classes (section ??), puis les **graphes** et les réseaux de neurones sur graphes, en particulier les graphes hétérogènes et le Heterogeneous Graph Transformer (section ??). Enfin, nous présentons les principaux outils d'**interprétabilité** des modèles, avec un accent sur l'approche SHAP (section ??), afin de préparer l'analyse des résultats qui sera menée dans les chapitres suivants.

I.2. Les substances per- et polyfluoroalkylées (PFAS)

Les PFAS occupent une place à part parmi les contaminants de l'eau : leur persistance, leur mobilité et le nombre très élevé de composés potentiels compliquent la surveillance classique. Cette section en présente la **définition**, les **propriétés physicochimiques**, les **usages** à l'origine des rejets, le **devenir** dans l'environnement (sources et transport), les enjeux de **surveillance des eaux souterraines**, puis les **risques sanitaires** et le **cadre réglementaire**.

I.2.1. Définition et propriétés physicochimiques

I.2.1.1. Une famille chimique vaste et hétérogène

Les **substances per- et polyfluoroalkylées** (PFAS, *per- and polyfluoroalkyl substances*) désignent une famille de composés organiques de synthèse dont le nombre exact dépasse largement quelques centaines de molécules : les inventaires réglementaires et scientifiques recensent de l'ordre de **4 000 à plus de 10 000** structures selon les critères d'inclusion retenus [?]. Toutes partagent l'idée d'une chaîne carbonée aliphatique dont une partie des atomes d'hydrogène est remplacée par du **fluor**.

Historiquement, une définition de référence exigeait la présence d'un groupement **perfluoroalkylé** saturé en fluor. L'Organisation de coopération et de développement économiques (OCDE) a ensuite élargi le champ à toute substance contenant au moins un groupement méthylène ou méthyle **entièrement fluoré**, afin d'intégrer des molécules utilisées dans des filières récentes (semi-conducteurs, batteries, matériaux haute performance). Le terme **PFAS** fonctionne ainsi comme un **parapluie réglementaire et analytique**, et non comme le nom d'un produit unique.

I.2.1.2. La liaison carbone–fluor et la persistance

La liaison **carbone–fluor** (C–F) est l'une des plus fortes de la chimie organique (de l'ordre de 485 kJ/mol). Elle confère aux molécules une inertie remarquable

face à la chaleur, aux oxydants et aux enzymes microbiennes. C'est ce qui justifie le surnom de *polluants éternels* : contrairement à de nombreux hydrocarbures, les PFAS ne sont pas facilement **biodégradés** dans les conditions naturelles [?]. Leur présence dans les sols, les eaux et certains biotes peut donc se prolonger **décennies** après l'arrêt des émissions à la source.

On oppose en pratique :

- les composés **perfluoroalkylés** : la chaîne est saturée en fluor (hors groupe fonctionnel) ;
- les composés **polyfluoroalkylés** : la fluorination est partielle ; ils peuvent se transformer en dérivés plus persistants, appelés **précurseurs**.

Les composés historiques à **chaîne longue** (souvent $\geq 6-8$ atomes de carbone pour les PFCA) comme le PFOA ou le PFOS ont été massivement produits à partir des années 1950. Sous pression réglementaire, l'industrie s'est orientée vers des **chaînes courtes** (C4–C6), présentées comme des alternatives ; celles-ci restent toutefois mobiles et persistantes dans l'environnement.

1.2.1.3. Groupes fonctionnels, tensioactivité et rétention dans les sols

Selon le **groupe fonctionnel** terminal, on classe notamment :

- les **acides perfluorocarboxyliques** (PFCA), par exemple l'acide perfluorooctanoïque (PFOA) ;
- les **acides perfluoroalkylsulfoniques** (PFSA), par exemple le sulfonate de perfluorooctane (PFOS).

Le tableau ?? illustre d'autres familles courantes.

Table I – Principales classes de PFAS et propriétés associées (synthèse pédagogique).

Classe	Groupe	Exemple	Propriété dominante
PFCA	Carboxylate	PFOA (C8)	Persistance, adsorption sur sols
PFSA	Sulfonate	PFOS (C8)	Tensioactivité, stabilité
Fluorotélomères	Alcools, sulfonates	6:2 FTS	Précurseur de PFCA
PFPE	Éther perfluoré	Lubrifiants	Résistance thermique

Les PFAS sont **amphiphiles** : une chaîne fluorée hydrophobe et lipophobe est reliée à une tête polaire hydrophile. Cette structure explique leur efficacité comme **tensioactifs** (réduction de la tension superficielle), notamment dans les mousses

anti-incendie, et leur tendance à s'accumuler aux **interfaces** air-eau et solide-eau en zone non saturée [?].

La figure ?? illustre la structure d'un PFAS non polymérique, le sulfonate de perfluorooctane (PFOS).




Figure 1 – Représentation schématique du PFOS (acide perfluorooctanesulfonique, $C_8F_{17}SO_3H$ ou $C_8F_{17}SO_3^-$). Source : adapté de [?].

On observe que la chaîne perfluorée (queue) et le groupe sulfonate (tête polaire) matérialisent la structure amphiphile évoquée ci-dessus et expliquent la persistance ainsi que la tensioactivité du composé.

La **longueur de chaîne** modifie la solubilité, la mobilité et la bioaccumulation : les chaînes courtes se déplacent plus facilement dans l'eau ; les chaînes longues sont davantage retenues par les matières organiques du sol et les protéines.

1.2.2. Usages industriels et voies de rejet

Les PFAS ne sont pas des polluants accidentels ponctuels : ils résultent de **choix industriels** répétés sur plus de soixante ans. Leur combinaison de répellence (eau, graisses), de stabilité thermique et de faible friction a conduit à de nombreuses applications [?] :

- **Textiles et habillement** : imperméabilité, résistance aux taches ;
- **Emballages alimentaires** et papier traité : barrière à l'huile et à l'eau ;
- **Mousses anti-incendie** pour feux d'hydrocarbures (films aqueux AFFF) ;
- **Industrie chimique et électronique** : fluides de procédé, lubrifiants, revêtements ;

- **Cosmétiques et produits d'entretien** : certains composés sont aujourd'hui progressivement interdits ou restreints selon les juridictions.

À chaque **cycle de vie** (fabrication, utilisation, traitement des déchets), une fraction des PFAS peut être rejetée dans l'air, l'eau ou les sols. Les procédés de traitement classiques des eaux usées ou des lixiviats de décharges ne sont généralement pas conçus pour **casser** la liaison C–F : une partie des composés traverse les stations et retourne vers les milieux naturels [?, ?].

I.2.3. Sources, transport et devenir environnemental

I.2.3.1. Typologie des sources de contamination

On classe couramment les sources selon leur intensité et leur localisation :

1. **Sources ponctuelles industrielles** : usines de synthèse ou de transformation de produits fluorés, rejets historiques stockés dans les sols ;
2. **Sites militaires et aéroportuaires** : entraînements au feu avec mousses AFFF, souvent identifiés comme **hotspots** de contamination des nappes ;
3. **Sources diffuses** : stations d'épuration, sites d'enfouissement, ruissellement urbain transportant des résidus de produits de consommation.

Des études à l'échelle régionale ont montré une association statistique entre la présence de PFAS dans l'eau potable et la proximité d'installations industrielles, de bases militaires ou de stations d'épuration [?]. La mousse **AFFF** mérite une attention particulière : développée pour éteindre les feux de carburant, elle a été déployée à grande échelle sur les aérodromes et casernes ; les mélanges infiltrés dans le sol peuvent alimenter des panaches souterrains durables.

I.2.3.2. Mécanismes de transport dans l'air, le sol et l'eau

Une fois rejetés, les PFAS suivent des trajectoires **couplées** :

- **Eaux souterraines** : transport principalement **advectif** avec le flux de la nappe ; la vitesse dépend de la conductivité hydraulique, de la porosité, du gradient hydraulique et du degré de rétention sur les sols (matière organique, minéraux) [?].
- **Zone vadose** (non saturée) : accumulation possible aux interfaces air–eau, formant un **réservoir** libéré progressivement lors des pluies ;

- **Atmosphère** : certains précurseurs volatils (fluorotélomères) peuvent être transportés sur de longues distances avant dépôt sec ou humide, contribuant à une contamination **ubiquitaire** même loin des sites industriels [?].

Sur des aquifères perméables à faible teneur en carbone, des panaches de plusieurs **kilomètres** ont été décrits en aval de sources ponctuelles. Le comportement ne se réduit donc pas à une dilution immédiate : la persistance et la mobilité conjointes expliquent l'étendue spatiale des problèmes.

I.2.3.3. Le schéma source, voie et récepteur

En évaluation des risques environnementaux, le devenir des PFAS est souvent représenté par le modèle **source, voie et récepteur** :

- **Source** : activité humaine qui émet les PFAS (usine, base militaire, rejet urbain) ;
- **Voie** : milieu qui transporte le polluant (sol, eau souterraine, eau de surface, air) ;
- **Récepteur** : milieu ou organisme exposé (nappe exploitée, puits, rivière, population).

Ce schéma aide à structurer la pensée, indépendamment des outils mathématiques utilisés ensuite pour l'analyse des données.

La figure ?? présente les principales voies de contamination humaine aux PFAS selon leur production, leur utilisation et la pollution des milieux.




Figure 2 – Voies possibles de contamination humaine aux PFAS (sources directes en rouge, contamination indirecte via sol ou eau en bleu, voies d'exposition en violet). Source : adapté de [?].

On observe que les rejets industriels ou l'usage de produits de consommation alimentent d'abord les milieux (sol, eau), avant d'atteindre l'homme par l'eau potable, l'alimentation ou d'autres voies d'exposition. On observe par ailleurs une **co-occurrence** fréquente avec d'autres polluants organiques sur les mêmes sites : solvants chlorés (TCE, PCE), hydrocarbures, additifs (MTBE). Ces co-contaminants partagent souvent une histoire industrielle commune, même si leurs propriétés de transport diffèrent.

1.2.4. Surveillance des eaux souterraines et limites de la mesure

Les **eaux souterraines** constituent un enjeu majeur car elles alimentent une part importante de l'eau potable et de l'irrigation. Les PFAS y sont d'autant plus préoccupants qu'ils peuvent migrer **loin** de la source visible et demeurer longtemps à des concentrations très faibles mais significatives sur le plan sanitaire.

La **surveillance** repose classiquement sur :

- le prélèvement sur des **puits** ou points de contrôle ;

- l'analyse en laboratoire par chromatographie de type LC-MS/MS, ciblant un **panier** de composés (souvent quelques dizaines de molécules parmi des milliers possibles) ;
- la comparaison aux **seuils réglementaires** ou aux valeurs guides sanitaires.

Plusieurs limites structurelles expliquent la difficulté d'un suivi exhaustif :

- **Coût** élevé d'une analyse multi-composés ;
- **Couverture spatiale** incomplète (impossible de mesurer tous les puits d'une région) ;
- **Non-détection** fréquente : une valeur nulle ne signifie pas toujours l'absence de PFAS, mais parfois une concentration sous le seuil de détection de la méthode ;
- **Hétérogénéité** des protocoles entre régions et campagnes.

Ces contraintes expliquent l'intérêt, dans la littérature récente, pour des approches de **priorisation** fondées sur des données déjà disponibles (contexte géologique, proximité d'activités, qualité de l'eau).

I.2.5. Impacts sanitaires et cadre réglementaire

I.2.5.1. Voies d'exposition et effets documentés

L'exposition humaine aux PFAS peut intervenir par plusieurs **voies** [?] :

- **Eau potable** contaminée (voie souvent dominante près des sites pollués) ;
- **Alimentation** (poissons d'eau douce, produits d'origine animale bioaccumulants) ;
- **Poussières intérieures** et produits de consommation traités ;
- **Contact professionnel** sur les sites de production ou d'usage intensif.

Les effets sanitaires étudiés à des doses environnementales très basses (ng/L dans l'eau) incluent notamment :

- des effets sur le **système immunitaire** (réponse vaccinale) ;
- des perturbations **thyroïdiennes** et métaboliques (lipides) ;

- des impacts sur le **développement fœtal** (poids à la naissance, prééclampsie) ;
- pour certains composés, des associations avec des **cancers** (rein, testicules) dans les cohortes les plus exposées.

La figure ?? synthétise les pathologies suspectées d'être liées à la toxicité des PFAS chez l'humain.




Figure 3 – Pathologies suspectées d'être induites par la toxicité des PFAS (effets épidémiologiques corroborés au centre ; autres effets documentés en gris ; effets reprotoxiques sur les côtés). Source : adapté de [?].

On observe que plusieurs organes et fonctions (immunité, thyroïde, développement fœtal, reproduction) figurent parmi les effets les plus documentés, ce qui justifie le renforcement des seuils et des programmes de surveillance.

Le tableau ?? en donne une vue synthétique tabulaire ; il ne remplace pas une analyse toxicologique détaillée.

1.2.5.2. Évolution du cadre réglementaire

Face à ces risques, les seuils admissibles ont fortement baissé au cours des dernières années. Aux États-Unis, l'EPA a publié en 2016 un **avis sanitaire** (*health advisory*) à **70 ng/L** pour la somme PFOA+PFOS [?], puis en 2024 un **règlement national** sur l'eau potable fixant des limites maximales de contaminants (MCL) à **4 ng/L** pour le PFOA et le PFOS **séparément** [?]. Cette dualité (avis historique vs limites récentes plus strictes) illustre la **rapidité** de l'évolution normative.

Table II – Exemples d'effets sanitaires associés à l'exposition aux PFAS (synthèse).

Système	Effets documentés	Populations sensibles
Immunitaire	Diminution de la réponse vaccinale	Enfants
Endocrinien	Perturbation thyroïdienne, lipides	Adultes
Développement	Faible poids à la naissance	Femmes enceintes
Reproduction	Fertilité, complications gestationnelles	Adultes
Cancér (certains composés)	Rein, testicules (associations)	Exposés professionnels

En Europe, la directive sur l'eau potable (2020/2184/UE) encadre un sous-ensemble de PFAS :

- une limite sur la **somme de 20 PFAS** prioritaires (indicateur PFAS Total, valeur paramétrique de l'ordre de $0,1 \mu\text{g/L}$) ;
- une limite sur le **total des PFAS** mesurés au-delà d'un seuil de quantification (indicateur PFAS TQS, de l'ordre de $0,5 \mu\text{g/L}$).

Des initiatives nationales complètent ce cadre (programmes de surveillance en Allemagne, Pays-Bas, Danemark, etc.). En France, des textes récents visent à restreindre certains usages non essentiels (cosmétiques, textiles, produits de loisirs) et à renforcer la fiscalité ou la redevance sur les rejets industriels, dans une logique de **prévention** à la source.

Quelle que soit la juridiction, le message commun est le suivant : les concentrations d'intérêt sont **très faibles**, la liste des composés à suivre **change**, et la surveillance doit être **étendue** dans le temps et dans l'espace, ce qui pose un défi logistique considérable pour les gestionnaires de l'eau.

I.3. Apprentissage automatique et méthodes d'ensemble

L'**apprentissage automatique** (*machine learning*, ML) regroupe les méthodes qui permettent à un système informatique d'améliorer une tâche à partir de données, sans que chaque règle de décision soit codée explicitement. En sciences de l'environnement, ces approches servent notamment à exploiter des tableaux de mesures et de variables contextuelles (géologie, hydrologie, proximité d'activités) pour estimer un risque ou prioriser des sites à contrôler. Cette section présente d'abord les principaux **paradigmes** d'apprentissage, les **principes des méthodes**

d'ensemble illustrés par des exemples courants, l'**évaluation des classificateurs**, enfin la **gestion du déséquilibre** entre classes.

I.3.1. Définition et principes généraux

L'apprentissage automatique peut se définir, suivant Mitchell [?], comme l'amélioration d'une performance P sur une tâche T grâce à l'expérience E . Formellement, on cherche un programme f tel que la performance sur T s'améliore lorsque l'expérience E augmente :

$$\mathcal{L}(f) \downarrow \quad \text{lorsque} \quad P(T, f, E) \uparrow. \quad (\text{I.1})$$

En pratique, un **algorithme** ajuste des paramètres à partir d'exemples pour produire des prédictions ou des décisions. On distingue ensuite plusieurs paradigmes selon la nature des données disponibles et l'objectif visé.

I.3.1.1. Apprentissage supervisé

En **apprentissage supervisé**, chaque exemple d'entrée $\mathbf{x}$ est associé à une **étiquette** y connue. L'objectif est d'apprendre une fonction $f(\mathbf{x}) \approx y$ qui **généralise** à de nouvelles observations non vues à l'entraînement.

Deux tâches principales en découlent :

- la **classification**, lorsque y est discrète (par exemple *contaminé / non contaminé*) ;
- la **régression**, lorsque y est continue (par exemple une concentration mesurée).

Le protocole habituel consiste à séparer les données en un jeu d'**entraînement** (pour ajuster f), un jeu de **validation** (pour choisir les hyperparamètres) et un jeu de **test** (pour estimer la performance en conditions indépendantes). En surveillance environnementale, la classification binaire (dépassement ou non d'un seuil, présence ou absence d'un signal) est fréquente lorsque l'on cherche à orienter des campagnes de mesure.

I.3.1.2. Apprentissage non supervisé

En **apprentissage non supervisé**, les données ne sont pas étiquetées : l'algorithme cherche à mettre en évidence des **structures** sans cible explicite. Les objectifs typiques sont :

- le **regroupement** (*clustering*), par exemple regrouper des sites aux profils hydrogéologiques voisins ;
- la **réduction de dimension**, pour visualiser ou compresser un grand nombre de variables corrélées ;

- la détection d'**anomalies**, pour repérer des observations atypiques.

Ces méthodes ne produisent pas directement une prédiction de contamination, mais elles peuvent précéder une étape supervisée en révélant des homogénéités spatiales ou des corrélations entre variables.

I.3.1.3. Apprentissage semi-supervisé

L'**apprentissage semi-supervisé** combine un nombre limité d'exemples **étiquetés** et un volume plus important de données **non étiquetées**. Il est particulièrement utile lorsque l'étiquetage est **coûteux** ou **lent**, ce qui est le cas en environnement lorsque chaque étiquette correspond à une analyse de laboratoire.

L'idée générale est d'exploiter la structure des données non étiquetées (similarité entre sites, continuité spatiale) pour renforcer un modèle entraîné sur le sous-ensemble étiqueté. Des travaux récents sur les PFAS en eaux souterraines ont mobilisé cette logique lorsque les mesures ciblées restent rares par rapport au nombre de points à évaluer [?].

I.3.1.4. Apprentissage par renforcement

En **apprentissage par renforcement**, un **agent** interagit avec un **environnement** et apprend une politique de décision à partir de **récompenses** ou de **pénalités** reçues au fil du temps. Contrairement au cadre supervisé, il n'existe pas d'étiquette correcte pour chaque action : l'agent doit **explorer** et **exploiter** ses choix pour maximiser un gain cumulé.

Ce paradigme est central en robotique, en jeux ou en recommandation dynamique. Pour la surveillance tabulaire des eaux souterraines, il intervient moins directement que l'apprentissage supervisé ; nous le mentionnons ici pour situer le panorama des approches d'apprentissage automatique.

I.3.2. Les méthodes d'ensemble

Une **méthode d'ensemble** combine plusieurs **apprenants** pour former un prédicteur plus stable ou plus précis qu'un modèle isolé. Le principe est le suivant : si les apprenants ne se trompent pas toujours aux mêmes endroits, les combiner peut compenser leurs faiblesses respectives. Le **bagging** atténue surtout la **variance** (prédictions instables d'un modèle très flexible), tandis que le **boosting** réduit plutôt le **biais** (erreurs systématiques d'un modèle trop simple). Quant au **stacking**, il combine des modèles de natures éventuellement différentes pour optimiser la combinaison des sorties.

1.3.2.1. Bagging

Le **bagging** (*bootstrap aggregating*) entraîne plusieurs modèles en **parallèle** sur des tirages **bootstrap** des observations (échantillonnage avec remise), puis **agrège** leurs prédictions. En classification, la décision finale est un **vote majoritaire** ; en régression, une moyenne des prédictions. Le bagging vise surtout à stabiliser un apprenant à forte variance (comme un arbre de décision profond) en moyennant des versions entraînées sur des sous-jeux légèrement différents. On peut formaliser l'agrégation en classification par

$$\hat{y}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \sum_{b=1}^B \mathbb{I}(h_b(\mathbf{x}) = c),$$

où h_b désigne le b -ième modèle entraîné sur un bootstrap, et B le nombre total de modèles. Plus B augmente, plus la prédiction devient stable, jusqu'à un plateau de performance.

Exemple (forêt aléatoire). La **forêt aléatoire** (*Random Forest*) [?] est l'illustration standard du bagging appliqué aux arbres de décision. Chaque arbre est entraîné sur un sous-échantillon bootstrap ; à chaque nœud, seul un sous-ensemble aléatoire de variables est candidat au meilleur partage. Cette double aléa (données et variables) **décorrèle** les arbres et limite le surapprentissage. Dans la pratique, les hyperparamètres les plus structurants sont :

- le nombre d'arbres B (`n_estimators`) ;
- la profondeur maximale de chaque arbre (`max_depth`) ;
- le nombre minimal d'observations pour scinder un nœud ou créer une feuille (`min_samples_split`, `min_samples_leaf`) ;
- le nombre de variables testées à chaque nœud (`max_features`).

Un réglage prudent de ces paramètres contrôle le compromis biais-variance et évite des arbres trop spécialisés.

Un atout important de Random Forest est l'estimation dite **out-of-bag** (OOB) : pour chaque observation, on peut évaluer la prédiction en utilisant uniquement les arbres qui n'ont pas vu cette observation à l'entraînement. Ce score OOB donne une estimation rapide de la généralisation sans validation croisée exhaustive.

Pour l'interprétation, la forêt fournit des **importances de variables** (par impureté ou par permutation), utiles pour identifier les descripteurs dominants. En revanche, ces importances doivent être analysées avec prudence en présence de variables corrélées. Les forêts aléatoires restent ainsi une base solide en données

tabulaires, à la fois robuste, explicable à un niveau global, et souvent performante comme modèle de référence ou composant d'un ensemble plus complexe.

La figure ?? illustre le principe d'une forêt aléatoire : plusieurs arbres entraînés en parallèle sur des sous-échantillons, puis agrégés par vote.




Figure 4 – Schéma d'une forêt aléatoire (bagging d'arbres de décision avec sous-échantillonnage des observations et des variables). Source : adapté de [?].

On observe que chaque arbre voit un sous-jeu de données différent et ne retient qu'une fraction des variables à chaque scission, ce qui diversifie les prédictions avant agrégation.

1.3.2.2. Boosting

Le **boosting** construit le modèle de façon **séquentielle** : chaque nouvel apprenant cible les erreurs laissées par l'ensemble des apprenants précédents, au lieu d'entraîner des modèles indépendants comme en bagging. La figure ?? résume cette logique additive : le modèle courant est enrichi à chaque itération par un arbre entraîné sur les résidus.




Figure 5 – Principe du boosting : ajout séquentiel d’arbres pour corriger les erreurs du modèle courant. Source : illustration pédagogique adaptée de [?].

On observe que les prédictions s’améliorent progressivement en cumulant de petits correctifs, plutôt qu’en moyennant des modèles parallèles indépendants comme en bagging.

Le **gradient boosting** [?] met cette idée en œuvre en ajoutant, à chaque itération, un arbre qui corrige les résidus selon le gradient d’une fonction de perte différentiable. On écrit souvent la prédiction additive sous la forme

$$F_M(\mathbf{x}) = F_{M-1}(\mathbf{x}) + \eta h_M(\mathbf{x}), \quad (\text{I.2})$$

où h_M est un nouvel arbre entraîné sur les résidus et η un taux d’apprentissage. Dans la pratique, le boosting construit souvent des arbres **courts** (faible profondeur) afin de corriger progressivement les erreurs sans sur-ajuster le bruit. Le paramètre η (*learning rate*) contrôle la contribution de chaque nouvel arbre : une valeur faible stabilise l’apprentissage mais exige davantage d’itérations. Le nombre d’arbres, la profondeur maximale et les contraintes de régularisation gouvernent ainsi le compromis entre **capacité de modélisation** et **généralisation**.

Exemple (XGBoost et LightGBM). XGBoost (*eXtreme Gradient Boosting*) [?] est l’une des implémentations les plus utilisées sur **données tabulaires**, notamment lorsque l’on recherche un modèle performant et robuste. Son apprentissage optimise une fonction objectif composée d’un terme de perte et d’un terme de complexité :

$$\mathcal{J}^{(t)} = \sum_{i=1}^n l\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t),$$

avec une régularisation typique

$$\Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j|,$$

où T est le nombre de feuilles, w_j les poids des feuilles, et $(\alpha, \lambda, \gamma)$ les coefficients de pénalisation. Cette formulation explicite permet de limiter la complexité des arbres et de réduire le surapprentissage.

En pratique, les hyperparamètres les plus influents sont :

- `n_estimators` : nombre d'arbres ajoutés ;
- `max_depth` : profondeur maximale des arbres ;
- `learning_rate` : poids de chaque nouvel arbre ;
- `subsample` et `colsample_bytree` : sous-échantillonnage des observations et des variables ;
- `reg_alpha`, `reg_lambda` et `gamma` : contrôle de la régularisation.

XGBoost prend aussi en charge les valeurs manquantes en apprenant une direction de branche par défaut lors des splits, et propose des implémentations efficaces (*histogram-based*, parallélisation) adaptées aux volumes de données importants. Dans un cadre appliqué, XGBoost est souvent mobilisé comme modèle de référence fort ou comme composant d'un empilement, car il combine bonne précision, robustesse et interprétabilité globale (importance des variables, SHAP).

LightGBM (*Light Gradient Boosting Machine*) [?] privilégie une croissance des arbres **feuille par feuille** (*leaf-wise*) et introduit des mécanismes d'échantillonnage (GOSS) et de regroupement de variables (EFB) pour accélérer l'entraînement sur de grands jeux de données.

1.3.2.3. Stacking

Le **stacking** (*stacked generalization*) place un **méta-classifieur** (ou méta-régresseur) au-dessus de plusieurs **modèles de base** de natures éventuellement différentes. Chaque modèle de base produit une prédiction (ou une probabilité) ; le méta-modèle apprend à les combiner de manière optimale, au lieu de se limiter à un vote fixe comme en bagging. L'idée centrale est que des modèles différents capturent des **signaux complémentaires** : un modèle peut mieux exploiter les interactions non linéaires tabulaires, un autre la structure relationnelle, un autre encore des effets locaux. Le stacking apprend donc une **fonction de fusion** des sorties de base plutôt qu'une règle de combinaison fixée a priori.

Si l'on note $p_k(\mathbf{x})$ la sortie du k -ième modèle de base, le méta-modèle apprend une fonction

$$\hat{y} = g(p_1(\mathbf{x}), p_2(\mathbf{x}), \dots, p_K(\mathbf{x})),$$

où g peut être, selon les cas, une régression logistique, un arbre de décision, un gradient boosting ou un autre classifieur. En pratique, les entrées de g peuvent être enrichies par des variables de confiance (entropie des probabilités, écart entre modèles, etc.).

Exemple (méta-classifieur sur sorties de bases). On peut par exemple empiler une forêt aléatoire, un gradient boosting et un modèle produisant des embeddings (graphe ou autre), puis entraîner un classifieur final sur les vecteurs de prédictions produits par ces bases.

La figure ?? résume l'architecture hiérarchique du stacking.




Figure 6 – Principe du stacking : plusieurs modèles de base alimentent un méta-classifieur.

On observe que le méta-modèle ne reçoit pas les variables brutes mais les sorties des apprenants de base, ce qui permet de combiner des modèles de natures différentes.

Pour éviter le surapprentissage, les entrées du méta-classifieur doivent provenir de **prédictions hors échantillon** : les modèles de base ne doivent pas avoir vu les exemples utilisés pour entraîner le méta-modèle. La procédure usuelle repose sur une validation croisée en deux niveaux :

- niveau 1 : générer, pour chaque observation d'entraînement, des prédictions hors pli des modèles de base ;
- niveau 2 : entraîner le méta-modèle sur cette matrice de méta-caractéristiques, puis réentraîner les modèles de base sur l'ensemble d'entraînement.

Cette discipline méthodologique est essentielle pour obtenir un gain réel au test.

Le stacking est particulièrement utile quand la performance individuelle des modèles est proche mais que leurs erreurs ne se recouvrent pas totalement. Il peut

toutefois être sensible à la complexité du méta-modèle et à la qualité des prédictions de base ; un protocole d'évaluation rigoureux reste donc indispensable.

Le tableau ?? présente les trois familles d'ensembles et un exemple représentatif pour chacune ; pour les données tabulaires de taille modérée, les ensembles d'arbres restent souvent très compétitifs face à des réseaux profonds génériques [?].

Table III – Synthèse des trois familles d'ensembles et d'un exemple représentatif pour chacune.

Famille	Construction		Effet visé	Exemple
Bagging	Parallèle	sur	Réduit la variance	Forêt aléatoire
	tirages bootstrap			
Boosting	Séquentielle	sur	Réduit le biais	XGBoost, Light-GBM
	les résidus			
Stacking	Méta-modèle	sur	Combine des mod-	Méta-classifieur
	les sorties	des	èles hétérogènes	
	bases			

I.3.3. Évaluation de classificateur et gestion du déséquilibre

Les métriques d'évaluation des classifieurs de contamination PFAS (F1, AUC-ROC, matrice de confusion) et les techniques de gestion du déséquilibre de classes (SMOTE, ADASYN) sont présentées au chapitre ??, section ??, où elles servent de cadre conceptuel commun à la lecture de l'état de l'art. Les définitions formelles et les protocoles d'application figurent dans cette section ; on s'y réfèrera systématiquement lors des comparaisons inter-études du chapitre ??.

I.4. Généralités sur les graphes et l'apprentissage profond

Les données de surveillance des eaux souterraines sont souvent stockées sous forme **tabulaire** (une ligne par puits, une colonne par variable). Or, un site de prélèvement n'est pas isolé : il partage un contexte géologique, une proximité d'installations, des co-contaminants et une position géographique avec d'autres sites. Les **graphes** offrent un langage naturel pour représenter ces dépendances et les exploiter par apprentissage profond, en complément des modèles tabulaires (forêts aléatoires, XGBoost) présentés en section ??–??. Des travaux récents sur les PFAS mobilisent déjà des graphes pour la prédiction spatio-chimique [?, ?].

I.4.1. Représentation des données par graphe

Un **graphe** $G = (V, E)$ modélise des entités par des **nœuds** $v \in V$ et des liens par des **arêtes** $e \in E$. Chaque nœud peut porter un vecteur de caractéristiques $\mathbf{x}_v \in \mathbb{R}^{d_v}$.

En classification de sites, on associe en général à chaque nœud **sample** (échantillon) une **étiquette** y_v (par exemple contamination oui/non).

Contrairement à une image (grille régulière) ou à une séquence (chaîne), un graphe autorise des connexions **irrégulières** : le voisinage d'un site n'est pas imposé par la position dans un tableau, mais par la structure relationnelle choisie. Cette flexibilité est utile lorsque l'on veut relier explicitement un puits à des variables de contexte (environnement, installations, qualité de l'eau, regroupement géographique).

On distingue :

- le **graphe homogène** : un seul type de nœud et un seul type d'arête ;
- le **graphe hétérogène** : plusieurs types de nœuds et d'arêtes typées, notées (s, r, t) pour une relation r entre un nœud source de type s et un nœud cible de type t .

En surveillance environnementale, l'hétérogénéité reflète le modèle conceptuel **source, voie et récepteur** (section ??) : sources d'activité, milieux de transport, sites de mesure.

I.4.2. Réseaux de neurones sur graphes

Les **réseaux de neurones sur graphes** (GNN, *Graph Neural Networks*) apprennent une **représentation vectorielle** (*embedding*) pour chaque nœud en diffusant l'information de proche en proche. Le mécanisme standard est le **message passing** : à chaque couche ℓ , un nœud agrège les messages de ses voisins $\mathcal{N}(v)$ puis met à jour sa représentation :

$$\mathbf{h}_v^{(\ell+1)} = \text{UPDATE}\left(\mathbf{h}_v^{(\ell)}, \text{AGGREGATE}\left(\{\mathbf{h}_u^{(\ell)} : u \in \mathcal{N}(v)\}\right)\right).$$

La figure ?? illustre ce mécanisme sur un nœud central et ses voisins.




Figure 7 – *Message passing : agrégation des représentations des voisins $\mathcal{N}(v)$ vers le nœud v .*

On observe que l'information locale se propage par couches successives : après ℓ itérations, $\mathbf{h}_v^{(\ell)}$ encode un voisinage à ℓ sauts [?, ?].

Des variantes historiques incluent les **GCN** (*Graph Convolutional Networks*), les **GAT** (*Graph Attention Networks*) et **GraphSAGE**, qui diffèrent par la fonction d'agrégation et la pondération des voisins. En pratique, ces modèles sont souvent implémentés avec des bibliothèques spécialisées telles que **PyTorch Geometric** (PyG), qui fournit des structures de données et des couches convolutives sur graphe [?].

I.4.3. Graphes hétérogènes pour la modélisation environnementale

Un graphe hétérogène $G = (V, E, \tau, \phi)$ associe à chaque nœud un type $\tau(v) \in \mathcal{T}_V$ et à chaque arête un type $\phi(e) \in \mathcal{T}_E$. Formellement, une arête typée est un triplet (s, r, t) : une relation r relie un nœud de type s à un nœud de type t . Cette formalisation évite de fusionner dans une seule matrice d'adjacence des relations de nature différente (géographie, chimie, proximité d'installation).

Dans les approches hybrides tabulaire-graphe appliquées aux PFAS, on construit couramment un graphe à **cinq types de nœuds** (tableau ??) :

- `sample` : point de prélèvement (vecteur de variables contextuelles et étiquette de contamination) ;
- `env` : descripteurs environnementaux (précipitations, recharge, propriétés de sol) ;
- `facility` : indicateurs de proximité d'activités humaines (distances, densités d'installations) ;
- `water` : variables de qualité de l'eau et co-contaminants (TDS, nitrates, solvants chlorés, etc.) ;
- `geo_cluster` : regroupement géographique de sites voisins.

Table IV – Types de nœuds usuels dans un graphe hétérogène de surveillance des PFAS (vue pédagogique).

Type	Rôle	Exemples de signaux
<code>sample</code>	Site à prédire	Variables tabulaires, étiquette
<code>env</code>	Contexte naturel	Sol, recharge, précipitations
<code>facility</code>	Pression anthropique	Distances, comptages d'usines
<code>water</code>	Chimie associée	Co-contaminants, conductivité
<code>geo_cluster</code>	Structure spatiale	Cluster géographique

Les **arêtes typées** relient ces entités selon des relations sémantiques distinctes (tableau ??). Les relations sont en pratique **bidirectionnelles** : par exemple `has_env` / `affects`, `near` / `near_to`, `quality` / `measured_in`, `located_in` / `contains`.

Table V – Exemples de relations typées dans un graphe hétérogène de surveillance (paires directes/inverses).

Relation	Sens	Interprétation
has_env / affects	sample $\leftrightarrow$ env	Contexte environnemental du site
near / near_to	sample $\leftrightarrow$ facility	Proximité d'installations
quality / measured_in	sample $\leftrightarrow$ water	Qualité de l'eau au site
located_in / contains	sample $\leftrightarrow$ geo_cluster	Appartenance géographique

I.4.3.1. Principes de construction d'un graphe de surveillance

La construction du graphe repose sur une **catégorisation métier** des variables : chaque famille de descripteurs devient un type de nœud, ce qui permet au modèle de traiter séparément les signaux environnementaux, industriels et hydrogéochimiques. Pour chaque observation `sample`, les arêtes vers `env`, `facility` et `water` encodent le fait que le site possède ces attributs ; les vecteurs portés par ces nœuds reprennent les variables correspondantes.

La dimension **géographique** est introduite par des nœuds `geo_cluster` : les coordonnées des sites sont regroupées par un algorithme de partitionnement (par exemple K-means sur la latitude et la longitude), puis chaque site est relié au cluster auquel il appartient. Cette structure favorise le partage d'information entre sites proches dans l'espace, ce qui est pertinent pour des panaches de contamination à l'échelle régionale.

Enfin, la structure est stockée sous forme de **graphe hétérogène** dans un objet du type `HeteroData` (PyTorch Geometric), qui maintient séparément les matrices de features par type de nœud et les index d'arêtes par relation typée. Comme pour toute étape d'apprentissage, les transformateurs de structure (normalisation, clustering géographique) doivent être ajustés **sans fuite de données** : seul le jeu d'entraînement sert à apprendre la structure, puis celle-ci est appliquée aux jeux de validation et de test.

I.4.4. Heterogeneous Graph Transformer (HGT)

Le **Heterogeneous Graph Transformer** (HGT) [?] adapte le mécanisme d'**attention** des transformeurs aux graphes hétérogènes. Pour une méta-relation (τ_s, ϕ, τ_t) , les poids d'attention dépendent du type de nœud source, du type de relation et du type de nœud cible. Chaque type dispose de projections spécifiques (matrices requête, clé, valeur), ce qui permet d'apprendre des interactions différenciées entre, par exemple, un lien *géographique* et un lien *de qualité de l'eau*.

Pour un message envoyé d'un voisin u vers un nœud cible v , l'attention peut s'écrire schématiquement :

$$\alpha_{uv} = \text{softmax} \left(\frac{\mathbf{Q}_{\tau(v)} \mathbf{h}_u \cdot \mathbf{K}_{\tau(u)} \mathbf{h}_v}{\sqrt{d}} \right), \quad \mathbf{h}'_v = \sum_{u \in \mathcal{N}(v)} \alpha_{uv} \mathbf{V}_{\phi(u,v)} \mathbf{h}_u,$$

où $\mathbf{Q}$, $\mathbf{K}$ et $\mathbf{V}$ dépendent des types de nœuds et de la relation. Des couches `HGTConv` sont empilées pour produire, en sortie, un **embedding** de dimension fixe pour chaque nœud `sample`.

Cet embedding résume l'information relationnelle diffusée dans le graphe (contexte environnemental, proximité d'installations, co-contaminants, voisinage géographique). Il peut ensuite être exploité de deux manières complémentaires, au coeur des approches hybrides :

- **Fusion par embeddings** : concaténation des embeddings HGT avec les variables tabulaires d'origine, puis apprentissage d'un classifieur XGBoost sur l'espace enrichi ;
- **Stacking** : utilisation des probabilités ou embeddings HGT comme entrées d'un méta-classifieur, aux côtés d'autres modèles tabulaires (section ??).

On observe ainsi un pont entre **données relationnelles** (graphe) et **modèles tabulaires** (boosting), utile lorsque la structure spatiale et contextuelle apporte un signal que les seules colonnes isolées ne capturent pas entièrement.

1.5. Interprétabilité des modèles

Un modèle précis mais opaque limite l'acceptation par les gestionnaires de l'eau et les régulateurs : une décision de contrôle, de priorisation de campagnes ou de fermeture de puits exige une **justification** compréhensible et reproductible. En santé environnementale, l'interprétabilité n'est plus un simple complément esthétique : elle conditionne la confiance des parties prenantes et la possibilité de confronter les sorties algorithmiques à des connaissances de terrain (hydrogéologie, usages industriels, co-contaminants). Cette section présente les notions nécessaires pour lire les analyses menées dans la contribution, en particulier l'approche **SHAP** et son déploiement sur les modèles tabulaires, fusionnés et empilés décrits aux sections ?? et ??.

I.5.1. Enjeux et interprétabilité a posteriori

On distingue en pratique deux familles d’approches. L’interprétabilité **intrinsèque** repose sur des modèles structurellement lisibles (arbres de décision peu profonds, régressions linéaires avec coefficients explicites). L’interprétabilité **a posteriori** (*post-hoc*) applique, après entraînement, des méthodes qui expliquent les prédictions d’un modèle potentiellement complexe (forêt aléatoire, gradient boosting, réseau sur graphe). Les importances par impureté des forêts aléatoires (section ??) donnent un ordre de grandeur global, mais elles ne décrivent pas la contribution à une prédiction individuelle ni ne satisfont des axiomes de répartition équitable entre variables corrélées.

L’approche **SHAP** (*SHapley Additive exPlanations*) [?] fournit un cadre unifié : chaque variable reçoit une contribution additive à la prédiction, fondée sur la théorie des jeux coopératifs. Elle s’applique naturellement aux modèles à arbres mobilisés dans ce mémoire (XGBoost, LightGBM) via l’algorithme **Tree-SHAP**, et se prolonge aux espaces de features enrichis (fusion d’embeddings, méta-caractéristiques de stacking).

I.5.2. Valeurs de Shapley et décomposition additive

Pour une prédiction $f(\mathbf{x})$ sur un vecteur de variables $\mathbf{x} = (x_1, \dots, x_p)$, la contribution SHAP de la variable i repose sur la **valeur de Shapley** :

$$\phi_i = \sum_{S \subseteq \mathcal{F} \setminus \{i\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f(S \cup \{i\}) - f(S)], \quad (\text{I.3})$$

où $\mathcal{F} = \{1, \dots, p\}$ est l’ensemble des indices de variables et $f(S)$ la prédiction moyenne du modèle lorsque seules les variables de la coalition S sont observées, les autres étant marginalisées selon la distribution de référence (souvent l’échantillon d’entraînement ou de test).

Chaque variable est vue comme un *joueur* ; la coalition S représente un sous-ensemble de variables disponibles pour la prédiction. Le terme $f(S \cup \{i\}) - f(S)$ mesure le **gain marginal** de i lorsque S est déjà connu ; la formule (??) en fait la moyenne pondérée sur toutes les coalitions, ce qui évite qu’une variable corrélée monopolise tout le crédit ou soit ignorée selon l’ordre d’introduction.

Cette construction vérifie des propriétés souhaitables [?] :

- **Efficacité** : $\sum_{i=1}^p \phi_i = f(\mathbf{x}) - \mathbb{E}[f(\mathbf{X})]$, où $\mathbb{E}[f(\mathbf{X})]$ est la **valeur de base** (*expected value*) du modèle ;
- **Symétrie** : deux variables ayant la même contribution marginale sur toute coalition reçoivent la même valeur SHAP ;

- **Nullité** : une variable sans effet reçoit $\phi_i = 0$;
- **Additivité** : pour un ensemble de modèles combinés additivement, les contributions se somment.

La prédiction s'écrit ainsi sous forme additive :

$$f(\mathbf{x}) = \phi_0 + \sum_{i=1}^p \phi_i, \quad \phi_0 = \mathbb{E}[f(\mathbf{X})],$$

ce qui permet de lire, pour chaque observation, quelles variables **augmentent** ou **diminuent** la sortie du modèle par rapport à la moyenne.

Le calcul exact de l'équation (??) est exponentiel en p (toutes les coalitions). **TreeSHAP** [?] exploite la structure des arbres de décision pour obtenir des valeurs SHAP **exactes** en temps polynomial pour XGBoost, LightGBM et les forêts aléatoires. En pratique, on instancie un `TreeExplainer` sur le booster entraîné ; à défaut, XGBoost expose aussi des *pred_contribs* (contributions par feuille) compatibles avec la même lecture additive.

1.5.3. Analyses globale et locale

Les sorties SHAP se lisent à deux échelles complémentaires.

Niveau global. On agrège typiquement les valeurs absolues $|\phi_i|$ sur un jeu d'observations (souvent l'échantillon de test) pour obtenir une **importance moyenne** par variable. Le graphique en barres (*bar plot*) classe les variables par ordre décroissant de cette importance. Le graphique en nuage (*beeswarm*, ou *summary plot*) représente, pour chaque variable, la distribution des ϕ_i : la position horizontale indique l'ampleur et le signe de l'effet, la couleur le niveau de la variable (faible ou élevé). On observe ainsi non seulement *quelles* variables comptent le plus, mais aussi si une valeur élevée de la variable pousse généralement vers la classe positive ou négative.

Niveau local. Pour une observation $\mathbf{x}^{(j)}$ (un puits, un point de surveillance), les $\phi_i^{(j)}$ décrivent la prédiction individuelle. Le **graphique de force** (*force plot*) aligne les contributions positives (vers la classe *contaminé*) et négatives (vers la classe *non contaminé*) autour de la valeur de base ϕ_0 . Un barplot local des $|\phi_i^{(j)}|$ les plus élevés offre une vue synthétique pour un cas d'étude. Ces vues sont utiles pour expliquer à un expert pourquoi un site précis a été classé à risque, au-delà d'un score global.

Relations non linéaires. Les **graphiques de dépendance** (*dependence plots*) représentent, pour une variable i , la valeur de x_i en abscisse et ϕ_i en ordonnée. Ils mettent en évidence des effets à seuil, des saturations ou des interactions (en colorant les points selon une deuxième variable corrélée). Pour des classificateurs par arbres, on peut y vérifier que le modèle reproduit des comportements plausibles (par exemple une influence accrue de la proximité d’une source industrielle au-delà d’un certain rayon), sans confondre cette cohérence avec une preuve causale.

1.5.4. Interprétabilité d’un pipeline hybride

La contribution de ce mémoire combine plusieurs briques dont l’explicabilité ne se lit pas de la même manière. Nous en donnons ici le vocabulaire ; les figures et chiffres détaillés relèvent du chapitre consacré au protocole expérimental, dans le **mode prédictif** (variables contextuelles et structurelles, **sans** concentrations mesurées de PFAS comme entrées du modèle).

Modèle tabulaire de référence (XGBoost seul). Sur les variables contextuelles standardisées (géologie, usages, co-contaminants, indicateurs de qualité d’eau, etc.), TreeSHAP fournit l’importance globale et des explications locales pour des cas représentatifs (sites fortement classés positifs ou négatifs). Cette ligne de base permet de vérifier quels signaux tabulaires portent la prédiction avant tout enrichissement par le graphe.

Fusion embeddings–tabulaire. Lorsque les embeddings produits par le HGT (section ??) sont concaténés aux variables d’origine puis appris par un XGBoost de fusion, chaque dimension d’embedding devient une **pseudo-variable** (par exemple `HGT_emb_j` ou, après réduction de dimension, `PCA_emb_j`). TreeSHAP s’applique alors sur l’espace joint. Deux lectures se complètent :

- **Locale** : une composante d’embedding peut dominer pour un site donné, traduisant l’effet du voisinage dans le graphe (installations proches, cluster géographique, co-contaminants liés) ;
- **Globale** : la somme des $|\phi_i|$ sur le bloc tabulaire, comparée à celle sur le bloc embeddings, indique la part relative de la **couche de mesure directe** et de la **couche contextuelle relationnelle** dans les décisions du modèle fusionné.

On observe souvent une dualité : quelques dimensions d’embedding peuvent figurer parmi les variables les plus influentes prises une à une, tandis que l’ensemble

des variables tabulaires conserve une masse SHAP agrégée majoritaire lorsque les mesures contextuelles sont riches.

Modèle HGT seul. Les réseaux sur graphe ne disposent pas, à ce jour, d'un TreeSHAP standard aussi mature que pour les arbres. Pour le HGT, une **sensibilité locale** par gradient ($\partial f / \partial x_i \times x_i$ sur les features du nœud `sample`) indique quelles entrées tabulaires du nœud influencent le logit de la classe positive pour une observation donnée. Cette quantité n'est pas une valeur de Shapley sur le graphe entier (les messages entre nœuds ne sont pas décomposés variable par variable), mais elle permet une comparaison qualitative avec les profils SHAP du XGBoost sur le même site.

Stacking. Le méta-classifieur (souvent un XGBoost) reçoit des **méta-caractéristiques** : probabilités des modèles de base (HGT, XGBoost, LightGBM), statistiques dérivées (entropie, écarts), indicateurs d'accord entre modèles, et parfois un sous-vecteur d'embeddings réduit. TreeSHAP sur ces méta-features répond à une question différente : *quel modèle de base (ou quelle sortie agrégée) a pesé dans la décision finale ?* Un cas d'étude sur un même échantillon de test (entrées brutes, prédictions des quatre pipelines, barres SHAP locales) synthétise ces points de vue et aide à comprendre les désaccords entre modèles.

Lien avec la performance. L'interprétabilité ne remplace pas les métriques de la section ?? : un modèle peut être explicable mais moins performant qu'un empilement opaque. Dans la contribution, l'analyse SHAP accompagne surtout le **compromis interprétabilité-performance** (fusion pour un bon compromis, stacking pour le gain maximal) et la validation face aux experts.

1.5.5. Limites et recul épistémologique

Une variable importante au sens SHAP (proximité d'une installation, co-contaminant, embedding lié à un cluster géographique) signale une **association statistique** apprise par le modèle, pas un mécanisme physique démontré. Les variables corrélées se partagent le crédit : l'ordre d'importance peut varier selon l'échantillon et la distribution de référence. Les explications portent sur le **modèle entraîné** et le jeu de données considéré ; un réentraînement ou un changement de protocole (par exemple passage au mode confirmatoire avec concentrations PFAS) peut modifier les profils SHAP même si les tendances physiques demeurent qualitatives.

Pour le HGT, la partie du signal portée par la **topologie** du graphe (chemins entre `facility`, `env`, `sample`) n'est pas entièrement dépliée dans les graphiques

tabulaires ou d’embeddings. Enfin, l’usage opérationnel suppose une **lecture conjointe** avec des hydrogéologues et des toxicologues : l’outil priorise et explique, la décision publique reste argumentée au-delà du seul score algorithmique.

I.6. Synthèse

Ce chapitre a introduit, de manière autonome et progressive, les concepts mobilisés dans la suite du mémoire. Les **PFAS** ont été présentés comme polluants persistants, soumis à un encadrement réglementaire de plus en plus strict. Les paradigmes de l’**apprentissage automatique** (supervisé, non supervisé, semi-supervisé et par renforcement), les métriques F1 et ROC-AUC, les méthodes d’ensemble par **bagging** (forêt aléatoire), **boosting** (XGBoost, LightGBM) et **stacking** (méta-classifieur), ainsi que le traitement du **déséquilibre** par SMOTE et ADASYN, constituent le socle des méthodes prédictives en données tabulaires. Les **graphes hétérogènes** (nœuds `sample`, `env`, `facility`, `water`, `geo_cluster`), les GNN, le **HGT** et les schémas de fusion ou de stacking entre embeddings graphiques et modèles tabulaires, préparent la lecture des approches hybrides développées dans la suite du mémoire. Enfin, **SHAP** et TreeSHAP (analyses globale et locale, graphiques de dépendance) permettent d’expliquer les modèles tabulaires, la fusion embeddings–XGBoost, le stacking sur méta-caractéristiques et, partiellement, le HGT par sensibilité au gradient ; cette interprétabilité conditionne une utilisation responsable en santé environnementale, sous réserve d’un recul sur la causalité.

Le chapitre ?? examine comment ces outils ont été appliqués à la prédiction des PFAS et des contaminants en eaux souterraines. Le chapitre consacré à la contribution présente, quant à lui, le protocole expérimental, les choix d’implémentation et les résultats obtenus dans le cadre de ce mémoire.

II

CHAPTER

ÉTAT DE L'ART SUR LA PRÉDICTION DES CONTAMINANTS ÉMERGENTS DE L'EAU PAR INTELLIGENCE ARTIFICIELLE

SOMMAIRE

II.1 - Introduction	30
II.2 - Cadre conceptuel de la revue	31
II.3 - Modèles tabulaires pour la prédiction des PFAS	34
II.4 - Architectures profondes et relationnelles	42
II.5 - Discussion	45
II.6 - Synthèse	49

II.1. Introduction

La surveillance des PFAS dans les eaux souterraines constitue un défi analytique et économique majeur : les analyses par chromatographie en phase liquide couplée à la spectrométrie de masse tandem coûtent plusieurs centaines d'euros par échantillon, tandis que les seuils réglementaires se durcissent rapidement. L'Agence de protection de l'environnement américaine a abaissé en 2023 la valeur maximale admissible à 4 ng/L pour le PFOA et le PFOS pris séparément [?]; la directive européenne sur l'eau potable (2020/2184) impose une limite de 0,5 µg/L pour la somme des PFAS détectables [?]. Ces contraintes rendent impossible un contrôle exhaustif de l'ensemble du parc de puits pour la plupart des gestionnaires de réseaux.

C'est dans ce contexte que les méthodes d'intelligence artificielle se sont progressivement imposées comme outils de **priorisation** : plutôt que de remplacer les mesures de laboratoire, elles permettent d'orienter les campagnes vers les sites présentant la plus forte probabilité de dépassement des seuils réglementaires, à partir d'informations contextuelles disponibles sans analyse PFAS préalable. Les enjeux sanitaires, la structure chimique des PFAS et les fondements algorithmiques des méthodes mobilisées ont été détaillés au chapitre ?? ; ce chapitre se concentre sur leur application au problème de surveillance.

Depuis les premiers travaux de la décennie 2010, trois générations de méthodes se succèdent dans la littérature. Une première génération de **modèles probabilistes et tabulaires** (réseaux bayésiens, forêts aléatoires, gradient boosting) traite chaque puits comme un vecteur de descripteurs indépendants pour produire des cartes de vulnérabilité régionales et nationales. Une deuxième génération introduit les **architectures de réseaux de neurones** : d'abord sur données moléculaires (QSAR), puis sous forme de chaînes de classifieurs semi-supervisées capables de prédire simultanément le statut de plusieurs dizaines d'analytes. Une troisième génération, encore récente, mobilise les **graphes hétérogènes** pour encoder explicitement la topologie du réseau de surveillance : les puits y sont des nœuds reliés par des arêtes typées à des sources anthropiques, des variables environnementales et des clusters géographiques.

Ce chapitre passe en revue ces trois générations de manière structurée. La section ?? présente le cadre conceptuel spécifique à la revue, dont la distinction mode prédictif/confirmatoire qui conditionne l'interprétation de tous les résultats. La section ?? examine les méthodes tabulaires, organisées en approches probabilistes (section ??), méthodes d'ensemble (section ??) et attribution de sources (section ??). La section ?? étudie les architectures profondes et relationnelles : réseaux de neurones (section ??), apprentissage semi-supervisé multi-analytes (section ??) et graphes hétérogènes hybrides (section ??). La section ?? propose une discussion transversale avec tableau comparatif et identification des lacunes structurelles. Une synthèse clôt le chapitre en section ??.

Les définitions algorithmiques des méthodes mobilisées (forêt aléatoire, XG-Boost, LightGBM, HGT, SMOTE, ADASYN, SHAP, stacking) ne sont pas réitérées : voir chapitre ??, sections ?? et ??.

II.2. Cadre conceptuel de la revue

Avant d'examiner les travaux, quatre éléments conceptuels propres à cette revue doivent être posés. Le premier est la formalisation du problème de prédiction ML sur données PFAS. Le deuxième et le troisième établissent le socle métrique commun (métriques d'évaluation, gestion du déséquilibre de classes) qui sert de référence à toutes les comparaisons inter-études. Le quatrième, et le plus fondamental, est la distinction entre mode prédictif et mode confirmatoire : mal comprise, elle conduit à des comparaisons de performance trompeuses entre études.

II.2.1. Formalisation du problème de prédiction PFAS par apprentissage automatique

La prédiction du statut de contamination d'un puits se formule en **classification binaire** (un analyte ou la somme PFAS totale, $y \in \{0, 1\}$, voir section ??) ou, pour les pipelines prédisant plusieurs dizaines d'analytes simultanément, en **classification multi-étiquettes** ($y \in \{0, 1\}^L$, L analytes). Cette dernière formulation, absente du cadre multiclassique classique présenté au chapitre ??, est propre à la littérature PFAS [?] et conditionne le choix des architectures présentées en section ??.

Le **déséquilibre structurel de classes** (exposé en section ?? avec SMOTE [?] et ADASYN [?]) est particulièrement marqué dans les corpus de surveillance PFAS : le rapport classes minoritaires/majoritaires est souvent compris entre 1/10 et 1/50, rendant l'accuracy trompeuse [?]. Le score F1 (section ??) est retenu comme indicateur de référence dans ce chapitre, complété par l'AUC-ROC pour les comparaisons inter-études.

II.2.2. Métriques d'évaluation des classifieurs de contamination PFAS

La comparaison des méthodes exigée par la revue nécessite un socle métrique commun. En **classification binaire** (présence/absence d'un PFAS, dépassement de seuil réglementaire), les prédictions se confrontent à la vérité terrain via une **matrice de confusion** recensant quatre effectifs : vrais positifs (VP), vrais négatifs (VN), faux positifs (FP) et faux négatifs (FN) (tableau ??).

Table VI – *Matrice de confusion pour une classification binaire (classe positive = site contaminé).*

	Prédit 0	Prédit 1
Réel 0	Vrai négatif (VN)	Faux positif (FP)
Réel 1	Faux négatif (FN)	Vrai positif (VP)

En surveillance environnementale, un faux négatif (site contaminé non détecté) est plus grave qu'un faux positif (prélèvement inutile) ; les métriques retenues dans

la littérature reflètent ce souci. L'**exactitude** ($\text{Acc} = (VP + VN) / (VP + VN + FP + FN)$) est trompeuse sous un fort déséquilibre de classes (section ??). Le **score F1**, moyenne harmonique de la précision et du rappel, est la métrique de référence :

$$F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}, \quad \text{avec} \quad \text{Rappel} = \frac{VP}{VP + FN}. \quad (\text{II.1})$$

La **ROC-AUC** complète le F1 pour les comparaisons inter-études : elle mesure la capacité du modèle à séparer les classes sur l'ensemble des seuils de décision, indépendamment du seuil opérationnel [?]. En classification multi-étiquettes (L analytes), le F1 **macro** (moyenne uniforme sur les L analytes) est privilégié pour éviter de masquer les mauvaises performances sur les analytes rares.

II.2.3. Déséquilibre de classes et rééchantillonnage synthétique

Dans les corpus de surveillance PFAS, la classe positive (détection ou dépassement de seuil) est structurellement minoritaire : le rapport peut atteindre 1/10 à 1/50 selon les analytes et la région [?, ?]. Un classifieur non corrigé tend à ignorer la classe positive pour maximiser l'exactitude, ce qui est inacceptable en surveillance sanitaire.

SMOTE (*Synthetic Minority Over-sampling Technique*) [?] génère des exemples synthétiques dans la classe minoritaire par interpolation linéaire entre un exemple $\mathbf{x}_i$ et l'un de ses k voisins minoritaires :

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda (\mathbf{x}_j - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1). \quad (\text{II.2})$$

ADASYN (*Adaptive Synthetic Sampling*) [?] prolonge SMOTE en concentrant la génération sur les exemples minoritaires les plus proches de la frontière de décision : le nombre d'exemples synthétiques alloué à chaque $\mathbf{x}_i$ est proportionnel à la fraction $r_i = \Delta_i/k$ de ses k voisins appartenant à la classe majoritaire. Cette focalisation adaptative est particulièrement pertinente lorsque les sites contaminés sont spatialement dispersés dans un corpus hétérogène, comme dans les études californiennes à grande échelle.

Règle méthodologique commune. SMOTE et ADASYN ne s'appliquent qu'au **jeu d'entraînement** ; les jeux de validation et de test conservent la distribution réelle des classes pour éviter toute surestimation des métriques. Cette règle est appliquée dans tous les travaux examinés ; son non-respect est signalé explicitement dans les limites.

II.2.4. Mode prédictif et mode confirmatoire

Une distinction conceptuelle, trop souvent implicite dans la littérature, sépare deux régimes d'évaluation radicalement différents.

Le **mode confirmatoire** désigne la configuration où le vecteur de features comprend des **concentrations PFAS mesurées** (partielles ou complètes) pour le puits évalué. La variable cible est dérivée de ces mesures : $\mathbb{I}[\text{PFAS}_{\text{total}} > 70 \text{ ng/L}]$ en référence aux limites EPA 2016 [?]. Cette formulation crée une **circularité partielle** : les entrées contiennent directement ou indirectement l'information déterminant l'étiquette. Les performances publiées en mode confirmatoire (F1 de l'ordre de 0,96 à 0,977) ne reflètent donc pas ce que le modèle ferait sur un puits jamais analysé.

Le **mode prédictif** correspond au scénario opérationnellement pertinent : classer un puits **avant** tout prélèvement PFAS, sur la seule base d'informations contextuelles disponibles a priori (géologie, hydrologie, qualité générale de l'eau, proximité aux sources anthropiques, coordonnées géographiques). Formellement, si $\mathbf{x}_c$ est le vecteur de variables contextuelles et $\mathbf{x}_p = (\tilde{c}_1, \dots, \tilde{c}_K)$ les concentrations PFAS mesurées :

$$\text{Mode prédictif : } \hat{y} = g(\mathbf{x}_c), \quad (\text{II.3})$$

$$\text{Mode confirmatoire : } \hat{y} = g(\mathbf{x}_c, \mathbf{x}_p). \quad (\text{II.4})$$

Les deux modes répondent à des questions métiers distinctes : le mode prédictif (Dois-je envoyer un préleveur ?) précède l'analyse ; le mode confirmatoire (Ce profil partiel indique-t-il un dépassement global ?) complète un laboratoire partiellement informé. C'est le mode prédictif qui détermine la valeur réelle d'un outil d'aide à la décision pour les gestionnaires de réseaux ; c'est celui que nous adoptons exclusivement dans notre contribution.

Cette clé de lecture est appliquée systématiquement à chaque travail examiné dans les sections suivantes.

II.3. Modèles tabulaires pour la prédiction des PFAS

Les méthodes tabulaires constituent le fondement de la littérature prédictive sur les PFAS. Elles traitent chaque puits comme un **vecteur de variables contextuelles** dont la pertinence repose sur les mécanismes physico-chimiques de transport des PFAS en aquifère (section ??). Leur avantage principal est la **compatibilité directe** avec les bases de surveillance environnementale structurées en

tableaux, sans recours à des architectures graphiques ou à des modèles de transport hydrogéologique. Leur **limite structurelle** est l'hypothèse d'indépendance des observations : la topologie du réseau de surveillance et les liens de voisinage entre puits ne sont pas exploités.

II.3.1. Mécanismes de transport des PFAS et pertinence des variables contextuelles

La sélection des variables contextuelles dans les modèles ML de prédiction des PFAS n'est pas arbitraire : elle découle directement des mécanismes physico-chimiques qui gouvernent le devenir et le transport des PFAS en milieu souterrain. Trois processus principaux, décrits par Guelfo et al. [?] dans une revue exhaustive de l'état de la science, conditionnent la distribution spatiale des concentrations observées.

Advection et atténuation en fonction de la distance. Les PFAS se déplacent principalement par **advection** avec le flux d'eau souterraine, suivant les lignes d'écoulement depuis les zones de recharge vers les zones de décharge. Prevedouros et al. [?] montrent que les concentrations de PFCAs décroissent avec la distance aux sources ponctuelles : la proximité à une installation fluorochimique, une base militaire (usage de mousses AFFF) ou une station d'épuration constitue donc un **proxy du flux de contamination advectif**. C'est ce constat mécaniste qui fonde l'utilisation systématique, dans toutes les études examinées, du nombre d'installations à 1, 3, 10 et 50 km comme variables prédictives.

Rétention sur la matrice solide. Brusseau et al. [?] établissent un modèle de rétention complet montrant que les PFAS se sorbent sur la matière organique du sol et sur les interfaces air-eau des zones vadoses : la granulométrie (proportion d'argiles, de limons, uniformité de la distribution), la teneur en matière organique et la profondeur de la nappe modulent fortement la mobilité des différentes familles de PFAS. Les composés à longue chaîne (PFOS, PFOA) se retiennent davantage que les composés à chaîne courte (PFBS, PFPeA), plus mobiles mais aussi plus difficiles à éliminer. Ce mécanisme justifie l'inclusion de descripteurs de sol (granulométrie, teneur en argile, ratio eau-argile) dans les vecteurs de features des modèles tabulaires.

Déposition atmosphérique. Les PFAS volatils ou semi-volatils (fluorotélomères, sulfonamides) sont émis dans l'atmosphère par les installations industrielles, trans-

portés sur des distances pouvant dépasser 50 km et déposés par les précipitations [?]. Ce vecteur de contamination **diffus et longue portée** explique pourquoi les variables météorologiques (humidité, précipitations, qualité de l'air : $\text{PM}_{2.5}$, NO_2) figurent parmi les prédicteurs importants identifiés par Dong et al. [?], alors qu'elles ne sont pas directement liées aux sources ponctuelles locales.

Conséquences pour la modélisation par graphes. L'advection crée une **dépendance spatiale structurelle** entre puits : deux puits situés en aval d'une même source partagent un contexte de contamination commun qui ne peut pas être capturé par des vecteurs indépendants. Cette dépendance est directionnelle (orientée par le sens de l'écoulement) et hétérogène (matières de l'intensité du flux, de la lithologie, de la proximité à la source). Les **graphes hétérogènes** (section ??) sont précisément conçus pour encoder cette topologie : les arêtes de voisinage géographique entre nœuds `sample` et `geo_cluster` représentent la propagation advective ; les arêtes `near/near_to` vers les nœuds `facility` quantifient le flux de contamination par proximité de source. Cette justification mécaniste motive directement les choix d'architecture de notre contribution (voir chapitre suivant), et sera mise à l'épreuve par les analyses d'ablation présentées en mode prédictif.

II.3.2. Approches probabilistes et géostatistiques

Les réseaux bayésiens (graphe orienté acyclique, DAG) se distinguent des méthodes discriminantes classiques par leur capacité à représenter des dépendances conditionnelles non monotones et à inférer avec des données manquantes : pour une variable cible Y et un ensemble d'observations $\mathbf{e}$, la distribution a posteriori $P(Y \mid \mathbf{e})$ est calculée en marginalisant les variables non observées via la factorisation de Markov du DAG. Cette propriété est décisive en surveillance des PFAS, où les jeux de données sont structurellement incomplets (valeurs censurées, campagnes hétérogènes).

II.3.2.1. Travaux de Li et MacDonald Gibson (2022)

Problème. Li et MacDonald Gibson [?] cherchent à prédire la présence des PFAS à chaîne courte (PFBS, PFBA, PFPeA et leurs précurseurs fluorotélomères) dans les eaux souterraines du Minnesota. Ces composés, substituts industriels aux PFAS à longue chaîne progressivement interdits, sont plus hydrophiles, plus mobiles en phase aqueuse et moins fréquemment mesurés dans les bases historiques, ce qui limite les approches purement supervisées.

Méthodologie. Les auteurs agrègent les données du programme de surveillance du Minnesota, recodent les valeurs sous le seuil de détection à LD/2 et

standardisent 88 variables contextuelles couvrant : proximité aux sources industrielles (distance aux usines 3M de Cottage Grove et Oakdale), caractéristiques hydrogéologiques régionales, occupation du sol et co-contaminants inorganiques. La structure du DAG est apprise automatiquement par Hill Climbing avec score BIC.

Résultats (mode prédictif partiel). Les AUC-ROC dépassent **0,96** pour les composés les mieux représentés (PFOS, PFOA, PFHxS) et sont de l'ordre de **0,78 à 0,82** pour les composés à chaîne courte. Les arêtes les plus fortes du DAG relient le statut de contamination PFAS aux variables de proximité industrielle, médiatisée par les zones humides (bassins de rétention des composés PFAS transportés par ruissellement).

Limites. Le modèle est entraîné et validé exclusivement sur le Minnesota (transférabilité non validée). La présence de mesures PFAS partielles dans les données d'entraînement introduit une **composante confirmatoire implicite** difficile à isoler sans protocole de division strict par site.

II.3.2.2. Travaux de McMahon et al. (2022)

Problème. McMahon et al. [?] cherchent à caractériser la distribution spatiale des concentrations PFAS dans les eaux souterraines potables de l'est des États-Unis à partir de proxies géochimiques, en s'affranchissant de mesures PFAS ciblées systématiques.

Méthodologie. Les auteurs mobilisent des arbres de régression boostés (BRT, variante de gradient boosting, section ??) sur un corpus de plusieurs centaines d'échantillons géoréférencés. Les prédicteurs incluent la concentration en tritium (^3H), le carbone organique dissous (COD), la présence de solvants chlorés volatils (TCE, PCE) et divers indicateurs hydrogéologiques régionaux.

Résultats (mode prédictif). Le tritium, indicateur d'une recharge récente, est le prédicteur le plus fortement associé aux concentrations PFAS élevées : résultat mécaniquement interprétable, les aquifères rechargés récemment ayant été en contact avec des eaux de surface potentiellement contaminées par les rejets industriels de la seconde moitié du XX^e siècle. Le COD et les solvants chlorés constituent également des co-prédicteurs significatifs, suggérant que les indicateurs indirects d'activité industrielle peuvent servir de proxies efficaces sans mesure PFAS directe.

Limites. Les auteurs ne fournissent pas de métriques quantitatives de classification ; le travail est davantage descriptif qu'opérationnel pour la priorisation directe

des puits. Il n'est pas transposable tel quel à une démarche de priorisation sans étape de calibration quantitative supplémentaire.

II.3.2.3. Travaux de Hu et al. (2021)

Problème. Environ 43 millions d'Américains dépendent de puits privés qui échappent aux programmes de surveillance institutionnels. Hu et al. [?] cherchent à identifier ces puits à risque élevé à l'échelle nationale sans disposer d'aucune donnée analytique PFAS a priori.

Méthodologie. Les auteurs mobilisent uniquement des variables contextuelles disponibles sans campagne PFAS : densité d'installations militaires et aéronautiques dans un rayon de 20 km, proximité de stations d'épuration et de décharges, caractéristiques pédologiques. Ce protocole constitue un exemple référence de **mode prédictif pur**, sans aucune mesure PFAS en entrée.

Résultats (mode prédictif pur). Les auteurs produisent des **cartes de vulnérabilité nationales** permettant de prioriser les puits à contrôler. La démarche démontre qualitativement sa valeur pour orienter des campagnes d'information à grande échelle.

Limites. La validation externe reste absente ; l'incertitude sur les estimations n'est pas quantifiée. La couverture nationale introduit un lissage régional pouvant sous-représenter des aquifères spécifiques.

II.3.3. Méthodes d'ensemble pour la priorisation des puits

L'émergence des méthodes d'ensemble à base d'arbres (forêt aléatoire [?], XGBoost [?], LightGBM [?], section ??) a élargi les capacités de priorisation à des corpus de plus grande taille. Quatre propriétés expliquent leur domination sur les jeux de données tabulaires de surveillance PFAS [?] : compatibilité native avec les données mixtes, robustesse aux valeurs manquantes par branches par défaut, interprétabilité par importances SHAP [?], et absence de nécessité de réglage d'architecture. Le déséquilibre structurel de classes impose l'usage systématique de SMOTE ou ADASYN [?, ?] : Dong et al. [?] montrent que le choix de la stratégie de rééchantillonnage et du ratio cible influence de 3 à 12 points de F1 sur la classe positive, rendant non comparables les études qui omettent de documenter ce protocole.

II.3.3.1. Travaux de George et Dixit (2021)

Problème. George et Dixit [?] proposent l'un des premiers cadres dédiés à la priorisation des puits de surveillance PFAS par apprentissage automatique, sur un corpus californien constitué à partir des bases publiques du California State Water Resources Control Board. L'objectif est de concevoir un outil capable d'orienter

les prélèvements vers les sites à risque avant ou en complément des analyses de laboratoire.

Méthodologie. Les auteurs entraînent et comparent une **forêt aléatoire** et **XG-Boost** sur des descripteurs couvrant la proximité aux sources (bases militaires, sites industriels, stations d'épuration, aéroports), les caractéristiques hydrogéologiques (type de lithologie, perméabilité, profondeur de crépine, type d'aquifère) et la qualité générale de l'eau (nitrates, sulfates, chlorures, TDS). Le déséquilibre est corrigé par SMOTE avant entraînement ; les performances sont évaluées par validation croisée stratifiée à 5 plis.

Résultats (mode mixte). La forêt aléatoire obtient une AUC-ROC d'environ **0,948** et un F1 d'environ **0,964** ; XGBoost atteint respectivement **0,906** et **0,878**. L'analyse SHAP révèle que les variables de proximité aux bases militaires et aux installations fluorochimiques contribuent le plus à l'écart entre puits contaminés et non contaminés.

Limites. Les auteurs eux-mêmes signalent [?] qu'une fraction des observations inclut des mesures PFAS préalablement disponibles dans la base californienne, introduisant une **composante confirmatoire partielle** : les performances publiées ne reflètent pas nécessairement ce qui serait obtenu sur des puits jamais échantillonnés (cf. modes, section ??).

II.3.3.2. Travaux de Tokranov et al. (2024)

Problème. Tokranov et al. [?] étendent la démarche à l'échelle nationale américaine, en s'appuyant sur les données géochimiques de l'USGS collectées entre 2019 et 2022. L'enjeu est d'estimer l'exposition de la population américaine à une échelle encore inatteignable par les études régionales.

Méthodologie. Un modèle XGBoost est entraîné sur plusieurs milliers d'échantillons géoréférencés avec des centaines de variables couvrant la géologie, l'hydrologie, l'occupation du sol, la proximité aux sources et la profondeur des puits. L'importance des variables est analysée par SHAP global et par permutation.

Résultats (mode mixte). Les résultats permettent d'estimer qu'entre **71 et 95 millions d'Américains** dépendraient de sources d'eau souterraine avec des concentrations détectables de PFAS. L'analyse des importances classe en tête l'utilisation des sols en zone urbaine, la profondeur de crépine, la densité de population et la distance aux aéroports et centres d'entraînement des pompiers. Ce classement est cohérent avec celui de George et Dixit, confirmant la **robustesse du signal de proximité industrielle** à travers des régions géologiquement très diverses.

Limites. La présence de mesures PFAS dans une fraction des données d’entraînement introduit une composante confirmatoire partielle dont l’impact en déploiement pur reste difficile à quantifier a posteriori. Le lissage de la résolution régionale par la grande hétérogénéité des aquifères nationaux constitue une limite supplémentaire pour les applications locales.

Le tableau ?? compare les performances des approches tabulaires présentées dans ce groupe.

Table VII – *Performances des méthodes tabulaires sur la prédiction/priorisation des PFAS. Les métriques proviennent des articles sources ; les protocoles diffèrent entre études. † : présence probable de concentrations PFAS mesurées parmi les features (composante confirmatoire).*

Référence	Méthode	AUC-ROC	F1	Particularité
Li et al. [?]	Réseau bayésien	$\approx 0,78-0,96$	n.r.	PFAS CC, Minnesota
McMahon et al. [?]	BRT	(descriptif)	n.r.	Est États-Unis
Hu et al. [?]	Stats. contextuelles	(cartes)	n.r.	Puits privés USA
George et Dixit [?]	Forêt aléatoire	$\approx 0,948$	$\approx 0,964^\dagger$	Californie, mixte
George et Dixit [?]	XGBoost	$\approx 0,906$	$\approx 0,878^\dagger$	Californie, mixte
Tokranov et al. [?]	XGBoost	(national)	n.r.	Échelle nationale US

On observe que les scores les plus élevés ($F1 \approx 0,96$) sont obtenus dans des protocoles où des mesures analytiques PFAS peuvent figurer parmi les entrées, tandis que les approches purement contextuelles affichent des performances plus modestes mais opérationnellement plus représentatives.

II.3.4. Attribution des sources : une tâche confirmatoire connexe

L’attribution de sources (*source apportionment*) exploite les profils multi-analytes pour allouer un échantillon contaminé à un type de source : mousses anti-incendie AFFF, rejets d’usines fluorochimiques, stations d’épuration. Cette tâche, structurellement confirmatoire (les concentrations PFAS doivent être déjà connues), est incluse dans la revue parce qu’elle informe la sélection des variables de proximité dans les modèles de priorisation : les témoins chimiques caractéristiques de chaque type de source orientent le choix des types de nœuds dans le graphe hétérogène (section ??).

II.3.4.1. Travaux de Kibbey et al. (2020)

Problème. Kibbey et al. [?] cherchent à identifier la source de contamination PFAS (AFFF, industrie fluorochimique, station d’épuration) à partir du profil

analytique multi-composé d'un échantillon d'eau, sans nécessiter de modèle hydrogéologique.

Méthodologie. Les auteurs exploitent les **empreintes chimiques** des échantillons : les profils relatifs d'une cinquantaine de composés PFAS constituent un vecteur de caractéristiques multi-analytique. La pertinence de ce vecteur repose sur un fondement chimique : chaque type de source industrielle génère des profils PFAS spécifiques en termes de longueur de chaîne carbo-fluorée et de groupement fonctionnel terminal (sulfonate/carboxylate/phosphonate), partiellement conservés lors du transport en aquifère. Plusieurs algorithmes sont comparés (forêts aléatoires, SVM à noyau radial, classifieurs naïfs bayésiens), évalués par validation croisée à 10 plis.

Résultats (mode confirmatoire). Une précision d'attribution d'environ **90 %** est obtenue pour distinguer entre sources AFFF, industrielles et diffuses ; ce résultat démontre que la diversité structurale des profils PFAS encode des informations diagnostiques robustes.

Limites. La qualité de l'attribution dépend du nombre d'analytes ciblés ; les **mélanges de sources** génèrent des vecteurs ambigus pour lesquels les classifieurs standard produisent des attributions incertaines.

II.3.4.2. Travaux de Dávila-Santiago et al. (2022)

Problème. Dávila-Santiago et al. [?] prolongent la démarche de Kibbey et al. vers l'attribution de sources à partir de données **non ciblées** (NTS, *non-target screening*) : sans viser a priori un ensemble défini d'analytes, les techniques d'analyse de masse haute résolution (HRMS) détectent des milliers de signaux chimiques dans un échantillon.

Méthodologie. Les auteurs développent un pipeline intégrant normalisation et filtrage des signaux HRMS, réduction de dimension par décomposition en valeurs singulières (SVD) et un classifieur de gradient boosting sur l'espace réduit. Le pipeline est appliqué sur des jeux de données californiens d'eau de surface et souterraine.

Résultats (mode confirmatoire). Des signatures liées aux sources AFFF, industrielles et agricoles restent identifiables même sans ciblage analytique : la démarche ouvre la voie à un criblage de surveillance à grande échelle moins coûteux qu'une analyse multi-résidus ciblée systématique.

Limites. Le pipeline dépend fortement de la résolution HRMS disponible. Sa généralisation à des contextes où seul un LC-MS/MS standard est disponible reste à évaluer.

II.4. Architectures profondes et relationnelles

Les méthodes tabulaires traitent chaque puits comme un point isolé dans un espace de features et ignorent la **topologie** du réseau de surveillance. Or, les panaches de PFAS s'étendent le long de lignes d'écoulement préférentielles : les puits situés dans le même cluster géographique ou en aval d'une même source partagent un contexte de contamination commun que les vecteurs indépendants ne peuvent pas capturer. Les architectures profondes ont émergé pour intégrer ces dépendances : d'abord sur des données moléculaires (QSAR), puis sous forme de chaînes semi-supervisées multi-analytes, et enfin via des graphes hétérogènes modélisant la structure relationnelle complète du système de surveillance.

II.4.1. Réseaux de neurones sur données tabulaires et applications moléculaires

II.4.1.1. Travaux de Borisov et al. (2024)

Problème. Borisov et al. [?] évaluent empiriquement si les réseaux de neurones surpassent les arbres d'ensemble sur les jeux de données tabulaires de taille petite à moyenne : régime typique des corpus de surveillance environnementale, où quelques centaines à quelques dizaines de milliers d'observations analysées sont disponibles.

Méthodologie. Les auteurs réalisent un benchmark systématique comparant MLP génériques, TabNet [?] et SAINT [?] aux méthodes d'ensemble (forêt aléatoire, XGBoost) sur des jeux de données publics généraux et environnementaux, avec réglage soigneux des hyperparamètres pour toutes les architectures.

Résultats. Les méthodes d'ensemble à base d'arbres surpassent ou égalent les réseaux de neurones dans la grande majorité des benchmarks. Trois mécanismes explicatifs sont identifiés : (i) les données tabulaires ne sont pas invariantes par transformation, rendant inutilisable le biais inductif local des convolutions ; (ii) les effets non-linéaires sont souvent locaux et discrets dans les données environnementales, ce que les arbres capturent par leur mécanisme de partitionnement récursif ; (iii) les perceptrons requièrent davantage de données pour généraliser. Sur le corpus californien EW3C00134, qui compte environ 26 000 observations mais dont seulement 2 600 à 3 000 sont étiquetées, ces architectures tabulées profondes restent désavantagées par rapport à XGBoost.

Limites. Ces résultats sont généraux et ne ferment pas la porte aux architectures spécialisées exploitant la structure relationnelle des données de surveillance.

II.4.1.2. Travaux de Cheng et Ng (2019)

Problème. Cheng et Ng [?] cherchent à prédire la bioactivité de plus de 3 400 composés PFAS répertoriés sur la liste OCDE sur 26 cibles biologiques (protéines, enzymes, récepteurs cellulaires), sans expérimentation animale systématique, dans le cadre d’une approche QSAR (*Quantitative Structure-Activity Relationship*).

Méthodologie. Les auteurs comparent des classifieurs classiques, des réseaux de neurones multitâches (*Multitask Neural Networks*, MNN) partageant des couches entre les 26 cibles, et des réseaux convolutifs sur graphes moléculaires (GCN). Les molécules sont encodées par des descripteurs physicochimiques : masse molaire, $\log P$, nombre d’atomes de fluor, longueur de chaîne carbo-fluorée, groupe fonctionnel terminal.

Résultats (mode confirmatoire moléculaire). Les MNN et GCN moléculaires obtiennent une précision équilibrée entre 70 et 80 % selon l’essai ciblé, et une AUC moyenne de **0,916** pour les meilleures architectures, surpassant les classifieurs classiques de 5 à 10 points. L’apprentissage multitâche se révèle particulièrement bénéfique : le partage de représentations entre plusieurs cibles compense le manque d’étiquettes pour les essais peu documentés.

Limites. Cette approche est confirmatoire et moléculaire : elle prédit la bioactivité d’un composé PFAS, pas la contamination d’un puits de surveillance. Sa valeur pour ce mémoire est méthodologique : elle illustre que l’apprentissage profond trouve un terrain favorable dès lors que la **structure moléculaire** peut être exploitée directement, ce qui motive l’utilisation de GCN pour la modélisation des nœuds compound dans les graphes hétérogènes.

II.4.2. Apprentissage semi-supervisé multi-étiquettes pour la prédiction multi-analytes

La prédiction simultanée de plusieurs dizaines d’analytes se heurte à deux contraintes structurelles. La première est la **rareté des étiquettes** : moins de 10 % des sites du corpus californien EW3C00134 disposent de mesures PFAS complètes pour les 35 analytes cibles [?] ; les 90 % restants constituent des données non étiquetées exploitables. La seconde est la **corrélation inter-analytes** : les différents composés PFAS ne sont pas statistiquement indépendants dans un même échantillon ; leur cooccurrence encode l’empreinte chimique de la source [?].

Les **chaînes de classifieurs** [?] capturent ces dépendances en prédisant les étiquettes séquentiellement :

$$\hat{y}_\ell = f_\ell(\mathbf{x}, \hat{y}_1, \dots, \hat{y}_{\ell-1}), \quad \ell = 1, \dots, L, \quad (\text{II.5})$$

où chaque classifieur f_ℓ utilise les prédictions précédentes comme variables supplémentaires. L'apprentissage semi-supervisé (section ??) répond à la contrainte de rareté en générant des pseudo-étiquettes pour les observations non étiquetées dont la probabilité dépasse un seuil de confiance, puis en ré-entraînant sur le jeu élargi.

II.4.2.1. Travaux de Dong et al. (2024)

Problème. Dong et al. [?] cherchent à prédire, à partir de variables **contextuelles** exclusivement (sans concentration PFAS mesurée en entrée), deux cibles distinctes sur le corpus californien EW3C00134 : (i) le dépassement du seuil global de 70 ng/L (criblage binaire) et (ii) la présence de chacun des **35 analytes PFAS** individuels au-delà de 2 ng/L (classification multi-étiquettes). Le corpus regroupe 26 000 observations géoréférencées issues de 23 sources publiques (programme GAMA, Geotracker, EPA, NOAA, SGMA, etc.) pour la période 2016–2022, et constitue la base de données exploitée dans notre propre contribution.

Corpus et features. Après nettoyage (suppression des variables avec plus de 40 % de valeurs manquantes), les 112 variables d'entrée couvrent six catégories : sources de contamination (nombre d'installations industrielles à 1, 3, 10 et 50 km), géospatial/date, qualité de l'air et météo (humidité, PM_{2,5}, NO₂, SO₂), sol (granulométrie, uniformité), hydrologie, et qualité de l'eau souterraine mesurée via des **co-contaminants indicateurs** (solvants chlorés, hydrocarbures aromatiques, nitrates). **Aucune concentration PFAS mesurée n'est incluse dans ces features.** Les coordonnées géographiques explicites (longitude, latitude, comté) sont volontairement exclues afin d'améliorer la généralisabilité spatiale du modèle.

Méthodologie. Le pipeline est organisé en deux tâches séquentielles :

1. **Tâche 1 – Criblage total.** Un classifieur binaire (forêt aléatoire avec sur-échantillonnage ADASYN) prédit si la somme des concentrations PFAS dépasse 70 ng/L ; la cible est dérivée des données de laboratoire disponibles, les 112 features contextuelles servant de seule entrée.
2. **Tâche 2 – Prédiction multi-analytes.** Les 35 analytes sont répartis en quatre classes selon leur taux de détection (Class 0 : $n > 25\,000$ obs. ; Class 3 : $n < 100$ obs.). Pour chaque classe :
 - **Apprentissage semi-supervisé par pseudo-étiquetage** : un premier modèle est entraîné sur les puits étiquetés (PFAS mesuré) ; ses prédictions sur les puits non étiquetés (PFAS non mesuré) dont la probabilité

dépasse 95 % de confiance sont réintégrées comme pseudo-étiquettes dans un second entraînement.

- **Chaînes de classifieurs XGBoost** (équation (??)) : les analytes sont ordonnés par sous-famille (PFCAs, fluorotélomères, PFSAs, sulfonamides) puis par longueur de chaîne croissante ; chaque classifieur f_ℓ reçoit en entrée les 112 features contextuelles **ainsi que les étiquettes prédites** $\hat{y}_1, \dots, \hat{y}_{\ell-1}$ des analytes précédents. L'entrée supplémentaire de la chaîne est donc une **prédiction de modèle**, non une concentration PFAS mesurée.
- Sur-échantillonnage SMOTE (Task 2) sur le jeu d'entraînement uniquement.

Résultats. *Tâche 1* : la forêt aléatoire avec ADASYN atteint une AUC-ROC de **0,99**, une exactitude de 96 % et un rappel de 95 % sur le jeu de test final, surpassant XGBoost (AUC 0,91) et tous les classifieurs linéaires. *Tâche 2* : la chaîne de classifieurs XGBoost est la méthode la plus performante pour l'ensemble des classes ; les AUC-ROC moyennes par classe sont 0,938 (Class 0), 0,965 (Class 1), 0,942 (Class 2) et 0,985 (Class 3) ; la valeur minimale individuelle est 0,729 (PFBA, analyte très rare). Le pseudo-étiquetage améliore l'AUC de Class 2 de +2,9 **pp** (gain négligeable pour Classes 1 et 3). Les contamination sources (nombre d'installations à 1–50 km) et la granulométrie du sol dominent l'importance des variables pour les deux tâches ; un seul co-contaminant inorganique (nitrate) apparaît parmi les 20 variables les plus importantes.

Limites. Il importe de ne pas confondre **apprentissage semi-supervisé** et **mode confirmatoire** : le pseudo-étiquetage gère la rareté des étiquettes sur des puits non analysés, mais les features restent purement contextuelles. La chaîne de classifieurs exploite des **corrélations inter-analytes via des étiquettes prédites**, non des concentrations mesurées ; l'évaluation reste proche du **mode prédictif** au sens de la section ???. Les limites opérationnelles sont : (i) biais de sélection du programme GAMA (sur-représentation des zones suspectes) ; (ii) division aléatoire 80/20 sans contrainte géographique, exposant à un **spatial data leakage** ; (iii) dégradation du pseudo-étiquetage en dessous de 100 exemples étiquetés (Class 3).

II.5. Discussion

II.5.1. Tableau comparatif synthétique

Le tableau ?? synthétise les travaux examinés selon leur mode d'évaluation dominant, leur tâche et leurs métriques.

Table VIII – *Synthèse comparative des approches de prédiction PFAS examinées. Les métriques proviennent des articles sources ; protocoles et corpus différent entre études. * : présence de concentrations PFAS mesurées dans les features (mode confirmatoire dominant ou partiel).*

Référence	Méthode	Métrique	Mode	Tâche
Li et al. [?]	Réseaux bayésiens	AUC $\approx 0,78-0,96$	Préd. partiel	PFAS CC (MN)
Hu et al. [?]	Stats. con-textuelles	(cartes)	Prédictif pur	Vuln. puits privés
McMahon et al. [?]	BRT	(descriptif)	Descriptif	Profils régionaux
George & Dixit [?]	RF / XGBoost	F1 $\approx 0,96/0,88^*$	Mixte*	Priorisation bin. (CA)
Tokranov et al. [?]	XGBoost	(national)	Mixte*	Vuln. nationale US
Kibbey et al. [?]	ML supervisé	Préc. $\approx 90\%^*$	Confirmatoire	Attribution sources
Dávila-Santiago et al. [?]	ML non ciblé	(relatif)	Confirmatoire	NTS fingerprinting
Cheng et Ng [?]	QSAR/DNN	AUC moy. $0,916^*$	Confirmatoire	Bioactivité mol.
Dong et al. [?]	Semi-sup., CC	AUC $0,94-0,99$ (T1) ; $0,73-1,00$ (T2)	Prédictif (ctx)	35 analytes (CA)

On observe que les publications affichant les meilleurs scores ($F1 > 0,90$) mobilisent presque systématiquement des données analytiques PFAS dans leurs entrées. Deux travaux seulement (Li et al. et Hu et al.) évaluent leur modèle en mode prédictif strict ; cette lacune de documentation n'est pas anodine : un praticien qui lit $F1 = 0,96$ dans un article peut croire disposer d'un outil opérationnel de priorisation avant analyse, alors qu'il s'agit en réalité d'un outil de complétude d'un profil analytique partiellement connu. Aucune étude publiée ne compare les deux modes sur le même corpus avec le même protocole de division par site, ce qui motive directement le protocole expérimental présenté au chapitre suivant.

II.5.2. Lecture transversale : convergences et enseignements

Trois enseignements transversaux ressortent de la lecture croisée des dix travaux.

La proximité industrielle est le signal le plus robuste. De Li et al. (2022) à Tokranov et al. (2024), les variables de proximité aux bases militaires, aux usines

fluorochimiques et aux aéroports arrivent en tête des importances SHAP dans des contextes géologiques très différents. Ce résultat constitue un fondement solide pour la sélection des features contextuelles.

La complémentarité tabulaire/relationnelle est structurellement fondée. Les travaux exploitant la structure relationnelle entre analytes (chaînes de classifieurs, Dong et al.) ou entre puits voisins (approches graphiques) améliorent systématiquement leurs scores par rapport aux modèles tabulaires indépendants entraînés sur les mêmes features contextuelles. Aucun des deux régimes pris seul ne capture l'ensemble de l'information disponible : les features contextuelles encodent le risque statique, la structure relationnelle encode la corrélation spatiale entre puits voisins et la proximité aux sources anthropiques.

Le mode d'évaluation conditionne les performances de façon fondamentale. Les études dont les features comprennent des concentrations PFAS mesurées publient des scores bien supérieurs ($F1 > 0,90$) à celles qui s'appuient exclusivement sur des variables contextuelles. Cette différence ne reflète pas un surcroît de qualité algorithmique : elle quantifie la valeur informative des mesures de laboratoire, et ne vaut que si l'on compare strictement le même modèle dans les deux modes sur un même ensemble de test.

II.5.3. Lacunes structurelles identifiées

L'examen croisé des travaux révèle cinq lacunes structurelles.

L1 – Structure relationnelle sous-exploitée. La majorité des études tabulaires ignore les liens entre puits voisins, panaches et sources communes. Les graphes hétérogènes [?] comblent partiellement ce vide, mais la sensibilité des performances aux choix de construction du graphe (seuil de distance pour les arêtes, nombre de types de nœuds, dimension de l'embedding) n'a pas fait l'objet d'une étude de sensibilité systématique dans la littérature publiée. La question de la sensibilité au seuil de distance et au nombre de types de nœuds reste ouverte.

L2 – Biais d'évaluation circulaire. Plusieurs publications présentent des scores très élevés ($F1 > 0,90$) sans préciser si des concentrations PFAS mesurées figurent dans les features [?]. Peu de travaux documentent simultanément les deux modes sur le même corpus ; aucune étude publiée ne compare les deux modes avec le même protocole de division strictement par site. La vérification de l'absence de fuite d'information (les variables contextuelles ne doivent pas être corrélées à plus

de 10 % de variance avec les concentrations PFAS en mode prédictif) est une étape méthodologique souvent omise.

L3 – Transférabilité géographique non validée. Les modèles sont entraînés et testés sur une seule région (Californie, Minnesota, est des États-Unis). Les validations croisées spatiales (entraînement sur un aquifère, test sur un autre de lithologie différente) restent pratiquement absentes. Pour les graphes hétérogènes, la question est architecturalement profonde : le graphe étant construit sur les nœuds d'entraînement, une approche inductive [?] (GraphSAGE) serait requise pour généraliser à des nœuds non vus.

L4 – Graphes statiques face à une dynamique hydrogéologique variable. Les graphes hétérogènes de la littérature sont statiques : arêtes et valeurs de nœuds fixées à l'entraînement. Or, les conditions de recharge de la nappe et la direction des écoulements fluctuent saisonnièrement ; les événements de précipitations extrêmes peuvent remobiliser des PFAS fixés vers la nappe [?]. Des architectures de graphes temporels (TGN [?]) permettraient d'associer à chaque arête une série temporelle de poids reflétant les conditions de connectivité saisonnières ; leur intégration dans un pipeline PFAS reste une direction ouverte.

L5 – Interprétabilité insuffisamment standardisée. Si SHAP [?] s'impose progressivement comme standard, les protocoles varient fortement entre études. Les pipelines hybrides graphe et boosting soulèvent des questions spécifiques non encore codifiées : comment interpréter la contribution d'un embedding HGT agrégeant l'information de dizaines de nœuds voisins ? Comment comparer des valeurs Tree-SHAP exactes (XGBoost, LightGBM) à des estimations SHAP Kernel approximatives (HGT) ? Une variable tabulaire fortement corrélée à HGT_emb_0 verra sa valeur SHAP individuelle réduite par interaction, rendant son importance marginale sous-estimée.

Le tableau ?? positionne les principales contributions au regard de ces cinq lacunes.

On observe qu'aucun travail de la littérature n'adresse simultanément L1, L2 et L5 : les études tabulaires ignorent la structure relationnelle ; celles qui exploitent un graphe ne documentent pas le mode prédictif strict ; l'interprétabilité reste non standardisée. Notre contribution, décrite au chapitre suivant, adresse ces trois lacunes et apporte un élément partiel sur L3. Les lacunes L3 et L4 constituent des perspectives explicites pour des travaux ultérieurs.

Table IX – Positionnement des principales contributions au regard des cinq lacunes identifiées.

● : lacune adressée ; ○ : partiellement adressée ; × : non adressée. L1 : structure relationnelle ; L2 : biais confirmatoire ; L3 : transfert géographique ; L4 : graphe dynamique ; L5 : interprétabilité standardisée.

Référence	L1	L2	L3	L4	L5
Li et al. [?]	×	○	×	×	×
George et Dixit [?]	×	×	×	×	○
McMahon et al. [?]	×	○	○	×	×
Tokranov et al. [?]	×	○	●	×	○
Dong et al. [?]	×	×	×	×	○
Notre contribution	●	●	○	×	●

II.6. Synthèse

Ce chapitre a dressé un panorama structuré de l'état de l'art sur l'application de l'intelligence artificielle à la prédiction et à la surveillance des PFAS en eaux souterraines.

Bilan par génération. La première génération (modèles probabilistes et arbres d'ensemble) a établi le socle des variables prédictives (proximité aux sources, indicateurs hydrogéologiques, co-contaminants) et démontré la faisabilité de la priorisation opérationnelle à l'échelle régionale et nationale. La deuxième génération (semi-supervisé, chaînes multi-étiquettes) a étendu le champ à plusieurs dizaines d'analytes simultanément et exploité les données non étiquetées, au prix d'une dépendance au mode confirmatoire rarement explicitée. La troisième génération (graphes hétérogènes hybrides) représente l'état de l'art : elle intègre la topologie du réseau de surveillance et produit, selon les travaux disponibles, des gains mesurables en mode prédictif par rapport aux méthodes purement tabulaires.

Ce que la littérature dessine en creux. Les lacunes L1–L5 décrivent les contours d'un système idéal de priorisation des puits : fonctionnant sans aucune mesure PFAS préalable (mode prédictif pur), intégrant les relations spatiales via un graphe hétérogène, communiquant son incertitude par des probabilités calibrées, interprétable par SHAP globale et locale, et validé sur une division spatiale indépendante. Aucune étude publiée ne satisfait simultanément l'ensemble de ces critères, ce qui définit le périmètre de la contribution présentée dans les chapitres suivants.

Positionnement de la contribution. Les lacunes L1 et L2 motivent directement les choix méthodologiques décrits dans le chapitre suivant : corpus EW3C00134 en mode prédictif exclusif (17 variables contextuelles, aucune concentration PFAS en entrée), graphe hétérogène à six types de nœuds, évaluation de quatre pipelines (XGBoost seul, HGT seul, fusion embeddings, stacking) selon un protocole de

division par site rigoureux avec vérification d'absence de fuite d'information, et analyse SHAP globale et locale sur les quatre architectures.

III

CHAPTER

FUSION CONSENSUELLE DES MISES À JOUR DES RÉPLIQUES PARTIELLES

CONCLUSION GÉNÉRALE

CONTENTS

La problématique étudiée et les choix méthodologiques	52
Analyse critique des résultats obtenus	52
Quelques perspectives	52

Le bilan...

La problématique étudiée et les choix méthodologiques

Nous...

Analyse critique des résultats obtenus

Sachant...

Quelques perspectives

Ce travail...



UN AUTRE EXEMPLE COMPLET DE FUSION CONSENSUELLE

Dans cette annexe...

Les schémas des règles de transition

Rappelons que les schémas des transitions (complétés pour prendre en compte les documents non clos) de l'automate permettant de représenter les expansions des répliques partielles suivant la vue $\mathcal{V}_1 = \{A, B\}$ lorsqu'on associe les symboles de Dyck '(' et ')' (resp. '[' et ']') au symbole visible A (resp. B) et qu'on associe les symboles ' $(_\omega$ ' et ' $)_\omega$ ' (resp. ' $[_\omega$ ' et ' $]_\omega$ ') au bourgeon A_ω (resp. B_ω) de type A (resp. B), sont les suivants:

De même...

Table X – Les schémas des règles de transition pour notre exemple

$\langle A, w_1 \rangle \longrightarrow$	$(P_1, [\langle C, u \rangle, \langle B, v \rangle])$	si $w_1 = u[v]$
$\langle A, w_2 \rangle \longrightarrow$	$(P_1, [\langle C, u \rangle, \langle B, w_{11} \rangle])$	si $w_2 = uw_{11}$ avec $w_{11} = [\omega]_\omega$
$\langle A, w_3 \rangle \longrightarrow$	$(P_2, [])$	si $w_3 = \varepsilon$
$\langle A, w_4 \rangle \longrightarrow$	$(A_\omega, [])$	si $w_4 = (\omega)_\omega$
$\langle B, w_5 \rangle \longrightarrow$	$(P_3, [\langle C, u \rangle, \langle A, v \rangle])$	si $w_5 = u(v)$
$\langle B, w_6 \rangle \longrightarrow$	$(P_3, [\langle C, u \rangle, \langle A, w_4 \rangle])$	si $w_6 = uw_4$
$\langle B, w_7 \rangle \longrightarrow$	$(P_4, [\langle B, u \rangle, \langle B, v \rangle])$	si $w_7 = [u][v]$
$\langle B, w_8 \rangle \longrightarrow$	$(P_4, [\langle B, w_{11} \rangle, \langle B, v \rangle])$	si $w_8 = w_{11}[v]$
$\langle B, w_9 \rangle \longrightarrow$	$(P_4, [\langle B, u \rangle, \langle B, w_{11} \rangle])$	si $w_9 = [u]w_{11}$
$\langle B, w_{10} \rangle \longrightarrow$	$(P_4, [\langle B, w_{11} \rangle, \langle B, w_{11} \rangle])$	si $w_{10} = w_{11}w_{11}$
$\langle B, w_{11} \rangle \longrightarrow$	$(B_\omega, [])$	si $w_{11} = [\omega]_\omega$
$\langle C, w_{12} \rangle \longrightarrow$	$(P_5, [\langle A, u \rangle, \langle C, v \rangle])$	si $w_{12} = (u)v$
$\langle C, w_{13} \rangle \longrightarrow$	$(P_5, [\langle A, w_4 \rangle, \langle C, v \rangle])$	si $w_{13} = w_4v$
$\langle C, w_{14} \rangle \longrightarrow$	$(P_6, [\langle C, u \rangle, \langle C, v \rangle])$	si $w_{14} = uv \neq \varepsilon$
$\langle C, w_{15} \rangle \longrightarrow$	$(C_\omega, [])$	si $w_{15} = \varepsilon$



APPENDIX

QUELQUES FONCTIONS HASKELL POUR LE CALCUL DES CONSENSUS

Dans cette annexe...

Représentation des grammaires et des vues

Une grammaire est constituée d'un ensemble de symboles et d'un ensemble de productions. Nous représentons une grammaire par le type `Gram` suivant:

```
1 data Gram prod symb = Gram {prods::[prod],
2                               symbols::[symb],
3                               lhs::prod -> symb,
4                               rhs::prod -> [symb]}
```

La fonction `lhs` (resp. `rhs`) prend en argument une grammaire `G` et une production `p` de `G` puis retourne le symbole en partie gauche (resp. la liste des symboles en partie droite) de `p`. À partir de ce type, on peut construire la grammaire $\mathbb{G}_{expl}$ (chap ?? exemple ??) grâce au code Haskell suivant:

```
1 data Prod = P1 | P2 | P3 | P4 | P5 | P6 | P7 | Aomega | Bomega | Comega
2           deriving (Eq, Show)
3 data Symb = A | B | C deriving (Eq, Show)
4
5 gram :: Gram Prod Symb
6 gram = Gram lprod lsymb lhs_ rhs_
7   where
8     lprod = [P1, P2, P3, P4, P5, P6, P7]
9     lsymb = [A, B, C]
10    lhs_ p = case p of
11      P1 -> A; P2 -> A; P3 -> B; P4 -> B; P5 -> C; P6 -> C; P7 -> C
12    rhs_ p = case p of
13      P1 -> [C, B]; P2 -> []; P3 -> [C, A]; P4 -> [B, B];
14      P5 -> [A, C]; P6 -> [C, C]; P7 -> []
```

Les productions Aomega, Bomega et Comega ont été introduites pour pouvoir désigner les bourgeons de types respectifs A, B et C.